

# 基于 EEMD-LSSVM 的超短期负荷预测

王新, 孟玲玲

(河南理工大学电气工程与自动化学院, 河南 焦作 454000)

**摘要:** 针对传统的最小二乘支持向量机(LSSVM)参数不易确定且单一预测模型精度不高的问题, 提出了一种基于集合经验模态分解(EEMD)与 LSSVM 的组合预测模型。首先利用 EEMD 将历史数据分解成一系列相对比较平稳的分量序列, 再对各子序列分别建立合适的预测模型。进一步通过贝叶斯证据框架来优化 LSSVM 的参数, 用贝叶斯推理确定模型参数、正规化超参数和核参数。然后将各子序列预测结果进行叠加得到最终预测值。最后, 将该预测模型用于某一家庭超短期负荷预测中, 仿真结果表明, 该模型取得了比单一模型更好的预测效果。

**关键词:** 超短期负荷预测; 集合经验模态分解; 最小二乘支持向量机; 贝叶斯框架; 时间序列

## Ultra-short-term load forecasting based on EEMD-LSSVM

WANG Xin, MENG Lingling

(School of Electrical Engineering and Automation, Henan Polytechnic University, Jiaozuo 454000, China)

**Abstract:** To solve the problem of the uncertain parameters and the low precision of the single forecasting model for the traditional least squares support vector machine (LSSVM), a combined forecasting model based on ensemble empirical mode decomposition (EEMD) and the LSSVM is proposed. Firstly, the historical data is decomposed into a series of relatively stable component of the sequence by the EEMD, and then the appropriate forecasting model is established for each component of the sequence. The parameters of the LSSVM are optimized through the Bayesian evidence framework. Bayesian inferences are used to determine model parameters, regularization hyper-parameters and kernel parameters. The results of each component forecasting are superimposed to obtain the final forecasting result. Finally, a household ultra-short-term load data is used to validate the model, and the simulation results show that this model has achieved better forecasting result than a single model.

**Key words:** ultra-short-term load forecasting; ensemble empirical mode decomposition; least squares support vector machine; Bayesian framework; time series

中图分类号: TM715      文献标识码: A      文章编号: 1674-3415(2015)01-0061-06

## 0 引言

预测是通过历史数据来推断事物发展的趋势。由于预测问题本身存在一定的复杂性, 虽然对同一问题可以有多种预测方法, 但通过传统的预测方法来预测对象的发展趋势, 其预测精度普遍不高。因此, 新的预测理论及方法一直是国内外学者研究的热点。M. Beccali 提出了运用 Elman 神经网络预测模型对家庭用电情况进行分析和预测, 得到了较高的预测精度<sup>[1]</sup>。神经网络在预测中广泛应用, 但神经网络本身也存在结构不易确定, 易过学习、陷入

局部极小值等问题<sup>[2]</sup>。叶林提出了经验模态分解(Empirical Mode Decomposition, EMD)与支持向量机的组合方法对短期风电功率进行了预测<sup>[3]</sup>, 并与单一的预测模型进行全面对比分析, 验证了组合预测模型有更高的预测精度。基于统计理论的支持向量机方法采用结构风险最小化的原则, 成功地解决了高维和局部极值的问题, 得到了全局最优解, 并且结构比较简单, 但支持向量机的训练涉及二次规划等问题, 计算比较复杂。

LSSVM是在标准支持向量机的基础上进行改进得到的<sup>[4-5]</sup>, 它将耗时的二次规划问题转变成线性方程组求解问题, 有效地降低了计算复杂度, 加快了运算速度, 但是其预测精度很大程度上依赖于正规化参数 $\gamma$ 和核参数 $\sigma$ 。因此, 取得最优的 $\gamma$ 和 $\sigma$ 是LSSVM建模预测的关键, 常用的优化算法有遗传

基金项目: 河南省科技攻关项目(142102210048); 河南省高校科技创新人才支持计划项目(2008HASTIT022)

算法、粒子群算法等<sup>[6-7]</sup>,但在寻优过程中也存在一定的缺陷。由于贝叶斯证据方法具有逻辑完备性,非常适合于非线性模型参数优化的问题<sup>[8-9]</sup>,所以本文采用贝叶斯证据框架对 LSSVM 的参数进行优化。

本文将 EEMD 和 LSSVM 方法相结合,建立 EEMD-LSSVM 组合预测模型。通过 EEMD 将时间序列分解成一系列具有不同特征尺度的本征模态函数(Intrinsic Mode Function, IMF),然后对每个 IMF 分量分别建立预测模型,并采用贝叶斯证据方法进行参数优化,得到优化模型。最后,以某一家庭的超短期负荷数据为例进行实验分析,仿真结果表明 EEMD-LSSVM 组合模型的预测效果优于单一的 LSSVM 模型。

## 1 EEMD 的基本原理

EEMD 是一种 EMD 的改进方法,有利于克服 EMD 的模态混叠缺陷<sup>[10-11]</sup>。EEMD 通过添加辅助噪声来消除原时间序列中的间歇现象,抑制分解结果中噪声所产生的影响<sup>[12]</sup>。EEMD 具体分解步骤如下:

(1) 在原时间序列中加入随机高斯白噪声序列  $n_m(t)$ , 得到

$$x_m(t) = x(t) + n_m(t) \quad (1)$$

式中:  $x(t)$  为原时间序列;  $x_m(t)$  为加入噪声信号后的待处理的序列。

(2) 利用 EMD, 将加有白噪声的序列分解成  $n$  个 IMF 分量  $c_{i,m}(t), i=1, 2, \dots, n$ , 以及一个剩余分量  $r_{n,m}(t)$ 。

(3) 每次加入均方根相等的不同白噪声序列, 然后重复上述两个步骤, 得到  $M$  组不同的 IMF 分量和剩余分量。

(4) 对  $M$  组 IMF 分量和剩余分量计算均值, 把最后分解后得到的各 IMF 分量及剩余分量的均值作为 EEMD 最后的分解结果, 表示为

$$c_i(t) = \sum_{m=1}^M c_{i,m}(t) / M \quad (2)$$

$$r_n(t) = \sum_{m=1}^M r_{n,m}(t) / M \quad (3)$$

## 2 贝叶斯证据框架下的 LSSVM

### 2.1 LSSVM 的基本原理

对于给定一组样本集  $D = (x_i, y_i), i=1, \dots, N$ , 其中  $x_i \in R^m$  是输入样本数据,  $y_i \in R$  是相对应的输出。通过一个非线性函数  $\varphi$  将样本数据从一个原始

特征空间映射到一个高维的特征空间, 那么线性回归函数就表示为

$$f(x) = \omega^T \varphi(x) + b \quad (4)$$

式中:  $\omega$  表示权向量;  $b$  表示偏差。根据结构风险的最小化原则, LSSVM 算法进行函数回归时的优化目标函数可以表示为

$$\begin{cases} \min_{\omega, b, e} J_1(\omega, e) = \mu E_W + \zeta E_D = \frac{1}{2} \mu \omega^T \omega + \frac{1}{2} \zeta \sum_{i=1}^N e_i^2 \\ \text{s.t.} \quad y_i = \omega^T \varphi(x_i) + b + e_i, \quad i=1, \dots, N \end{cases} \quad (5)$$

式中,

$$E_W = \frac{1}{2} \omega^T \omega$$

$$E_D = \frac{1}{2} \sum_{i=1}^N e_i^2 = \frac{1}{2} \sum_{i=1}^N (y_i - \omega^T \varphi(x_i) - b)^2$$

式中:  $e_i$  为误差变量;  $\mu$  和  $\zeta$  为可调参数。为了求解上述优化问题, 因此构建 Lagrange 函数

$$L(\omega, b, e, \alpha) = J_1(\omega, e) - \sum_{i=1}^N \alpha_i \{ \omega^T \varphi(x_i) + b + e_i - y_i \} \quad (6)$$

式中,  $\alpha_i$  为拉格朗日乘子, 根据 Karush-Kuhn-Tucker 条件得到

$$\begin{cases} \frac{\partial L}{\partial \omega} = 0 \rightarrow \omega = \sum_{i=1}^N \alpha_i \varphi(x_i) \\ \frac{\partial L}{\partial b} = 0 \rightarrow \sum_{i=1}^N \alpha_i = 0 \\ \frac{\partial L}{\partial e_i} = 0 \rightarrow \alpha_i = \gamma e_i \\ \frac{\partial L}{\partial \alpha_i} = 0 \rightarrow \omega^T \varphi(x_i) + b + e_i - y_i = 0 \end{cases} \quad (7)$$

式中,  $\gamma = \zeta / \mu$ 。消去变量  $\omega$  和  $e_i$ , 优化问题可以转化为一个线性方程

$$\begin{bmatrix} 0 & I^T \\ I & \Omega + \frac{1}{\gamma} I \end{bmatrix} \begin{bmatrix} b \\ \alpha \end{bmatrix} = \begin{bmatrix} 0 \\ Y \end{bmatrix} \quad (8)$$

式中:  $\Omega_{ij} = \varphi(x_i)^T \varphi(x_j) = K(x_i, x_j)$ ;  $I = [1, \dots, 1]^T$ ;  $\alpha = [\alpha_1, \alpha_2, \dots, \alpha_N]^T$ ;  $Y = [y_1, y_2, \dots, y_N]^T$ 。

通过式(8)可以得到  $\alpha$  和  $b$ , 则用于表示回归的 LSSVM 预测模型为

$$f(x) = \sum_{i=1}^N \alpha_i K(x, x_i) + b \quad (9)$$

满足 Mercer 条件的核函数有多种核函数, 常用的有径向基核函数、线性核函数等<sup>[7-8, 13]</sup>, 其中径向基核函数为  $K(x, x_i) = \exp\{-\|x - x_i\|^2 / 2\sigma^2\}$ ,  $\sigma$  为核函数

宽度; 线性核函数为  $K(\mathbf{x}, \mathbf{x}_i) = \mathbf{x} \cdot \mathbf{x}_i^T$ 。

## 2.2 贝叶斯证据框架

在 LSSVM 回归方法中, 贝叶斯证据框架是通过最大化参数分布的后验, 来获得最优的参数值或模型<sup>[8]</sup>。贝叶斯推理包括三个层次的推理, 第一层推理出模型参数, 第二层推理出正规化超参数, 第三层推理出核参数<sup>[8,14]</sup>。

### 2.2.1 第一层推理

给定样本数据点  $D = \{(\mathbf{x}_i, y_i)\}_{i=1}^N$ , 模型  $H$ , 给定超参数  $\mu$  和  $\zeta$ , 由贝叶斯准则得到  $\omega$  的后验概率为

$$p(\omega, b | D, \log \mu, \log \zeta, H) = \frac{p(D | \omega, b, \log \mu, \log \zeta, H) p(\omega, b | \log \mu, \log \zeta, H)}{p(D | \log \mu, \log \zeta, H)} \quad (10)$$

式中,  $p(D | \log \mu, \log \zeta, H)$  是常数。假设训练数据是独立同分布的,  $\zeta$  是高斯先验独立可分的,  $e_i$  是服从高斯分布的,  $p(\omega, b | \log \mu, \log \zeta, H)$  依赖于  $\omega$ ,  $b$ ,  $\zeta$  和  $H$ , 则第一层推理为

$$p(\omega, b | D, \log \mu, \log \zeta, H) \propto \exp\left(-\frac{\mu}{2} \omega^T \omega - \frac{\zeta}{2} \sum_{i=1}^N e_i^2\right) \quad (11)$$

式中,  $e_i = y_i - (\omega^T \varphi(\mathbf{x}) + b)$  为回归误差。由此得出, 通过最小化式(5)的负对数可得到最大后验估计值  $\omega_{mp}$  和  $b_{mp}$ 。

### 2.2.2 第二层推理

在第二层推理中, 采用贝叶斯规则可以由数据集  $D$  推理出  $\mu$  和  $\zeta$ 。

$$p(\log \mu, \log \zeta | D, H) = \frac{p(D | \log \mu, \log \zeta, H) p(\log \mu, \log \zeta | H)}{p(D | H)} \quad (12)$$

式中,  $p(D | \log \mu, \log \zeta, H)$  是常数, 由此可以得到  $p(\log \mu, \log \zeta | D, H) \propto p(\log \mu, \log \zeta | H)$ 。由于  $\mu$ ,  $\zeta$  是标量, 假设  $\log \mu$  和  $\log \zeta$  服从均匀分布, 那么  $p(\log \mu, \log \zeta | H) = p(\log \mu | H) p(\log \zeta | H)$ 。

为了得到最大后验  $\mu_{mp}$  和  $\zeta_{mp}$  的值, 需要求解式(13)的最小化问题, 即

$$\min_{\mu, \zeta} J_2(\mu, \zeta) = \mu E_W(\omega_{mp}) + \zeta E_D(\omega_{mp}, b_{mp}) + \frac{1}{2} \sum_{i=1}^{N_{eff}} \ln(\mu + \zeta \lambda_{G,i}) - \frac{N_{eff}}{2} \log \mu - \frac{N-1}{2} \log \zeta \quad (13)$$

式中,  $\lambda_{G,i}$  是  $M \Omega M$  的  $N_{eff}$  个非零特征值, 它满足

$$(M \Omega M) v_{G,i} = \lambda_{G,i} v_{G,i} \quad (14)$$

式中,  $i = 1, \dots, N_{eff}$ ,  $N_{eff} \leq N-1$ ,  $M = \left(I_N - \frac{1}{N} \mathbf{1} \mathbf{1}^T\right)$ 。

取  $\gamma = \zeta / \mu$ , 构造下列最小化问题

$$\min_{\gamma} J_3(\gamma) = \sum_{i=1}^{N-1} \log \left[ \lambda_{G,i} + \frac{1}{\gamma} \right] + (N-1) \log \left[ E_W(\omega_{mp}) + \gamma E_D(\omega_{mp}, b_{mp}) \right] \quad (15)$$

从而进一步得到  $\gamma_{mp}$  和  $\gamma_{eff}$ 。

### 2.2.3 第三层推理

得到最优参数  $\mu_{mp}$  和  $\zeta_{mp}$  后, 第三层推理就是选择一个最优的模型  $H$ 。在这个选择的过程中, 需要核函数以及由贝叶斯规则来确定相应的确定核参数。通过贝叶斯推理得到  $H$  的后验概率为

$$p(H_j | D) \propto p(D | H_j) p(H_j) \quad (16)$$

假设  $p(H_j)$  的概率是均匀分布的, 那么可得到  $p(H_j | D) \propto p(D | H_j)$ 。其他假设与第一层和第二层推理相似, 进而得到

$$p(D | H_j) \propto \left( \frac{\mu_{mp}^{N_{eff}} \zeta_{mp}^{N-1}}{(\gamma_{eff} - 1)(N - \gamma_{eff}) \prod_{i=1}^{N_{eff}} (\mu_{mp} + \zeta_{mp} \lambda_{G,i})} \right)^{1/2} \quad (17)$$

通过最大化  $p(D | H_j)$ , 可以得到最优的核函数参数。

## 3 基于 EEMD-LSSVM 的预测模型建立

由于原始时间序列具有较强的非线性、非平稳性, 直接进行建模难以取得较好的预测效果。鉴于此, 本文采用 EEMD-LSSVM 组合预测模型, 具体步骤如下:

(1) 将原始数据进行 EEMD 分解, 得到若干个 IMF 分量和一个剩余分量。

(2) 对每个 IMF 分量和剩余分量进行预处理。采用 mapminmax 函数将样本数据归一化到  $[-1, 1]$  的范围内。

(3) 确定输入输出数据。利用函数 windowize 将时间序列映射到一个空间中, 一部分作为训练数据, 另一部分作为测试数据。

(4) 根据各分量序列的特点, 建立适当预测模型, 然后利用贝叶斯推理得出最优的预测模型。

(5) 用优化好的模型进行一步回归预测, 用实

测值进行更新, 以此进行类推, 实现多步预测。

(6) 对各个 IMF 分量和剩余分量的预测结果反归一化处理, 然后进行回归拟合, 得到最终的预测结果。

EEMD-LSSVM 预测模型的结构如图 1 所示。为了验证预测模型的准确性, 利用下列预测指标对各预测模型进行对比分析<sup>[5,8]</sup>, 平均绝对百分比误差 (MAPE), 均方根误差 (RMSE), 平均误差 (AE), 最大误差 ( $e_{\max}$ )。

$$MAPE = \frac{1}{m} \sum_{i=1}^m \left| \frac{Y_i - Y'_i}{Y_i} \right| \quad (18)$$

$$RMSE = \sqrt{\frac{1}{m} \sum_{i=1}^m (Y_i - Y'_i)^2} \quad (19)$$

$$AE = \frac{1}{m} \sum_{i=1}^m (Y_i - Y'_i) \quad (20)$$

$$e_{\max} = \max \left| \frac{Y_i - Y'_i}{Y_i} \right| \quad (21)$$

式中:  $Y'_i$  和  $Y_i$  分别表示第  $i$  个预测值和实际值;  $m$  表示预测的点数。

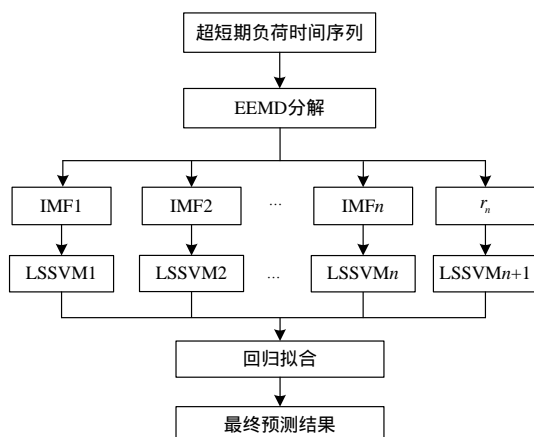


图 1 EEMD-LSSVM 预测模型的结构

Fig. 1 Structure of the EEMD-LSSVM forecasting model

#### 4 仿真研究

为了验证本文提出的组合预测模型的有效性, 现以某家庭超短期负荷数据为例进行分析。由于每日用电功率具有一定的周期性, 所以取正常运行 72 个小时的有功输出作为实验数据, 这里采样周期为 5 min, 共有 864 采样点, 所得的用电功率时间序列如图 2 所示。

从图 2 中可以看出, 时间序列具有明显的非平




图 2 超短期负荷时间序列

Fig. 2 Ultra-short-term load time series

稳性, 为了得到更好的预测效果, 首先对其进行 EEMD 分解, 得到 6 个 IMF 分量和一个剩余分量  $r_6$ , 如图 3 所示。由图可以看出, IMF1~IMF2 波动明显较大, 比较复杂。由于径向基核函数是局部核函数, 有较好的局部自适应能力, 学习能力比较强, 通过调整核参数, 就能够很好地模拟出相应的信号, 所以对于 IMF1~IMF2 选用径向基核函数。IMF3~IMF6 和剩余分量相对来说, 波动相对不是很大。由于线性核是一种全局性核函数, 有着较好的外推能力, 适用对变化比较平缓的信号进行建模, 所以对于 IMF3~IMF6 和剩余分量选用线性核函数。然后, 将各个分量预测的结果进行叠加得到最后的预测结果, 进一步得到用电功率曲线图。各个分量参数取值以及误差如表 1 所示。由表 1 可以得出, 第一个高频分量波动大, 由于其数值比较接近于 0, 因而误差相对比较大些; 其余各个分量的预测效果相对来说比较好。




图 3 超短期负荷 EEMD 分解

Fig. 3 Results of the EEMD for the ultra-short-term load

表 1 各 IMF 分量参数取值以及误差  
Table 1 Each IMF parameter values and errors

分量	$\sigma^2$	$\gamma$	RMSE	MAPE
IMF1	5.020 6	9.914 5	0.905 3	0.808 0
IMF2	3.634 3	9.914 5	0.158 1	0.199 4
IMF3	—	20.085 5	0.122 0	0.050 6
IMF4	—	30.236 3	0.016 4	0.009 6
IMF5	—	30.164 5	0.004 9	0.002 9
IMF6	—	30.126 3	0.002 3	0.014 7
$r_6$	—	30.133 0	0.062 4	0.008 2

注：“—”表示该分量没有这个参数取值。

为了验证本文所采用模型的优越性，分别采用了 LSSVM、EMD-LSSVM、EEMD-LSSVM 三种模型对超短期负荷进行预测，比较其效果。采用三种模型分别进行预测，得到的预测误差如表 2 所示，预测曲线如图 4 所示。

表 2 三种模型的预测误差对比  
Table 2 Compared errors of three forecasting models

模型名称	RMSE	MAPE	AE/kW	$e_{\max}$
LSSVM	1.538 2	0.256 3	0.775 2	1.046 5
EMD-LSSVM	0.969 0	0.182 1	-0.027 7	1.608 9
EEMD-LSSVM	0.884 7	0.162 0	-0.010 5	0.965 6

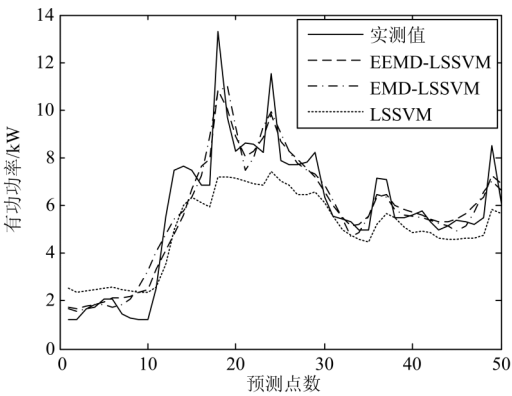


图 4 三种模型的预测结果

Fig. 4 Forecasting results for three models

由表 2 可以得出，贝叶斯优化 EEMD-LSSVM 的组合模型的平均百分比误差为 16.20%，明显要比其他两种模型的预测精度要高，这表明本文提出的方法在一定程度上能够提高超短期负荷预测的准确性，并且对一些突变点尤为明显。对误差进行分析可知，误差较大的点均是在超短期负荷功率较小的位置。最大误差百分比为 96.56%，其原因是预测第 10 个点的实际值本身比较小，处在变化的最低谷，相比而言，该点预测误差的百分比较大，但其实际误差的绝对值是较小的。从图 4 可以看出，本文提出的方法在整体上能够较好地预测负荷的变化趋

势，验证了该方法的有效性。

5 结论

(1) EEMD 可以有效地降低超短期负荷序列的非平稳特性，与 EMD 相比，EEMD 更适合对超短期负荷时间序列进行处理。

(2) 在采用 LSSVM 进行预测时，核参数和正规化参数的选取直接影响着模型预测的精度，采用贝叶斯证据方法对上述参数进行优化，可以提高预测精度。

(3) 算例结果表明 EEMD-LSSVM 组合模型可以有效地预测超短期负荷的变化，取得了比单一模型更好的预测效果。

参考文献

[1] BECCALI M, CELLURA M, LO BRANO V, et al. Short-term prediction of household electricity consumption: assessing weather sensitivity in a Mediterranean area[J]. Renewable and Sustainable Energy Reviews, 2008, 12(8): 2040-2065.

[2] 陈昌松, 段善旭, 殷进军. 基于神经网络的光伏阵列发电预测模型的设计[J]. 电工技术学报, 2009, 24(9): 153-158.

CHEN Changsong, DUAN Shanxu, YIN Jinjun. Design of photovoltaic array power forecasting model based on neural network[J]. Transactions of China Electrotechnical Society, 2009, 24(9): 153-158.

[3] 叶林, 刘鹏. 基于经验模态分解和支持向量机的短期风电功率组合预测模型[J]. 中国电机工程学报, 2011, 31(31): 102-108.

YE Lin, LIU Peng. Combined model based on EMD-SVM for short-term wind power prediction[J]. Proceedings of the CSEE, 2011, 31(31): 102-108.

[4] 王贺, 胡志坚, 张翌晖, 等. 基于 IPSO-LSSVM 的风电功率短期预研究[J]. 电力系统保护与控制, 2012, 40(24): 107-112.

WANG He, HU Zhijian, ZHANG Yihui, et al. Short-term prediction of wind power based on IPSO- LSSVM[J]. Power System Protection and Control, 2012, 40(24): 107-112.

[5] 祝志慧, 孙云莲, 季宇, 等. 基于经验模式分解和最小二乘支持向量机的短期负荷预测[J]. 继电器, 2007, 35(8): 37-40.

ZHU Zhihui, SUN Yunlian, JI Yu, et al. Short-term load forecasting based on empirical mode decomposition and least square support vector machine[J]. Relay, 2007,

- 35(8): 37-40.
- [6] 杨洪, 古世甫, 崔明东, 等. 基于遗传优化的最小二乘支持向量机风电场风速短期预测[J]. 电力系统保护与控制, 2011, 39(11): 44-48.  
YANG Hong, GU Shifu, CUI Mingdong, et al. Forecast of short-term wind speed in wind farms based on GA optimized LS-SVM[J]. Power System Protection and Control, 2011, 39(11): 44-48.
- [7] 孙斌, 姚海涛. 基于 PSO 优化 LSSVM 的短期风速预测[J]. 电力系统保护与控制, 2012, 40(5): 85-89.  
SUN Bin, YAO Haitao. The short-term wind speed forecast analysis based on the PSO-LSSVM predict model[J]. Power System Protection and Control, 2012, 40(5): 85-89.
- [8] QIAO Meiyang, LAN Jianyi, MA Xiaoping, et al. Time-series gas prediction model using LS-SVR within a Bayesian framework[J]. Mining Science and Technology, 2011, 21(1): 153-157.
- [9] 王林川, 白波, 于奉振, 等. 基于贝叶斯证据框架下 WLS-SVM 的短期负荷预测[J]. 电力系统保护与控制, 2011, 39(7): 44-49.  
WANG Linchuan, BAI Bo, YU Fengzhen, et al. Short-term load forecasting based on weighted least squares support vector machine within the Bayesian evidence framework[J]. Power System Protection and Control, 2011, 39(7): 44-49.
- [10] 茆美琴, 龚文剑, 张榴晨, 等. 基于 EEMD-SVM 方法的光伏电站短期出力预测[J]. 中国电机工程学报, 2013, 33(34): 17-24.  
MAO Meiqin, GONG Wenjian, ZHANG Liuchen, et al. Short-term photovoltaic generation forecasting based on EEMD-SVM combined method[J]. Proceedings of the CSEE, 2013, 33(34): 17-24.
- [11] 王贺, 胡志坚, 陈珍, 等. 基于集合经验模态分解和小波神经网络的短期风功率组合预测[J]. 电工技术学报, 2013, 28(9): 137-144.  
WANG He, HU Zhijian, CHEN Zhen, et al. A hybrid model for wind power forecasting based on ensemble empirical mode decomposition and wavelet neural networks[J]. Transactions of China Electrotechnical Society, 2013, 28(9): 137-144.
- [12] 张学清, 梁军. 基于 EEMD-近似熵和储备池的风电功率混沌时间序列预测模型[J]. 物理学报, 2013, 62(5): 1-10.  
ZHANG Xueqing, LIANG Jun. Chaotic time series prediction model of wind power based on ensemble empirical mode decomposition-approximate entropy and reservoir[J]. Acta Physica Sinica, 2013, 62(5): 1-10.
- [13] LI Hongze, GUO Sen, ZHAO Huiru, et al. Annual electric load forecasting by a least squares support vector machine with a fruit fly optimization algorithm[J]. Energies, 2012, 5(11): 4430-4445.
- [14] 苏莉, 陈鹏飞, 齐勇, 等. 贝叶斯证据框架下最小二乘支持向量机的软件老化检测方法[J]. 西安交通大学学报, 2013, 47(8): 12-18.  
SU Li, CHEN Pengfei, QI Yong, et al. A software aging detection method based on Bayesian framework using least squares support vector machine[J]. Journal of Xi'an Jiaotong University, 2013, 47(8): 12-18.

收稿日期：2014-03-30； 修回日期：2014-06-15

作者简介：

王 新(1967-), 男, 博士, 教授, 博士研究生导师, 主要研究方向为状态检测与故障诊断、电气传动和智能仪器仪表等; E-mail: wangxin@hpu.edu.cn

孟玲玲(1989-), 女, 硕士研究生, 主要研究方向为信号处理. E-mail: 905625796@qq.com