

基于 EEMD-样本熵和 Elman 神经网络的短期电力负荷预测

陈艳平, 毛 弋, 陈 萍, 童 伟, 袁建亮
(湖南大学电气与信息工程学院, 长沙 410082)

摘要: 针对电力负荷序列的非线性、非平稳性等特点, 提出了一种基于集总经验模式分解 EEMD-样本熵和 Elman 神经网络的短期负荷预测方法。为了减小电力负荷序列局部分析的计算规模以及提高负荷预测的精度, 先利用 EEMD-样本熵将原始电力负荷序列分解成一系列复杂度差异明显的子序列; 然后在综合考虑温度及日期类型等因素对各子序列影响的基础上, 根据各子序列的特点构造不同的 Elman 神经网络对各子序列分别进行预测; 最后将各子序列的预测结果叠加得到最终预测值, 并对 EUNITE 国际电力负荷预测竞赛公布的数据进行仿真实验。仿真结果表明该方法能有效地提高负荷预测的精度。

关键词: 短期负荷预测; 样本熵; 集总经验模式分解; Elman 神经网络

中图分类号: TM715 **文献标志码:** A **文章编号:** 1003-8930(2016)03-0059-06

DOI: 10.3969/j.issn.1003-8930.2016.03.011

Short-term Power Load Forecasting Based on Ensemble Empirical Mode Decomposition-sample Entropy and Elman Neural Network

CHEN Yanping, MAO Yi, CHEN Ping, TONG Wei, YUAN Jianliang

(College of Electrical and Information Engineering, Hunan University, Changsha 410082, China)

Abstract: According to the nonlinearity and non-stationarity of power load series, a short-term power load forecasting approach based on ensemble empirical mode decomposition (EEMD)-sample entropy and Elman neural network is proposed in the paper. In order to reduce the calculation scale of partial analysis for power load and improve the accuracy of load forecasting. Firstly, the power load time series is decomposed into a series of power load subsequences with obvious differences in complex degree by using EEMD-sample entropy. Then, on the basis of considering the influence on each subsequences of temperature and day type, different models to forecast each component separately are constructed using Elman neural network according to the features of subsequences. Finally, these forecasting results of subsequences are combined to obtain final forecasting result. The simulation example of the European network on intelligent technologies for smart adaptive system (EUNITE) power load prediction competition verifies that the combined prediction model can effectively improve the power load forecasting precision.

Key words: short-term load forecasting; sample entropy; ensemble empirical mode decomposition; Elman neural network

电力负荷预测的实质是根据预测对象的历史负荷数据建立相应的数学模型, 描述其发展规律, 是对电力市场需求的预测。做好电力负荷预测工作是实现电网经济安全运行的重要保障^[1]。

目前, 负荷预测的方法有很多。传统预测技术主要包括回归分析法、时间序列法、趋势外推法等, 这些方法大都采用显式的数学表达式来描述预测模型, 难以满足电力负荷的时变性要求; 现代预测方法主要有灰色预测法、模糊预测法、支持向量机等^[2], 其中应用较多的是静态前馈 BP (back propagation) 神经网络法, 但由于本身结构的问题, 存在如收敛速度慢、极易陷入局部极小值等缺点, 影响其应用^[3]; 同时, 由于电力负荷预测是一个样

本数据不断更新的动态过程, 利用静态前馈的 BP 网络对动态系统进行辨识, 很难得到较好的辨识效果。而 Elman 神经网络是一种典型的局部回归网络, 该模型通过在前馈网络的隐含层中增加一个承接层, 将其作为一个一步延时算子, 从而达到记忆的目的, 提高网络稳定性及处理动态信息的能力^[16-20]。

要提高负荷预测的精度, 需要在仔细分析外界因素对电力负荷影响的基础上, 准确把握负荷变化规律^[4]。电力负荷序列是具有周期性、随机性等特点的时间序列, 其实质是一种随机的非平稳时间序列。经验模式分解 EMD (empirical mode decomposition) 适合处理非线性非平稳信号^[4-7], 但有

收稿日期: 2014-06-09; 修回日期: 2015-05-11

时会出现模态混叠现象,不利于解析出序列分量的真实物理意义^[9]。EEMD法是在EMD法基础上的改进,利用高斯白噪声频率均匀分布这一统计特性,使得原始信号在加入高斯白噪声后,在不同尺度上都具有连续性,有效地解决模态混叠问题,改善信号的分析效果^[8-11]。

本文提出了一种基于EEMD-样本熵与Elman神经网络的短期负荷预测模型。利用EEMD将原始非平稳电力负荷时间序列分解成一系列具有不同特征尺度的固有模态分量IMF (intrinsic mode function),利用样本熵对各IMF分量进行复杂度分析,根据熵值大小叠加综合产生新的子序列;在综合考虑气象、日期类型等因素的基础上,建立不同的Elman递归神经网络模型,分别对各子序列进行分析,将其预测值叠加综合得到最终负荷预测值。

1 经验模态分解的基本理论

1.1 经验模式分解 EMD 原理

EMD由Huang等1998年提出,是一种对非线性非平稳信号进行平稳化处理的方法。利用EMD可将复杂信号分解成一系列IMF分量,其中包含了原信号的不同尺度波动或趋势的局部特征信息^[3-6],在一定程度上有利于解析出信号的真实物理意义,其分解原理及过程详见文献[7]。

然而,原始信号的间断性会导致EMD出现模态混叠现象,即一个IMF包含了较宽的全异尺度的信号或相近尺度的信号存在于不同的IMF分量中。这就使IMF的物理意义有所缺失,从而造成预测模型对负荷分量适应性的下降^[8-11]。

1.2 集总经验模式分解 EEMD

针对原始EMD存在的模态混叠等问题,2008年WU等创造性地提出了EEMD方法^[8]。为了解析出数据的实际信号,该方法通过利用高斯白噪声频率均匀分布的这一统计特性,使得原始信号在加入高斯白噪声后,在不同尺度上都具有连续性,有效地解决了EMD的模态混叠问题,从而改善了信号的分析效果^[8-10]。EEMD具体分解步骤^[10]如下。

(1)确定EMD要执行的次数 N ,白噪声信号的幅值系数 $k, n=1$ 。

(2)执行第 n 次EMD实验。

(3)加随机高斯白噪声序列 $l_n(t)$ 到目标数据序列 $x(t)$,得到加噪的待处理信号 $x_n(t)$;用EMD分解 $x_n(t)$,得到 I 个(IMF) $_{j,n}$,下标表示第 n 次实验分解得到的第 j 个IMF;若 $n < N$,则 $n=n+1$,重复步骤(2)。

(4)计算 N 次实验得到的每个IMF均值,即为EEMD方法分解得到的IMF。

2 样本熵

熵是衡量系统复杂度的一种定量描述工具,熵值随系统状态的变化而变化。为了降低近似熵的计算误差,Chman等于2000年首次提出了一种可以应用于时间序列复杂性度量的新方法—样本熵。样本熵是从时间序列复杂性的角度出发,度量系统产生新模式概率的大小,定量描述系统的复杂度和规则度^[13]。其熵值大小准确反映时间序列的复杂度和系统产生新模式的概率,样本熵值越大,时间序列越复杂,系统产生新模式的概率越大;反之,时间序列越简单,概率越小^[12-14]。

给定时间序列 $\{x(n)\}=\{x(1), x(2), \dots, x(N)\}$,计算样本熵^[15]步骤如下。

(1)将序列按照序号组成一组 m 维矢量, $X_m(1), \dots, X_m(N-m+1)$,其中 $X_m(i)=\{x(i), x(i+1), \dots, x(i+m-1)\}, (1 \leq i \leq N-m+1)$ 。

(2)定义向量 $X_m(i)$ 与 $X_m(j)$ 之间的距离 $d[X_m(i), X_m(j)]$ 为两者对应元素中最大差值的绝对值,即

$$d[X_m(i), X_m(j)] = \max_{k=0 \sim m-1} |x(i+k) - x(j+k)| \quad (1)$$

(3)给定阈值 r ,对每一个 i ,统计 $d[X_m(i), X_m(j)] < r$ 的数目,记作 $N_m(i)$ 。定义

$$B_m^r(i) = N_m(i) / (N - m + 1) \quad 1 \leq i \leq N - m + 1, i \neq j \quad (2)$$

(4)对所有的 $B_m^r(i)$ 求其平均值,记为 B_m^r ,则

$$B_m^r = \frac{1}{N - m + 1} \sum_{i=1}^{N-m+1} B_m^r(i) \quad (3)$$

(5)再 $m+1$,重复上述步骤(1)~(4),得到 B_{m+1}^r 。

(6)理论上此序列的样本熵为

$$\text{Samp En}(m, r) = \lim_{N \rightarrow \infty} \{-\ln(B_{m+1}^r / B_m^r)\} \quad (4)$$

当 N 为有限值时,Samp En的估计值为

$$\text{Samp En}(m, r, N) = -\ln(B_{m+1}^r / B_m^r) \quad (5)$$

由此,Samp En与 m, r 有关,但相对于近似熵具有更好的一致性,熵值的变化趋势不受 m 和 r 值的影响。一般取 $m=1$ 或 $2, r=(0.1 \sim 0.25)\text{Std}$ (Std是原始数据 $x(i) (i=1, 2, \dots, N)$ 的标准差),计算得到的样本熵统计特性更合理。本文取 $m=2, r=0.2\text{Std}$ 。

3 Elman 递归神经网络基本原理

Elman递归神经网络由Elman于1990年针对语音处理问题提出,是一种典型的局部回归网

络。除了具有输入层、隐含层和输出层外,还有一个独特的承接层。通常,输入层单元传输信号,输出层单元线性加权,隐含层单元的传递函数可以采用线性或非线函数,而承接层用来记忆隐含层前一时刻的输出值,可以认为是一个一步延时算子。该神经网络模型的特点是:隐含层的输出通过承接层的延迟和存储自联到隐含层的输入,这种自联方式使其对历史状态的数据更敏感,内部反馈网络的加入增加了网络本身处理动态信息的能力,从而达到了动态建模的目的^[16-25]。图 1 为 Elman 递归神经网络结构简图。




图 1 Elman 神经网络结构简图

Fig.1 Structure of Elman nerve network

该网络的非线性状态空间表达式^[17]为

$$y(k) = g(\omega_3 x(k)) \quad (6)$$

$$x(k) = f(\omega_1 x_c(k) + \omega_2(u(k-1))) \quad (7)$$

$$x_c(k) = x(k-1) \quad (8)$$

式中: k 为时刻; y 为 m 维输出节点向量; x 为 n 维中间层结点单元向量; u 为 r 维输入向量; x_c 为 n 维反馈状态向量; ω_3 为中间层到输出层的连接权值; ω_2 为输入层到中间层的连接权值; ω_1 为承接层到中间层的连接权值; $g(\cdots)$ 为输出神经元的传递函数, $u(\cdots)$ 为中间层输出的线性组合; $f(\cdots)$ 为中间神经单元的传递函数,常用 s 函数。

Elman 网络采用 BP 算法进行权值修正,学习指标函数采用误差平方和函数,即

$$E(\omega) = \sum_k^n [y_k(\omega) - y_k^*(\omega)]^2 \quad (9)$$

式中, $y_k^*(\omega)$ 为目标输出向量。

4 基于 EEMD-样本熵和 Elman 神经网络的负荷预测模型

4.1 负荷预测流程

实例采用 2001-08-01 欧洲智能技术网络 EUNITE (European network on intelligent technologies for smart adaptive systems) 主办的国际电力负荷预测竞赛提供的数据,东捷克斯洛伐克电力公司 (Eastern Slovakian Electricity Corporation) 1997—1998 年每日 48 点电力负荷记录,辅助数据为同期的每日平均气温和节假日信息。为更好地保证预

测模型的规模和避免网络出现过度拟合,本文选取 1998 年 1—11 月的日最大负荷数据共 334 个数据作为训练样本,1998 年 12 月的日最大负荷作为测试样本。为了便于计算,将这些数据标么化,得到训练样本时间序列,如图 2 所示。




图 2 训练样本序列

Fig.2 Sequence of training sample

由图 2 可见,电力负荷时间序列具有明显的非线性和非平稳性。为了获得更高的预测精度,利用 EEMD-样本熵对其进行分析。首先对其分解得到一系列不同尺度的 IMF 信号,如图 3 所示。

由图 3 可见,分解后的各分量表现出更强的规律性,同时其非平稳性也更加明显,造成分解后的 IMF 分量很多。若利用 Elman 神经网络直接对每一个分量进行预测,则增加了计算规模。为了更有效地对电力负荷进行预测,本文采用样本熵原理对每一个 IMF 进行复杂度分析;同时分别取 4 组不同的 m, r 值对各 IMF 分量进行样本熵值计算,得到各 IMF 的样本熵值曲线,如图 4 所示。




图 3 训练样本的 EEMD 分解

Fig.3 EEMD decomposition of training sample




图4 IMF的样本熵值

Fig.4 Sample entropy of IMF

由图4可见, m 、 r 的取值并不会影响样本熵值的总体变化趋势,各IMF分量的样本熵值随IMF分量频率的降低整体呈递减趋势,表明从高频到低频分量复杂度减小,验证了样本熵的有效性。当 $m=2$, $r=0.2Std$ 时计算得到的样本熵统计特性更合理,故本文据此样本熵值对原始数据序列进行重构。

对相邻熵值相差不大的IMF分量进行合并叠加,减少负荷预测的计算规模。对于IMF2、IMF3分量,其周期具有一定差异,但两者在负荷总量所占比例十分小,通过样本熵进行复杂性分析说明两者具有极大的相似性,故可采取同一Elman神经网络对两者的叠加分量直接预测。同理对其他IMF分量进行样本熵分析地说明相邻熵值相差不大的IMF分量具有极大的相似性,将这些具有相似性的分量叠加并用同一Elman神经网络进行预测,有利于提高负荷预测的计算效率。同时为了便于后面Elman模型输入特征的选择,将合并后的新序列与1998年同时期的温度 T 进行相关性分析,具体结果见表1,重构后的各子序列见图5。




图5 重构后的子序列F

Fig.5 Sub-sequence F after reconstructed

将新子序列 F 分别建立相应的Elman神经网络预测模型,再将各预测结果叠加并反标么化,得到电力负荷的预测值。具体预测流程见图6。

4.2 仿真实例及结果分析

通过上述分析,本文将重构后的各子序列分别对Elman网络进行训练,并选取训练快速、准确的Levenberg-Marquardt算法作为Elman网络的训练函数,建立了4个Elman神经网络模型。模型预

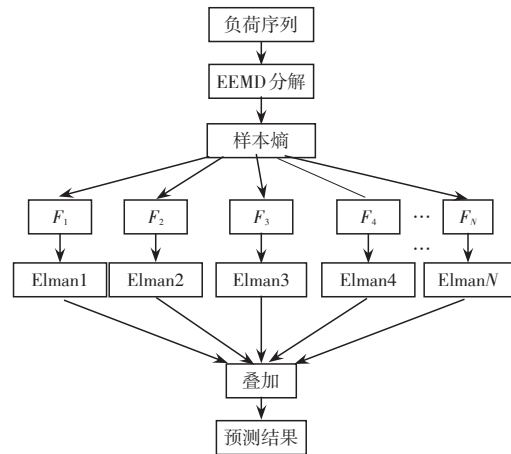


图6 基于本文方法的负荷预测流程

Fig.6 Flow chart of load forecasting based the proposed approach

测方式均使用滚动预测方式,例如,使用1998-12-25—1998-12-31的日最大负荷数据得到1999-01-01的日最大负荷数据,使用1998-12-26—1998-12-31及预测得到的1999-01-01的日最大负荷数据预测1999-01-02的日最大负荷数据。如此滚动预测,直到得到1999-01-31的日最大负荷。

根据网站公布的数据,将温度进行归一化处理,并定义日期类型:工作日为“0”,节假日为“1”。由图5可见,经EEMD-样本熵重构后的子序列具有规律性,能较好地把握负荷特征。 F_1 表现出明显的随机性,反映负荷受随机因素的影响; F_2 、 F_3 为周期分量,分别以7 d和30 d为周期变化; F_4 分量波动缓慢,且由表1的相关性分析知,这部分分量明显受气象因素影响。因此,在对这些序列建立Elman模型时,输入向量的选择各不相同,各Elman神经网络模型输入特征见表2。

表1 新序列F及F与T的相关系数

Tab.1 New sequence F and the correlation coefficients of F and T

新序列号	原IMF分量序列号	与T的相关系数R
F_1	1	-0.036 8
F_2	2,3	-0.057 0
F_3	4,5	-0.109 7
F_4	6,7,8	-0.897 6

表2 各Elman神经网络模型输入因子

Tab.2 Input factors of each Elman nerve network

子序列	输入因子的选择	总数
F_1, F_2, F_3	预测日的日期类型 W_i 、预测前7 d的日期类型 $W_{i-1} \cdots W_{i-7}$ 、预测日前7 d的日最大负荷 $L_{i-1} \cdots L_{i-7}$	15
F_4	预测日的日期类型 W_i 、预测前7 d的日期类型 $W_{i-1} \cdots W_{i-7}$ 、预测日前7 d的日最大负荷 $L_{i-1} \cdots L_{i-7}$ 、预测日的平均温度 T_i 、预测日前7 d的日平均温度 $T_{i-1} \cdots T_{i-7}$	23

将以上经过处理的数据输入由子序列训练后的 Elman 神经网络,得到相应的预测值,再将各分量的预测值相叠加就可以得到最终的预测结果,如图 7 所示。由图 7 可以看出,预测值与实际值具有相同的变化趋势,预测值能较好地反映实际负荷的周期性和变化情况。




图 7 本文预测结果

Fig.7 Forecasting results

运用 Elman 神经网络和 EEMD-Elman 两种预测模型进行预测,预测的精度以平均绝对百分误差 MAPE(mean absolute percentage error)为主要评价指标、以最大误差 ME(maximum error)为参考评价指标,预测结果误差分析见表 3。由表 3 可知,本文方法的 ME 略高于 EEMD-Elman 方法,可能是因为用 Elman 神经网络对重构后的分量进行预测时,造成了一定的累积误差;但本文方法的 MAPE 最小,总体预测效果更好。这是因为利用 EEMD-样本熵将原始非平稳电力负荷序列分解成一系列复杂度差异明显的子序列,和原始序列相比,这些子序列的局部负荷特性更为明显,更有利于预测;其次利用具有动态反馈的 Elman 神经网络对各个子序列分别进行预测,更有利于提高预测的精度。

表 3 预测误差比较

Tab.3 Forecasting errors comparison

预测方法	MAPE/%	ME/MW
本文方法	1.89	41.51
EEMD-Elman	2.08	39.42
Elman	3.12	45.67

5 结语

本文提出了一种基于 EEMD-样本熵和 Elman 神经网络的短期负荷组合预测方法。首先,针对 EMD 分解的模态混叠问题会引起负荷分解的不准确性,利用 EEMD 对原始电力负荷进行多尺度分解,得到的各 IMF 分量更能准确地反映原始负荷的局部特征;由于分解得到的 IMF 分量较多,需要利用样本熵对各个 IMF 分量进行复杂度分析,根据熵值将各个 IMF 分量重构得到一组新的子序列,这样减少了预测模型的计算规模;然后,针对

各个子序列的变化规律,利用具有局部动态反馈的 Elman 神经网络分别对各子序列进行预测,使得预测结果有更高的精度;最后叠加得到最终的预测值。仿真结果表明,本文方法具有更好的预测精度,是一种行之有效的预测模型。

参考文献:

- [1] 康重庆,夏清,刘梅. 电力系统负荷预测[M]. 北京:中国电力出版社,2007.
- [2] 于海燕,张凤玲(Yu Haiyan,Zhang Fengling). 基于模糊神经网络的电力负荷短期预测(Short-term load forecasting based on fuzzy neural network)[J]. 电网技术(Power System Technology),2007,31(3):68-72.
- [3] 祝志慧,孙云莲,季宇(Zhu Zhihui,Sun Yunlian,ji Yu). 基于经验模式分解和最小二乘支持向量机的短期负荷预测(Short-term load forecasting based on empirical mode decomposition and least square support vector machine)[J]. 继电器(Relay),2007,35(8):37-40.
- [4] 段其昌,饶志波,黄大伟,等(Duan Qichang,Rao Zhibo,Huang Dawei,et al). 基于 EMD 和 PSO-SVM 的电力系统中期负荷预测(Power system middle-term load forecasting based on EMD and SVM with PSO)[J]. 控制工程(Control Engineering of China),2012,19(5):913-917.
- [5] 牛东晓,李媛媛,乞建勋,等(Niu Dongxiao,Li Yuanyuan,Qi Jianxun,et al). 基于经验模式与因素影响的负荷分析方法(A novel approach for load analysis based on empirical mode decomposition and influencing factors)[J]. 中国电机工程学报(Proceedings of the CSEE),2008,28(16):96-102.
- [6] Huang N E,Shen Z,Long S R. The empirical mode decomposition and the Hilbert spectrum for nonlinear and non-stationary time series analysis[J]. Proceedings A of the Royal Society,1998,454(1997):903-995.
- [7] 郑连清,郑艳秋(Zheng Lianqing,Zheng Yanqiu). 基于经验模式分解与人工神经网络的短期电力负荷预测(Short-term power load forecasting based on empirical mode decomposition and ANN)[J]. 电力系统保护与控制(Power System Protection and Control),2009,37(23):66-69,74.
- [8] Wu Zhaohua,Norden E Huang. Ensemble empirical mode decomposition: a noise assisted data analysis method[J]. Advances in Adaptive Data Analysis,2008,1(1):1-41.
- [9] 朱祥和,王子琦,李严,等(Zhu Xianghe,Wang Ziqi,Li Yan,et al). 基于 EEMD 的 LS-SVM 和 BP 神经网络混合短期负荷预测(A hybrid short-term load forecasting method combined with LS-SVM and BP neural network)

- based on EEMD)[J]. 数学的实践与认识(Mathematics in Practice and Theory), 2012, 42(8): 151-158.
- [10] 田海雷, 李洪儒, 许葆华(Tian Hailei, Li Hongru, Xu Baohua). 基于集总经验模式分解和支持向量机的液压泵故障预测研究(Fault prediction for hydraulic pump based on EEMD and SVM)[J]. 中国机械工程(China Mechanical Engineering), 2013, 24(7): 926-931.
- [11] 张学清, 梁军(Zhang Xueqing, Liang Jun). 基于EEMD-近似熵和储备池的风电功率混沌时间序列预测模型(Chaotic time series prediction model of wind power based on ensemble empirical mode decomposition-approximate entropy and reservoir)[J]. 物理学报(Acta Physica Sinica), 2013, 62(5): 1-10.
- [12] Pincus S M. Approximate entropy as a measure of system complexity[J]. Proceeding of the National Academy Sciences, 1991, 88(6): 2297-2301.
- [13] Richman J S, Moorman J R. Physiological time-series analysis using approximate entropy and sample entropy[J]. American Journal of Physiology: Heart and Circulatory Physiology, 2000, 278(6): 2039-2049.
- [14] 刘慧, 和卫星, 陈晓平(Liu Hui, He Weixing, Chen Xiaoping). 生物时间序列的近似熵和样本熵方法比较(Approximate entropy and sample entropy for physiological time-series)[J]. 仪器仪表学报(Chinese Journal of Scientific Instrument), 2004, 25(4): 806-807, 812.
- [15] 来凌红, 吴虎胜, 吕建新, 等(Lai Linghong, Wu Husheng, Lü Jianxin, et al). 基于EMD和样本熵的滚动轴承故障SVM识别(SVM recognition method based on EMD and sample entropy in rolling bearing fault diagnosis)[J]. 煤矿机械(Coal Mine Machinery), 2011, 32(1): 249-252.
- [16] 石黄霞, 何颖, 董晓红(Shi Huangxia, He Ying, Dong Xiaohong). 基于Elman神经网络的电力负荷预测模型研究(Research of power load forecasting based on Elman neural network)[J]. 工业仪表与自动化装置(Industrial Instrumentation & Automation), 2013(1): 85-87.
- [17] 杨晓艳, 李飞, 白艳萍(Yang Xiaoyan, Li Fei, Bai Yanping). Elman递归神经网络在车牌字符识别中的应用(Application of Elman recursive neural network to recognition of vehicle license plate)[J]. 中北大学学报: 自然科学版(Journal of North University of China: Natural Science Edition), 2012, 33(5): 603-607.
- [18] 张靠社, 杨剑(Zhang Kaoshe, Yang Jian). 基于Elman0神经网络的短期风电功率预测(Short-term wind power forecasting based on the Elman neural network)[J]. 电网与清洁能源(Power System and Clean Energy), 2012, 28(12): 87-91.
- [19] 张健美, 周步祥, 林楠, 等(Zhang Jianmei, Zhou Buxiang, Lin Nan, et al). 灰色Elman神经网络的电网中长期负荷预测(Prediction of mid-long term load based on gray Elman neural networks)[J]. 电力系统及其自动化学报(Proceedings of the CSU-EPSA), 2013, 25(4): 145-149.
- [20] 周云龙, 王强, 孙斌, 等(Zhou Yunlong, Wang Qiang, Sun Bin, et al). 基于希尔伯特-黄变换与Elman神经网络的气液两相流流型识别方法(Applied study of Hilbert-Huang transform and Elman neural network on flow regime identification for gas-liquid two-phase flow)[J]. 中国电机工程学报(Proceedings of the CSEE), 2007, 27(11): 50-56.
- [21] 王新, 孟玲玲(Wang Xin, Meng Lingling). 基于EEMD-LSSVM的超短期负荷预测(Ultra-short-term load forecasting based on EEMD-LSSVM)[J]. 电力系统保护与控制(Power System Protection and Control), 2015, 43(1): 61-66.
- [22] 张成, 滕欢, 付婷(Zhang Cheng, Teng Huan, Fu Ting). 基于灰色离散Verhulst模型理论的电力中长期负荷预测研究(Middle and long term power load forecasting based on grey discrete Verhulst model's theory)[J]. 电力系统保护与控制(Power System Protection and Control), 2013, 41(4): 45-49.
- [23] 陈强, 金小明, 姚建刚, 等(Chen Qiang, Jin Xiaoming, Yao Jiangang, et al). 基于改进ABC算法的中长期电力负荷组合预测(Improved artificial bee colony algorithm applied to medium and long-term load combination forecasting)[J]. 电力系统保护与控制(Power System Protection and Control), 2014, 42(23): 113-117.
- [24] 陈超, 黄国勇, 范玉刚, 等(Chen Chao, Huang Guoyong, Fan Yugang, et al). 基于离散Fréchet距离和LS-SVM的短期负荷预测(Short-term load forecasting based on discrete Fréchet distance and LS-SVM)[J]. 电力系统保护与控制(Power System Protection and Control), 2014, 42(5): 142-147.
- [25] 张伟(Zhang Wei). 基于人体舒适度指数的配电网短期负荷预测方法(A distribution short-term load forecasting based on human comfort index)[J]. 电力系统保护与控制(Power System Protection and Control), 2013, 41(9): 74-79.

作者简介:

陈艳平(1989—), 女, 硕士研究生, 研究方向为电力负荷预测、电力市场。Email: cyp344608782@qq.com

毛弋(1965—), 男, 硕士, 副教授, 研究方向为电力系统规划、电力市场、电能质量等。Email: maoyidu@aliyun.com

陈萍(1987—), 女, 硕士研究生, 研究方向为配电网规划、配电网重构。Email: 410070487@qq.com