

基于核函数极限学习机的微电网 短期负荷预测方法

刘 念¹ 张清鑫¹ 刘海涛²

(1. 华北电力大学电气与电子工程学院 北京 102206 2. 中国电力科学研究院 北京 100192)

摘要 针对以单个或集体用户为业主的用户侧小容量微电网,考虑到成本约束及用电特征的不确定性,提出了一种基于核函数极限学习机的微电网短期负荷预测方法。使用核函数极限学习机、启发式遗传算法和分时训练样本,建立了包含离线参数寻优与在线负荷预测的预测模型;通过模型参数的周期更新来保证算法最优参数的时效性,同时降低在线预测系统的计算复杂度与历史数据存储量。通过对不同容量、类型的用户侧微电网进行短期负荷预测,分析了预测结果的准确度、参数周期更新的效果、预测结果对经济运行的影响和预测方法的计算效率。

关键词: 微电网 短期负荷预测 极限学习机 周期更新

中图分类号: TM715

Online Short-Term Load Forecasting Based on ELM with Kernel Algorithm in Micro-Grid Environment

Liu Nian¹ Zhang Qingxin¹ Liu Haitao²

(1. School of Electrical and Electronic Engineering North China Electric Power University
Beijing 102206 China

2. China Electric Power Research Institute Beijing 100192 China)

Abstract Considering the cost constraints and various electrical characteristics of the small capacity user-side micro-grid constituted by single or group users, a short-term load forecasting method based on extreme learning machine with kernel(ELM_k) algorithm is proposed. The ELM_k, heuristic genetic algorithm and time division training samples are used to establish a short-term load forecasting model, including offline parameter optimization and online load forecasting. The cycle update of model parameters guarantees the timeliness of the optimum parameters, and reduces the computational complexity and storage space of the online forecasting system. The load forecasting of user-side micro-grids with different capacities and types is processed, and the load forecasting accuracy, the model performance after cycle update, the micro-grid operation costs under load forecasting result and the calculation efficiency of this method are analyzed.

Keywords: Micro-grid, short-term load forecasting, extreme learning machine, cycle update

1 引言

微电网能促进分布式清洁能源接入,减少环境

污染并降低电能传输损耗,通过孤/并网模式切换提高用户的供电可靠性^[1]。短期负荷预测是微电网能量管理系统的重要组成部分,是对微燃气轮机、柴油机及储能等可控微源进行优化调度的基础^[2],预测结果将直接影响微电网运行策略^[3]与电能交易。相关研究表明,较高的微电网负荷预测误差将导致运行成本大幅增加^[4]。

国家自然科学基金资助项目(51277067),中央高校基本科研业务费专项基金项目(12MS32),国家电网公司科技项目(微电网应用模式与协调控制技术研究开发及应用)。

收稿日期 2013-04-11 改稿日期 2013-07-07

相对于大电网环境,微电网进行短期负荷预测的难度更高,这主要是由于负荷的随机性强,历史负荷曲线相似度低,再加上用户容量有限,各用户间负荷特征相互平滑作用较小,负荷总体波动较大^[5]。对于微电网短期负荷预测,文献[5]采用两层结构进行微电网负荷预测,但所选微电网容量很大,其最小负荷约 10MW,已相当于中压配电线路的负荷水平;由于预测方法包含特征优选、参数寻优等大量辅助步骤,在高性能计算机上的单次计算时间仍超过 40min,仅能用于日前负荷预测。文献[6]采用 BP 神经网络进行微电网分布式电源与负荷的短期功率预测,但由于算法的预测准确度较低,仅能在微电网高负荷时期利用负荷预测结果提高其供电可靠性。文献[7]采用遗传算法与 RBF 神经网络实现微电网负荷预测,进而实现微电网剩余功率预测,可是所选微电网负荷容量较大,其平均功率约 6.5MW,且负荷预测准确度有待提高。

当前针对微电网短期负荷预测的研究成果相对有限,且计算复杂度较高。针对以单个或集体用户为业主的小容量微电网,除保证较高的短期负荷预测准确度外,还应降低负荷预测方法的计算复杂度,便于在嵌入式终端装置上实现^[8-9]。

基于上述原因,本文在分析微电网负荷预测特点的基础上,采用核函数极限学习机算法,建立包含离线参数寻优与在线负荷预测的微电网短期负荷预测模型,并通过多种类型、容量的微电网实例验证预测准确度、周期更新稳定性与计算效率。

2 核函数极限学习机

极限学习机理论由 Huang 等人于 2006 年提出^[10],基于该理论已衍生出基本极限学习机、在线序贯极限学习机与核函数极限学习机(Extreme Learning Machine with kernel, ELM_k)等相关算法^[11]。ELM_k 是一种单层前馈神经网络算法,相对于基本 ELM 算法,其解决回归预测问题的能力更强,而相对于支持向量机算法,其在获得更好或相似的预测准确度时,计算速度更快^[12]。基本 ELM 算法已被应用于短期负荷预测^[13-14]与非技术性损失检测^[15],并展现出较高的性能。

本文选择 ELM_k 作为负荷预测算法。首先简单说明基本 ELM 算法的神经网络构建机制,其神经网络函数可表示为

$$f(x) = \mathbf{h}(x)\beta \quad (1)$$

ELM 通过最小化输出误差保证回归预测准确度,即

$$\lim_{L \rightarrow \infty} \|f(x) - f_0(x)\| = \lim_{L \rightarrow \infty} \left\| \sum_{i=1}^L \beta_i h_i(x) - f_0(x) \right\| = 0 \quad (2)$$

式中, L 为隐藏层神经元 $h(x)$ 的个数; $f_0(x)$ 为目标值构成的待预测函数。

同时 ELM 算法通过最小化输出权重 β 保证神经网络的泛化能力。通常 β 取其最小二乘解,计算方法为

$$\beta = \mathbf{H}^\dagger \mathbf{O} = \mathbf{H}^T (\mathbf{H}\mathbf{H}^T)^{-1} \mathbf{O} = \mathbf{H}^T \left(\frac{1}{C} + \mathbf{H}\mathbf{H}^T \right)^{-1} \mathbf{O} \quad (3)$$

式中, \mathbf{H} 为神经网络隐藏层矩阵; \mathbf{H}^\dagger 为 \mathbf{H} 矩阵的广义逆矩阵^[16]; \mathbf{O} 为预测目标值向量。根据岭回归理论,通过增加正常数 $1/C$,求解结果将更加稳定并具有更好的泛化能力^[17]。

对于 ELM_k 算法,其通过引入核函数来获得更好的回归预测准确度,即

$$\begin{aligned} f(x) &= \mathbf{h}(x)\mathbf{H}^T \left(\frac{1}{C} + \mathbf{H}\mathbf{H}^T \right)^{-1} \mathbf{O} \\ &= \begin{pmatrix} K(x, x_1) \\ \vdots \\ K(x, x_N) \end{pmatrix}^T \left(\frac{1}{C} + \boldsymbol{\Omega}_{\text{ELM}} \right)^{-1} \mathbf{O} \quad (4) \\ \boldsymbol{\Omega}_{\text{ELM}(i,j)} &= \exp(-\gamma \|x_i - x_j\|^2) \end{aligned}$$

式中, $\boldsymbol{\Omega}_{\text{ELM}}$ 为所选核函数,通常取高斯核函数; N 为输入层维数。

通过引入高斯核函数,隐藏层矩阵由原来的 $N \times L$ 维转化为 $N \times N$ 维,同时 L 成为核函数转化后的高维空间的维数。对于 ELM_k,虽然 L 参数无需人为设置,但核函数中的参数 γ 与广义逆矩阵中的参数 C 由于影响回归预测性能,仍需优化求解。

由于篇幅有限,仅简单说明 ELM_k 算法的基本原理,相关定理与理论证明可参考文献[11-12]。

3 微电网负荷预测模型

3.1 微电网负荷预测需求与模型构建

相对于大电网运行条件,微电网短期负荷预测具有以下特点:微电网中不一定能够配备高性能服务器进行负荷预测,并不适宜在每次负荷预测时都进行参数寻优;各时段用电特性差异较大,为提高负荷预测准确度,需要分时构建负荷预测模型;

在线负荷预测可能由嵌入式系统完成,预测模型在计算复杂度与存储空间方面都有较大限制。

考虑上述微电网负荷预测特点,本文基于分时训练样本,选择 ELM_k 与遗传算法 (Genetic Algorithm, GA) 相结合的方式,构建包含离线参数寻优与在线负荷预测的微电网短期负荷预测模型,如图 1 所示。

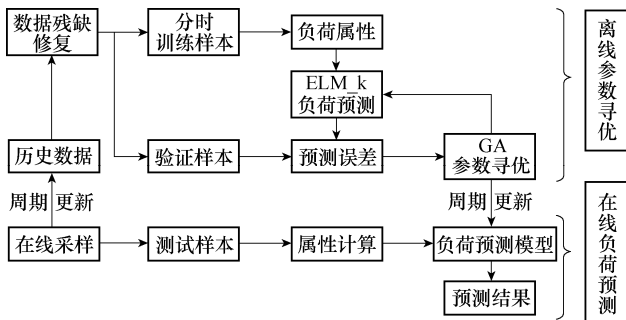


图 1 微电网短期负荷预测模型

Fig.1 Micro-grid short-term load forecasting model

3.2 数据残缺修复

微电网负荷的历史数据可能存在以下问题：

(1) 负荷采样数据存在残缺,即缺少某一时刻的历史样本,或该时刻的功率采样值为空。

(2) 负荷历史采样数据中存在停电类特殊事件,其特征表现为超过 2h 的负荷采样值连续为 0,不属于短期负荷预测的应用范畴。

(3) 历史采样数据中包含特殊节假日的负荷采样数据,尤其是特殊节假日所导致的调休,对工作日与节假日的负荷特征都有影响。由于本文不以特殊节假日短期负荷预测作为重点,将对原始负荷采样数据中的调休日负荷进行处理。

对于历史数据中存在的问题,实验采用周同期负荷数据的平均值进行填充或覆盖,其计算方法为

$$x_i = \frac{x_{i-W} + x_{i+W}}{2} \quad W = 7 \times 24 \quad (5)$$

式中, x_i 为第 i 个负荷功率采样值; W 为一周的理论采样样本数。

3.3 负荷属性

对于第 i 个负荷采样值 x_i , 研究中使用采样时间 t_i 、周信息 w_i 、日前平均负荷 da_i 、日前滞后负荷 dl_i 、周前滞后负荷 wl_i 作为其负荷属性。负荷数据的采样时间间隔为 1h, 采样时间 t_i 为 1~24 的整数; 对于周信息 w_i , 取值为 1~7 的整数; 对于日前平均负荷 da_i , 计算方法为

$$da_i = \frac{1}{24} \sum_{k=1}^{24} x_{i-k} \quad i = 25, \dots, G \quad (6)$$

式中, G 为负荷样本采样总数。

对于日前滞后负荷与周前滞后负荷, 计算方法如下

$$\begin{cases} dl_i = x_{i-24} & i = 25, \dots, G \\ wl_i = x_{i-168} & i = 169, \dots, G \end{cases} \quad (7)$$

为便于表述, 使用 A_i 指代第 i 个样本的所有负荷属性, 即

$$A_i = \{t_i, w_i, da_i, dl_i, wl_i\} \quad (8)$$

3.4 离线模型构建与参数寻优

由于工作日与节假日的负荷特征差别较大, 针对二者分别建立短期负荷预测模型。对于验证样本的选择, 设当前进行 T 时刻负荷预测模型的参数寻优, 则对应的验证样本为

$$V_T = \{x_i | A_i\}; t_i = T \quad (9)$$

式中, V_T 为 T 时刻预测模型的验证样本; x_i 为负荷预测的目标值; A_i 为样本的负荷属性值。

对应选择 T 时刻的前驱样本、日同期区间样本、周同期区间样本作为 T 时刻负荷预测模型的分时训练样本, 即

$$M_T = \{x_i | A_i\}; t_i = \{T-1, T-2, T-22, \dots, T-26, T-166, \dots, T-170\} \quad (10)$$

式中, M_T 为 T 时刻预测模型的训练样本。

基于 ELM_k 算法, 使用样本 M_T 与参数 C_T^g 和 γ_T^g 建立负荷预测模型 F_T^g 。再使用样本 V_T 的负荷属性进行预测验证, 即

$$\begin{cases} F_T^g = ELM_k(C_T^g, \gamma_T^g, M_T) \\ \hat{x}_i^g = F_T^g(A_i) \quad A_i \in V_T \end{cases} \quad (11)$$

式中, F_T^g 为 T 时刻的负荷预测模型; C_T^g 、 γ_T^g 为 ELM_k 算法的参数取值; g 为预测模型训练代数, 与遗传算法优化代数相对应; \hat{x}_i^g 为验证样本的负荷预测值。

遗传算法的目标函数为预测误差最小, 采用平均相对误差 (Mean Absolute Percent Error, MAPE) 作为预测模型构建时的评价函数, 即

$$MAPE^g = \frac{100\%}{S} \sum_{i=1}^S \left(\left| \frac{x_i - \hat{x}_i^g}{x_i} \right| \right) \quad (12)$$

式中, S 为预测时间总长度。

基于种群各代的负荷预测误差及对应参数, 使用 GA 进行参数寻优, 即

$$(C_T^{g+1}, \gamma_T^{g+1}) = \text{GA}(\text{MAPE}^g, C_T^g, \gamma_T^g) \quad (13)$$

遗传算法的优选参数为 Z_1 与 Z_2 , 并与 ELM_k 的算法参数相对应, 且满足式 (14)。文献[12]在进行 ELM_k 算法性能分析时, Z_1 与 Z_2 取 $[-24, 25]$ 内的整数, 本文类似选取 $[-10, 25]$ 内的浮点数, 即

$$C = 2^{Z_1}; \quad \gamma = 2^{Z_2}; \quad Z_1, Z_2 \in [-10, 25] \quad (14)$$

对于参数 Z_1 与 Z_2 的优选, 使用启发式交叉函数, 即以预测准确度较好的父代为基础, 依据比例系数向较差父代移动一段距离作为交叉形成的子代, 即

$$P_1^{g+1} = P_1^g + R(P_1^g - P_2^g) \quad (15)$$

式中, R 为比例系数, 取值为 1.2; P_1^g 、 P_2^g 为父代参数值, 其中 P_1^g 为预测准确度较好的父代, g 为遗传算法代数。

使用自适应变异函数, 基于父代的预测准确度, 并考虑待优选参数取值区间, 将子代的参数值加上一个随机值, 从而完成子代的变异操作。遗传算法种群个数为 20, 当连续 50 代的预测准确度变化小于 1% 时终止参数寻优过程。

离线参数寻优模块的运行周期为 1 周, 其中历史数据存储量可取 1~2 个月, 并每周进行更新, 基于更新后的历史数据进行启发式参数寻优, 获得各预测时刻的最优参数 C_T 与 γ_T ($T=1, \dots, 24$)。将该最优参数传递给在线负荷预测模型, 作为其下一个运行周期的预测算法训练参数。

3.5 在线负荷预测模型

进行在线负荷预测时, 设待预测时刻为 T^0 , 当前运行时刻为 T^0-1 , 基于当前时刻的采样和历史采样构建在线训练样本为

$$M_{T^0} = \{x_i | A_i\}; \quad t_i = \{T^0-1, T^0-2, T^0-22, \dots, T^0-26, T^0-166, \dots, T^0-170\} \quad (16)$$

使用训练样本 M_{T^0} , 最优参数 C_T 与 γ_T 构建预测模型为

$$F_{T^0} = \text{ELM_k}(C_T, \gamma_T, M_{T^0}); \quad T = T^0 \quad (17)$$

基于预测模型 F_{T^0} 与 T^0 时刻的负荷属性集, 实现 T^0 时刻的负荷预测, 即

$$\hat{x}_{T^0} = F_{T^0}(A_i); \quad t_i = T^0 \quad (18)$$

在线负荷预测模型运行时, 按式 (16) 不断更新在线训练样本, 并按式 (17) 式 (18) 进行短期负荷预测, 而最优参数 C_T 与 γ_T 则按周更新, 从而保证最优参数的时效性与在线模型的运行效率。该预测模型能直接进行 T^0 时刻的负荷预测, 若要同时进行 T^0+1 时刻的负荷预测, 可用 T^0 时刻的预测结果更新在线训练样本后进行计算。

4 实验与结果分析

4.1 微电网负荷样本

对于微电网短期负荷预测, 实验选择四个不同容量微电网的 5~7 月历史负荷作为原始采样数据, 其中: 微电网 D1 与 D2 主要为小区物业负荷, 微电网 R1 与 R2 主要为酒店负荷。样本采样时间间隔为 1h, 原始采样属性包含采样时间和负荷功率, 并根据式 (6) 式 (7) 添加日前平均负荷等属性。

构建预测模型前, 将对功率采样值 x_i 及负荷属性 A_i 进行归一化处理, 缩放至 $[0, 1]$ 的范围。以功率采样值为例, 其计算方法为

$$y_i = \frac{x_i - \min(x)}{\max(x) - \min(x)} \quad (19)$$

使用 5、6 月的历史数据作为分时训练样本与验证样本, 基于 ELM_k 与 GA 进行负荷预测模型的参数寻优。首先选择 7 月第 1 周的负荷数据作为测试样本, 测试短期负荷预测模型的预测准确度。测试周的 25~72h 为节假日, 其他时间为工作日。

4.2 微电网负荷预测准确度

对于负荷预测准确度的评价, 本文选择 MAPE, 最大误差 (Maximum Error, ME) 和均方误差 (Mean Square Error, MSE) 作为评价标准, 其计算方法为

$$ME_i = \max |x_i(p) - \hat{x}_i(p)|; \quad p = 1, \dots, 10 \quad (20)$$

$$MSE = \frac{1}{S} \sum_{i=1}^S [y_i - \hat{y}_i]^2 \quad (21)$$

式中, ME_i 为 i 时刻 p 次负荷预测的最大误差; \hat{y}_i 为神经网络输出的预测值; y_i 为预测目标值。7 月第 1 周中各微电网的负荷预测误差如表 1 所示, 各时刻最大误差如图 2~图 5 所示。

表 1 微电网负荷预测误差

Tab.1 Prediction error of micro-grid load

微网	平均负荷/kW	MAPE (%)	MSE ($\times 10^{-2}$)
D1	140.85	10.03	7.62
D2	261.96	10.9	5.99
R1	1 106.43	13.61	8.13
R2	1 315.61	7.69	4.6

4.3 负荷预测结果分析

为详细分析负荷特征与预测准确度之间的关系,各微电网的负荷预测结果如图 2~图 5 所示。




图 2 微电网 D1 的负荷预测结果

Fig.2 Load forecasting results of micro-grid D1




图 3 微电网 D2 的负荷预测结果

Fig.3 Load forecasting results of micro-grid D2




图 4 微电网 R1 负荷预测结果

Fig.4 Load forecasting results of micro-grid R1




图 5 微电网 R2 的负荷预测结果

Fig.5 Load forecasting results of micro-grid R2

分析各微电网的负荷预测结果发现:

(1) 各微电网在 25~72h 之间(点划线之间的区域)的节假日时段都出现了较大的负荷预测误差,这主要是因为节假日的负荷特征变化较大,用电习惯容易出现突变。

(2) 微电网的负荷上升沿与下降沿由于功率变化迅速,也容易出现一定的预测误差,其中以微电网 R1 最为典型,尤其在 31h 处的负荷上升沿出现了该预测周最大的预测误差。

(3) 微电网低负荷时段对预测误差的影响。虽然微电网 D2 的 MSE 误差小于微电网 D1,但由于 D2 的预测误差很多出现在低谷时段,且最小负荷仅有 116.4kW,导致微电网 D2 的 MAPE 误差反而较大。

(4) 对于微电网 D1 与 R1,其负荷曲线的日前相似度较低,也容易引起较大的负荷预测误差。

4.4 离线参数寻优的结果形式及参数取值

各微电网负荷预测系统每周都有两个 ELM_k 算法参数集对应其工作日与节假日;每个参数集都包含 24 组算法参数值,对应一天 24h。以微电网 R2 在 7 月第 1 周的节假日为例,其最优参数取值如图 6 所示。




图 6 微电网 R2 在 7 月第 1 周节假日的最优参数
Fig.6 Optimum parameters of micro-grid R2
in July first week holidays

4.5 模型周期更新准确度及经济性分析

相关研究成果通常只分析特定周的负荷预测性能^[5-7],并未能分析预测方法在连续多个测试周中的性能稳定性。为研究在线负荷预测模型周期更新后性能的稳定性,基于 3.4 节相关理论进行模型参数的周期更新,并连续进行 7 月第 2~4 周的负荷预测,各测试周的预测误差如表 2 所示。

表 2 负荷预测模型周期更新后的预测误差

Tab.2 Prediction error after cycle update of the load forecasting model

微网	第 2 周		第 3 周		第 4 周	
	MAPE (%)	MSE ($\times 10^{-2}$)	MAPE (%)	MSE ($\times 10^{-2}$)	MAPE (%)	MSE ($\times 10^{-2}$)
D1	8.22	5.69	9.77	9.99	9.23	6.14
D2	8.27	4.1	7.76	4.17	7.31	4.55
R1	10.96	3.42	9.26	5.39	6.77	4.54
R2	5.82	3.65	5.3	3.98	5.78	4.89

分析表 2 可知,负荷预测模型在周期更新后仍能保持原有负荷预测准确度。基于文献[4]的相关研究,当置信水平为 0.99 时,微电网短期负荷预测相对误差与运行成本的关系如图 7 所示,图中基准成本为预测误差为 0 时的运行成本。




图 7 微电网运行成本与预测相对误差的关系

Fig.7 Operation costs under different prediction errors

图 7 中,当预测相对误差大于 10%后,微电网的运行成本将会大幅增加。在 7 月各测试周中,大部分测试周的负荷预测误差都小于或接近 10%,仅微电网 R1 在第 1 周的预测误差较大。

4.6 性能分析

实验机器采用 Core i3 380M 处理器与 4G 内存,并在 Matlab 2012a 环境下完成相关计算。以 7 月第 1 周负荷预测为例,各微电网的单次参数寻优与单次负荷预测的计算时间如表 3 所示。

表 3 单次参数寻优与单次负荷预测的计算时间

Tab.3 Calculation time of single parameter optimization and single load forecasting

微网	单次参数寻优时间/s	单次负荷预测时间/ms
D1	507.64	0.508±0.26
D2	539.07	0.530±0.12
R1	527.96	0.565±0.34
R2	514.6	0.558±0.16

分析表 3 发现,该微电网短期负荷预测方法在参数寻优与负荷预测两个方面均具有较高的效率,10min 内可完成微电网一个运行周期的参数寻优,且单次负荷预测时间小于 1ms。

5 结论

本文基于核函数极限学习机,提出了包含离线参数寻优与在线负荷预测的微电网短期负荷预测方法,通过算例测试分析,可得到如下结论: 对多种类型、容量的微电网,该方法能够获得较高的预测准确度; 通过连续多周的微电网负荷预测,验证了预测方法在周期更新后的性能稳定性; 该预测方法具有较高的计算效率,便于在嵌入式终端装置上实现。

参考文献

- [1] 鲁宗相,王彩霞,闵勇,等. 微电网研究综述[J]. 电力系统自动化, 2007, 31(19): 100-107.
Lu Zongxiang, Wang Caixia, Min Yong, et al. Overview on microgrid research[J]. Automation of Electric Power Systems, 2007, 31(19): 100-107.
- [2] 陈益哲,张步涵,王江虹,等. 基于短期负荷预测的微网储能系统主动控制策略[J]. 电网技术, 2011, 35(8): 35-40.
Chen Yizhe, Zhang Buhan, Wang Jianghong, et al. Active control strategy for microgrid energy storage system based on short-term load forecasting[J]. Power Systems Technology, 2011, 35(8): 35-40.
- [3] 周念成,邓浩,王强钢,等. 光伏与微型燃气轮机混合微网能量管理研究[J]. 电工技术学报, 2012, 27(1): 74-84.
Zhou Niancheng, Deng Hao, Wang Qianggang, et al. Energy management strategy of PV and micro-turbine hybrid micro-grid[J]. Transactions of China Electrotechnical Society, 2012, 27(1): 74-84.

- [4] 刘小平, 丁明, 张颖媛, 等. 微网系统的动态经济调度[J]. 中国电机工程学报, 2011, 31(31): 77-84.
Liu Xiaoping, Ding Ming, Zhang Yingyuan, et al. Dynamic economic dispatch for microgrids[J]. Proceedings of the Chinese Society of Electrical Engineering, 2011, 31(31): 77-84.
- [5] Amjady N, Keynia F, Zareipour H. Short-term load forecast of microgrids by a new bilevel prediction strategy[J]. IEEE Transactions on Smart Grid, 2010, 1(3): 286-294.
- [6] 王越, 卫志农, 吴佳佳. 人工神经网络预测技术在微网运行中的应用[J]. 电力系统及其自动化学报, 2012, 24(2): 83-89.
Wang Yue, Wei Zhinong, Wu Jiajia. Application of ANN prediction technology in microgrid operation[J]. Proceedings of the CSU-EPSA, 2012, 24(2): 83-89.
- [7] 陈民铎, 朱博, 徐瑞林, 等. 基于混合智能技术的微电网剩余负荷超短期预测[J]. 电力自动化设备, 2012, 32(5): 13-18.
Chen Minyou, Zhu Bo, Xu Ruilin, et al. Ultra-short-term forecasting of microgrid surplus load based on hybrid intelligence techniques[J]. Electric Power Automation Equipment, 2012, 32(5): 13-18.
- [8] Ghofrani M, Hassanzadeh M, Etezadi-Amoli M, et al. Smart meter based short-term load forecasting for residential customers[C]. North American Power Symposium(NAPS), 2011: 1-5.
- [9] De Silva D, Yu X, Alahakoon D, et al. Incremental pattern characterization learning and forecasting for electricity consumption using smart meters[C]. IEEE International Symposium on Industrial Electronics (ISIE), 2011: 807-812.
- [10] Huang G B, Zhu Q Y, Siew C K. Extreme learning machine: theory and applications[J]. Neurocomputing, 2006, 70(1): 489-501.
- [11] Huang G B, Wang D H, Lan Y. Extreme learning machines: a survey[J]. International Journal of Machine Learning and Cybernetics, 2011, 2(2): 107-122.
- [12] Huang G B, Zhou H, Ding X, et al. Extreme learning machine for regression and multiclass classification [J]. Systems, Man, and Cybernetics, Part B: IEEE Transactions on Cybernetics, 2012, 42(2): 513-529.
- [13] 程松, 闫建伟, 赵登福, 等. 短期负荷预测的集成改进极端学习机方法[J]. 西安交通大学学报, 2009, 43(2): 106-110.
Cheng Song, Yan Jianwei, Zhao Dengfu, et al. Short-term load forecasting method based on ensemble improved extreme learning machine[J]. Journal of Xi'an Jiaotong University, 2009, 43(2): 106-110.
- [14] 毛力, 王运涛, 刘兴阳, 等. 基于改进极限学习机的短期电力负荷预测方法[J]. 电力系统保护与控制, 2012, 40(20): 140-144.
Mao Li, Wang Yuntao, Liu Xingyang, et al. Short-term power load forecasting method based on improved extreme learning machine[J]. Power System Protection and Control, 2012, 40(20): 140-144.
- [15] Nizar A H, Dong Z Y, Wang Y. Power utility nontechnical loss analysis with extreme learning machine method[J]. IEEE Transactions on Power Systems, 2008, 23(3): 946-955.
- [16] Serre D. Matrices: theory and applications[M]. Germany: Springer, 2010.
- [17] Toh K A. Deterministic neural classification[J]. Neural Computation, 2008, 20(6): 1565-1595.

作者简介

刘 念 男, 1981 年生, 博士, 副教授, 研究方向为新能源与智能配用电系统、电力系统信息安全。

张清鑫 男, 1988 年生, 硕士研究生, 研究方向为负荷特征分析、短期负荷预测。