

# 基于深度信念网络的短期负荷预测方法

孔祥玉<sup>1</sup>, 郑 锋<sup>1</sup>, 鄂志君<sup>2</sup>, 曹 旌<sup>2</sup>, 王 鑫<sup>2</sup>

(1. 智能电网教育部重点实验室(天津大学), 天津市 300072; 2. 国网天津市电力公司, 天津市 300010)

**摘要:** 电力系统信息化的发展及配电网中分布式电源和电动汽车的大量接入, 增加了用电模式的复杂性, 对负荷预测的精确度和稳定性提出了更高的要求。提出了一种基于深度信念网络的短期负荷预测方法。该方法包括深度信念网络的构建、模型参数的逐层预训练和微调, 以及模型的应用等步骤。在模型参数预训练过程中, 采用高斯-伯努利受限玻尔兹曼机(GB-RBM)作为堆叠组成深度信念网络的第1个模块, 使其能够更有效地处理对负荷有影响的多类型实值输入数据; 并采用无监督训练和有监督训练相结合的部分有监督训练算法进行预训练; 利用列文伯格-马夸尔特(LM)优化算法微调预训练阶段得到的网络参数, 使其更快收敛于最优解。最后, 以实际负荷数据进行算例分析, 结果表明, 在训练样本较大且负荷影响因素复杂的情况下, 所提方法具有更高的预测精度。

**关键词:** 电力系统; 负荷预测; 受限玻尔兹曼机; 深度信念网络; 列文伯格-马夸尔特算法

## 0 引言

精确负荷预测是实现电力系统安全经济运行和电网科学管理的基础, 也是提高发电设备利用率和经济调度有效性的重要保证, 对机组最优组合、经济调度、最优潮流、电力市场交易等有着重要的意义<sup>[1]</sup>。

目前用于短期负荷预测的方法主要为统计学方法和人工智能方法两大类。统计学方法包括多元线性回归(multiple linear regression, MLR)、自回归(auto regression, AR)和自回归移动平均(auto regressive moving average, ARMA)<sup>[2]</sup>等。该类方法模型简单, 但只能对少量影响因素及样本数据进行处理, 对原始时间序列的平稳性要求较高。人工智能方法包括灰色系统、模糊逻辑、支持向量机(support vector machine, SVM)<sup>[3]</sup>和人工神经网络(artificial neural network, ANN)<sup>[4]</sup>等, 其中反向传播(back propagation, BP)神经网络方法和SVM方法应用最为广泛。BP神经网络具有很强的自学习能力和复杂的非线性函数拟合能力, 但由于其网络初始参数由随机初始化得到, 导致BP神经网络泛化能力差、易陷入局部最优。SVM方法能够较好地解决传统算法中存在的非线性、高维数、局部最小值

等问题, 但在处理大数据量下的时间序列预测方面, 存在收敛速度慢和预测精度低的缺点。随着电力系统的发展, 用户负荷的类型及影响因素不断增加。在电力市场化环境下, 用户用能行为、用户对激励政策的响应程度和城市发展状况等都增加了用电模式的复杂性。大规模分布式电源的接入和电动汽车的广泛应用增加了负荷的波动性<sup>[5]</sup>, 峰谷分时电价通过自身的经济杠杆作用促使用户不断改变用电方式<sup>[6]</sup>, 并刺激和鼓励电动汽车改变其充放电行为<sup>[7]</sup>。而现阶段基于人工智能的负荷预测方法多为三层的浅层网络, 难以很好地处理这种复杂环境下输入和输出之间的关系。与此同时, 电力系统信息化水平的提高, 海量配用电信息通过各种量测系统的获取, 给负荷预测准确性的进一步提高带来了机遇, 对这些数据的有效分析成为提高电力负荷预测精度的关键。

深度信念网络(deep belief network, DBN)是Hinton在2006年提出的一种高效无监督学习算法<sup>[8]</sup>, 由一系列受限玻尔兹曼机(restricted Boltzmann machine, RBM)堆叠组成, 融合了深度学习和特征学习, 可以对大量数据进行快速分析, 具有强大的数据拟合能力<sup>[9]</sup>。通过逐层无监督预训练的方法得到网络初始参数, 有效解决了传统神经网络参数随机初始化导致的一系列问题; 除了具有好的初始点, 对于经常出现在神经网络中的过拟合和欠拟合问题, 也可以通过预训练得到有效解决。近年来, DBN在图像识别<sup>[10]</sup>、汇率预测<sup>[11]</sup>和局部放电

收稿日期: 2017-08-26; 修回日期: 2017-11-14。

上网日期: 2018-01-23。

国家自然科学基金资助项目(51377119); 国家重点研发计划资助项目(2017YFB0902902)。

模式识别<sup>[12]</sup>等领域得到了广泛的应用,为复杂环境下的负荷预测问题提供了新的思路。文献[13]将3层结构的DBN应用于时间序列预测问题,证明了通过逐层无监督预训练可获取网络参数的较好初始值。文献[14]将历史负荷数据作为输入变量,通过DBN和SVM的组合方法对未来1h的负荷进行预测,结果表明可得到较好的预测效果。文献[15]建立了由两个RBM组成的DBN预测模型,采用BP学习算法微调网络参数,分别针对工业用户和居民用户进行了短期负荷预测,并对输入变量的选取进行了详细分析,结果表明DBN预测模型的预测精度明显优于传统神经网络。

本文对文献[15]中应用的传统DBN进行适当改进,提出了一种应用于复杂环境下基于DBN的短期负荷预测方法。该方法采用无监督训练与有监督训练相结合的混合训练方法对预测模型进行部分有监督预训练,旨在对负荷影响因素与待预测负荷之间的复杂非线性关系进行分层表征,以更好地逼近复杂现实情况;并将天气、日期以及峰谷分时电价等影响因素作为预测模型的输入数据,采用高斯-伯努利RBM(Gaussian-Bernoulli RBM, GB-RBM)作为堆叠组成DBN的第1个RBM,从而更有效地对负荷预测模型输入变量中的连续型数据进行建模;最后采用列文伯格-马夸尔特(Levenberg Marquardt, LM)算法对预训练阶段得到的初始网络参数进行全局微调,避免了梯度下降法收敛缓慢和容易陷入局部最优的缺点。实验证明,在负荷类型复杂且影响因素众多的情况下,本文所提方法与BP神经网络、SVM方法和传统DBN方法相比,具有更好的预测精度。

## 1 基于DBN的负荷预测方法

DBN逐层无监督的学习过程可以弱化和目标函数相关性小的输入特征,进而能够更好地逼近复杂函数,有效提高负荷预测的准确性。将DBN应用于复杂因素下的负荷预测问题中,其关键在于预测模型的构造和相应模型的有效训练。本文将DBN和线性神经网络堆叠构成适用于负荷预测问题的DBN模型,并将训练过程分为两个阶段:部分有监督预训练阶段和基于LM算法的有监督微调阶段。其中部分有监督预训练可以快速得到网络参数的初始解,再利用LM算法对整个网络的参数进行微调,即可得到考虑多种影响因素下的负荷预测模型的最优网络参数解。

### 1.1 基于DBN的负荷预测模型结构

对于电力系统中的日前负荷预测,一般采用逐

点方式进行预测,模型的输出 $\hat{y}$ 为预测点的负荷预测值,预测点的间隔可以是15 min, 30 min或1 h。输入数据则为影响负荷的各种因素,包括日期属性(如月份类型、星期类型、节假日类型等)、天气数据(如温度、湿度、光照强度等)、需求侧管理信息(如峰谷分时电价等)。每一种影响因素可以再进行详细划分,从而形成负荷预测模型的输入向量 $x=[x_1, x_2, \dots, x_n]$ 。输入向量 $x$ 与相应实际负荷值 $y$ 构成一个训练样本 $\{x, y\}$ 。

本文所提出用于负荷预测的DBN的结构如图1所示,由一个输入层、多个隐藏层和一个输出层构成。输入层和所有隐藏层共同构成DBN模型,实现对输入数据的特征提取;最后一个隐藏层和输出层构成线性神经网络,作为网络的回归层,将DBN提取的特征向量作为输入,通过线性激活函数处理得到负荷预测值。为简化描述,本文将DBN和线性神经网络堆叠构成的改进DBN网络结构简记为DBN-NN。其中,权重 $w_l$ 为第 $l-1$ 层隐藏层 $h_{l-1}$ 和第 $l$ 层隐藏层 $h_l$ 之间的对称连接权重, $b_l$ 为第 $l$ 层中由各神经元的偏置组成的偏置向量。由于DBN的最顶层两层隐藏层为双向连接,下面各层之间是自顶向下的有向连接,使得DBN-NN负荷预测模型便于基于训练样本逐层进行预训练。

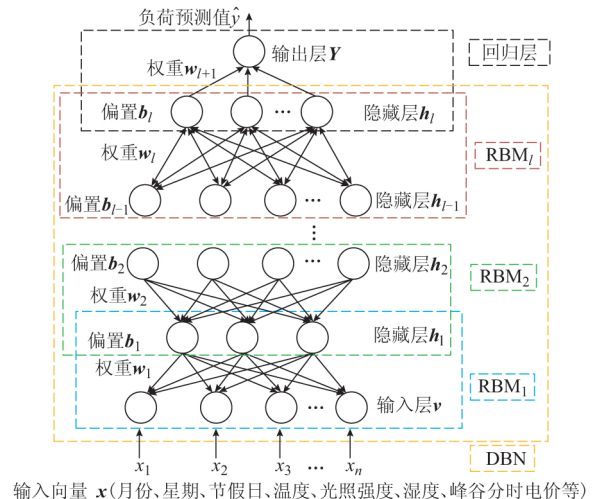


图1 用于负荷预测的DBN-NN结构  
Fig.1 Structure of DBN-NN for load forecasting

### 1.2 DBN-NN的部分有监督预训练阶段

DBN由一系列RBM堆叠组成,可应用RBM的训练方法进行逐层训练<sup>[13]</sup>,并通过该过程获得复杂环境下负荷预测模型的网络初始参数 $W=(w_l)$ 和 $B=(b_l)$ 。

RBM结构见附录A。对于可见单元和隐藏单元均为二进制随机单元的伯努利-伯努利RBM

(BB-RBM), 可见单元和隐藏单元的取值分别为  $v_i \in \{0, 1\}$  和  $h_j \in \{0, 1\}$ , 其能量函数可描述为<sup>[16]</sup>:

$$E(\mathbf{v}, \mathbf{h}; \boldsymbol{\theta}) = - \sum_{i=1}^n \sum_{j=1}^m w_{ij} v_i h_j - \sum_{i=1}^n a_i v_i - \sum_{j=1}^m b_j h_j \quad (1)$$

式中:  $\boldsymbol{\theta} = \{\mathbf{w} = (w_{ij})_{n \times m}, \mathbf{a} = (a_i)_n, \mathbf{b} = (b_j)_m\}$  为 RBM 的参数;  $\mathbf{v} = (v_i)$  和  $\mathbf{h} = (h_j)$  分别为 RBM 的可见单元和隐藏单元的向量;  $w_{ij}$  为可见单元  $v_i$  和隐藏单元  $h_j$  之间的对称连接权重;  $a_i$  和  $b_j$  分别为可见单元  $v_i$  和隐藏单元  $h_j$  的偏置;  $n$  和  $m$  分别为可见单元  $v_i$  和隐藏单元  $h_j$  的数目。

此类可见单元和隐藏单元的联合概率分布  $P(\mathbf{v}, \mathbf{h}; \boldsymbol{\theta})$  可表示为<sup>[16]</sup>:

$$P(\mathbf{v}, \mathbf{h}; \boldsymbol{\theta}) = \frac{e^{-E(\mathbf{v}, \mathbf{h}; \boldsymbol{\theta})}}{\sum_{\mathbf{v}, \mathbf{h}} e^{-E(\mathbf{v}, \mathbf{h}; \boldsymbol{\theta})}} \quad (2)$$

由于 RBM 中的隐单元的状态相互独立, 当给定随机可见向量  $\mathbf{v}$  时, 隐藏单元  $h_j$  的二进制状态被设置为 1 的概率可以通过下式计算得到<sup>[17]</sup>:

$$P(h_j = 1 | \mathbf{v}) = \sigma \left( \sum_{i=1}^n w_{ij} v_i + b_j \right) \quad (3)$$

式中:  $\sigma(x)$  为 sigmoid 激活函数, 其表达式为  $\sigma(x) = (1 + e^{-x})^{-1}$ 。

同样地, 当隐藏层各单元的状态  $\mathbf{h}$  确定时, 可见单元  $v_i$  的二进制状态被设置为 1 的概率可以表示为<sup>[17]</sup>:

$$P(v_i = 1 | \mathbf{h}) = \sigma \left( \sum_{j=1}^m w_{ij} h_j + a_i \right) \quad (4)$$

对于上述 RBM 模型, 本文采用对比散度(CD)方法求解对数似然函数的负梯度来获得参数  $\boldsymbol{\theta}$  的最优值<sup>[16, 18]</sup>。首先将训练数据作为可见单元的状态  $\mathbf{v}$ , 然后根据式(3)计算得到隐藏单元的状态  $\mathbf{h}$ ; 再根据式(4)计算得到可见单元更新重建后的状态  $\mathbf{v}' = (v_i')$ ; 最后根据式(3)重新计算得到隐藏单元更新重建后的  $\mathbf{h}' = (h_j')$ 。其参数更新公式可以表示为:

$$\begin{cases} \Delta w_{ij} = \epsilon_{\text{CD}} (\langle v_i h_j \rangle - \langle v_i' h_j' \rangle) \\ \Delta a_i = \epsilon_{\text{CD}} (\langle v_i \rangle - \langle v_i' \rangle) \\ \Delta b_j = \epsilon_{\text{CD}} (\langle h_j \rangle - \langle h_j' \rangle) \end{cases} \quad (5)$$

式中:  $\epsilon_{\text{CD}}$  为对比散度梯度下降算法的学习率;  $\langle \cdot \rangle$  表示变量的数学期望。

在实际负荷预测过程中, 由于负荷样本量巨大, 可以将训练样本划分为若干组小批量的数据集依次进行训练, 以提高计算效率<sup>[16]</sup>, 则对于包含  $K$  个样本的第  $g$  组数据集的权值和偏置更新公式可以表示为:

$$\begin{cases} w_{ij,g} = w_{ij,g-1} + \epsilon_{\text{CD}} \left[ \frac{1}{K} \sum_{k=1}^K (v_{i,k} h_{j,k} - v_{i,k}' h_{j,k}') \right] \\ a_{i,g} = a_{i,g-1} + \epsilon_{\text{CD}} \left[ \frac{1}{K} \sum_{k=1}^K (v_{i,k} - v_{i,k}') \right] \\ b_{j,g} = b_{j,g-1} + \epsilon_{\text{CD}} \left[ \frac{1}{K} \sum_{k=1}^K (h_{j,k} - h_{j,k}') \right] \end{cases} \quad (6)$$

在考虑多种影响因素的负荷预测过程中, 由于输入变量为日期属性、天气数据、需求侧管理信息等连续型数据, 本文采用可见单元和隐藏单元分别为线性随机单元和二进制随机单元的 GB-RBM 作为堆叠组成 DBN 的第 1 个 RBM。先通过 GB-RBM 将输入数据转换成二进制变量, 然后再采用 BB-RBM 进一步处理。GB-RBM 的能量函数被定义为<sup>[19]</sup>:

$$E(\mathbf{v}, \mathbf{h}; \boldsymbol{\theta}) = \sum_{i=1}^n \frac{(v_i - a_i)^2}{2\sigma_i^2} - \sum_{i=1}^n \sum_{j=1}^m w_{ij} \frac{v_i}{\sigma_i} h_j - \sum_{j=1}^m b_j h_j \quad (7)$$

式中:  $\sigma_i$  为可见单元  $v_i$  的高斯噪声的标准差。

在求解过程中为简化计算, 通常将  $\sigma_i$  设置为 1, 则式(4)可替换为<sup>[19]</sup>:

$$P(v_i | \mathbf{h}) = N \left( \sum_{j=1}^m w_{ij} h_j + a_i, 1 \right) \quad (8)$$

式中:  $v_i$  取实值, 服从均值为  $\sum_{j=1}^m w_{ij} h_j + a_i$ 、方差为 1 的高斯分布。除了可见单元的条件概率分布公式不同以及学习率  $\epsilon_{\text{CD}}$  更小之外, GB-RBM 的参数更新规则和 BB-RBM 的相同。

对于图像分类和语音识别等分类任务, 输入变量的构成已经包含很多关于目标变量  $y$  的信息, 可直接应用 RBM 的训练方法对 DBN 进行逐层无监督训练。而负荷预测作为回归问题, 需要采用无监督训练(重建输入)与有监督训练(减小预测误差)相结合的混合训练方法<sup>[20]</sup>, 混合训练的步骤见附录 B。研究表明, 对前几层隐藏层进行混合训练, 即可达到较好的训练效果。

为了对输入变量与输出变量之间的复杂非线性关系进行分层表征, 本文采用无监督训练与有监督训练相结合的部分有监督训练的方法对 DBN-NN 进行预训练<sup>[20]</sup>, 对第 1 层隐藏层的训练采用无监督训练与有监督训练相结合的混合训练方法, 以后各层逐层无监督训练。预训练流程如图 2 所示。对第 1 层进行训练时, 将  $\mathbf{x} = [x_1, x_2, \dots, x_n]$  作为 RBM<sub>1</sub> 的输入向量, 训练后得到其参数  $\{w_1, a_1, b_1\}$  并固定; 然后将 RBM<sub>1</sub> 的隐藏单元的激活概率作为

RBM<sub>2</sub> 的输入向量,根据式(6)得到其参数 $\{w_2, a_2, b_2\}$ ,将RBM<sub>2</sub>的隐藏单元的激活概率作为RBM<sub>3</sub>的输入向量,继续按照式(6)进行无监督训练,以后各层以此类推,直到最顶层结束,由此可以得到DBN网络的权重 $W$ 和偏置 $B$ 的初始参数。图中: $e_{\max}$ 为RBM训练的最大迭代次数,通常取值为50~200次。

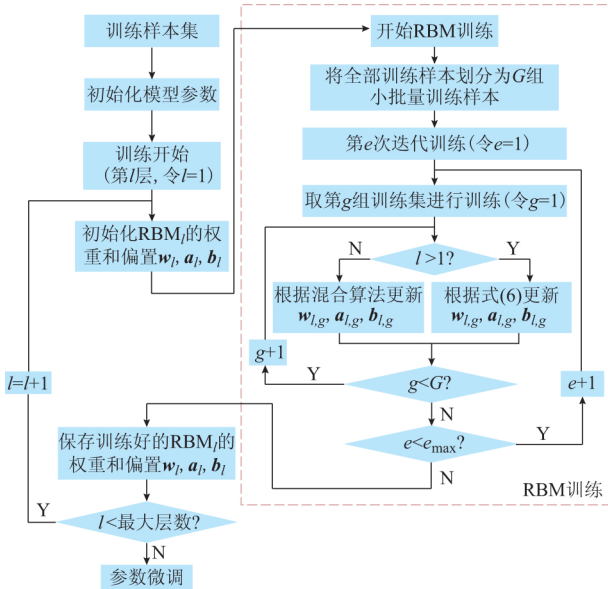


图2 DBN部分有监督预训练流程图

Fig.2 Flow chart of partially supervised pre-training for DBN

### 1.3 基于LM算法的有监督微调阶段

在预训练阶段完成后,需对整体参数进行微调,使模型收敛到全局最优<sup>[19]</sup>。对于给定的训练样本集 $\{x_{(t)}, y_{(t)}\} (t=1, 2, \dots, N)$ ,其输入与输出之间的关系可表示为:

$$\hat{y}_{(t)} = f(x_{(t)}, d) \quad (9)$$

式中: $f$ 为非线性函数; $x_{(t)} = [x_1, x_2, \dots, x_n]$ 为第 $t$ 个训练样本的输入变量; $d = [d_1, d_2, \dots, d_p]$ 为由DBN-NN网络的权重 $W, w_{l+1}$ 和偏置 $B$ 全部参数组成的未知参数向量,其中 $p$ 为参数的个数。

将预测值和实际值的误差平方和作为负荷预测模型的误差损失函数,其表达式为:

$$E(d) = \sum_{t=1}^N e_t^2 = \sum_{t=1}^N (y_{(t)} - f(x_{(t)}, d))^2 \quad (10)$$

式中: $N$ 为训练样本的个数; $y_{(t)}$ 为第 $t$ 个训练样本的实际负荷值。

通常采用最速梯度下降法和共轭梯度下降法实现模型参数的有监督微调<sup>[11,15]</sup>,但该方法往往收敛缓慢,容易陷入局部最优。LM算法适用于误差性能函数为误差平方和的情况,具有局部渐进的二

阶收敛性,所需要的迭代次数很少,并且一定收敛至非线性方程的最小二乘解<sup>[21]</sup>。本文利用LM算法以预训练阶段获得的参数为基础,求出一组 $d$ 使误差 $E(d)$ 最小化。若第 $k$ 次迭代结果为 $d_k$ ,则参数向量的更新可由下式计算得到<sup>[22]</sup>:

$$\Delta d_k = -[J^T(d_k)J(d_k) + \mu I]^{-1} J^T(d_k)E(d_k) \quad (11)$$

式中:阻尼因子 $\mu > 0$ 为常数; $I$ 为单位矩阵; $J(d_k)$ 为雅可比矩阵,即

$$J(d_k) = \begin{bmatrix} \frac{\partial e_1(d_k)}{\partial d_1} & \frac{\partial e_1(d_k)}{\partial d_2} & \dots & \frac{\partial e_1(d_k)}{\partial d_p} \\ \frac{\partial e_2(d_k)}{\partial d_1} & \frac{\partial e_2(d_k)}{\partial d_2} & \dots & \frac{\partial e_2(d_k)}{\partial d_p} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial e_N(d_k)}{\partial d_1} & \frac{\partial e_N(d_k)}{\partial d_2} & \dots & \frac{\partial e_N(d_k)}{\partial d_p} \end{bmatrix} \quad (12)$$

LM算法的每次迭代就是寻找一个合适的阻尼因子 $\mu$ 。当 $\mu$ 为0时,算法转化为最小二乘解的高斯-牛顿法, $\mu$ 很大时,则转化为最速梯度下降法。因此,在迭代前期,LM算法具有最速下降法初始下降量大、迭代迅速的全局收敛特性;而在迭代后期,具有高斯-牛顿法局部收敛的特性,避免了最速下降法的缺点。

## 2 基于DBN-NN的短期负荷预测求解流程

基于DBN-NN的负荷预测算法的具体流程图见附录C图C1。具体步骤如下。

1)对原始数据集进行预处理,并选取待预测日的训练样本集。对于非节假日,选取待预测日前若干天非节假日的数据作为训练样本集;对于节假日,采用加权灰色关联投影方法<sup>[23]</sup>选取待预测日的相似日的数据作为训练数据集,具体步骤见附录C。

2)构造DBN-NN负荷预测模型,利用训练样本集对其进行部分有监督预训练,得到负荷预测模型的网络参数初始值。

3)通过LM优化算法对DBN-NN进行有监督训练,微调整个网络的参数,得到最优解。

4)训练完成后,将待预测时刻输入数据集合输入到训练好的DBN-NN模型中,得到各个时刻的负荷预测值。

## 3 算例分析

### 3.1 实验数据和输入变量的选取

实验样本数据以中国某地区2015年1月至2017年7月的实际负荷数据为基础,负荷中包括若



干分布式电源和电动汽车,其中分布式电源主要为光伏发电。该地区采用峰谷分时电价,电价情况见附录 D。根据所研究对象电网的负荷特性,确定负荷预测的输入变量为月份、星期、节假日、预测时刻的温度、预测时刻的光照强度、预测时刻的相对湿度、预测日的降雨量、预测日的最高温度、预测日的最低温度、预测日的平均温度、预测时刻的电价、前一天同一时刻的负荷、前一天前一时刻的负荷、前一天后一时刻的负荷、前一周同一天的平均负荷(若前一周同一天是节假日,则继续向前寻找最近的同类型日)。天气数据源自气象网站,采集时间间隔为 1 h,算例中负荷数据选用与天气数据对应的每小时的数据进行分析。

### 3.2 实验评价指标

本文选取平均绝对百分误差  $e_{\text{MAPE}}$  作为评判各种方法预测效果的依据,以 24 点日前负荷预测为例, $e_{\text{MAPE}}$  的表达式为:

$$e_{\text{MAPE}} = \frac{1}{24} \sum_{i=1}^{24} \frac{|\hat{y}_i - y_i|}{y_i} \times 100\% \quad (13)$$

式中: $y_i$  和  $\hat{y}_i$  分别为预测日第  $i$  个采样点的实际负荷值和预测负荷值。电力负荷预测中, $e_{\text{MAPE}}$  值越小,则负荷预测越准确。

### 3.3 参数设置和结构选取

由于所构建的 DBN-NN 负荷预测模型,隐藏层的层数和每个隐藏层的单元数量对预测精度和运算耗时有一定的影响,因此本文对这两个参数的选取进行重点分析。模型的其他参数的设置参考文献[16]和文献[17],具体数值见附录 E。

为了获取最佳预测模型,将 2016 年 7 月 1 日至 31 日(非节假日)的数据作为测试样本集,2015 年 1 月 1 日至 2016 年 6 月 30 日的数据作为 DBN-NN 的训练样本集,采用枚举法对隐藏单元数逐层进行选取,以验证深度网络结构对预测效果和耗时的影响。首先确定第 1 层隐藏单元的最佳数量并固定;然后增加一层隐藏层,确定第 2 层隐藏单元数量的最佳值;以此类推,直到预测精度不再提高为止。

表 1 给出了不同网络结构下 DBN-NN 负荷预测模型的预测性能。对每层隐单元数量进行选取时,依次设置为 5~40 个(间隔为 5 个),共 8 个级别。隐藏层的层数依次设置为 1,2,3 层,性能指标  $e_{\text{MAPE}}$  的值为重复 20 次实验的平均值。由表 1 可知,第 1 层隐藏层的神经元数量为 20 个时, $e_{\text{MAPE}}$  取得最小值 1.88%;第 2 层隐单元数为 15 时, $e_{\text{MAPE}}$  取得最小值 1.51%;当第 3 层隐单元数为 25 时, $e_{\text{MAPE}}$  取得最小值 2.33%,已经高于仅包含两层时的最佳值 1.51%。由此可知,对于该数据集,DBN-NN 预测

模型采用 4 层结构(即第 1 层和第 2 层隐藏单元数目分别为 20 和 15,表中用红色标识)时具有较佳效果。

表 1 DBN-NN 模型不同结构时的预测性能  
Table 1 Forecasting performance of DBN-NN model with different structures

隐藏层数	隐单元数	$e_{\text{MAPE}}/\%$	耗时/s
1	5	5.38	5.69
	10	3.26	4.45
	15	2.41	5.39
	20	1.88	5.90
	25	2.12	13.32
	30	2.53	10.01
	35	2.38	14.52
	40	2.64	20.77
2	5	2.59	10.18
	10	1.75	15.68
	15	1.51	21.36
	20	2.03	36.99
	25	2.18	39.56
	30	2.27	45.90
	35	2.05	41.09
	40	2.59	63.40
3	5	3.16	24.17
	10	2.77	19.95
	15	2.85	28.70
	20	2.59	37.48
	25	2.33	49.95
	30	2.61	67.49
	35	2.87	111.66
	40	2.74	127.18

### 3.4 结果分析

为了充分验证本文方法的有效性和科学性,分别对该地区 2016 年各个季节的负荷进行了预测,训练样本集由各个待预测日前 10 个月的负荷数据、天气数据、日期类型数据和电价数据构成。为了突出本文方法的优势,选择 BP 神经网络、SVM 方法和传统 DBN 方法进行对比。表 2 为各种方法对 4 个季节的负荷进行预测时的  $e_{\text{MAPE}}$ 。为了保证客观性,实验结果均为执行 20 次实验得到的平均值。在考虑温度、光照强度、湿度和峰谷分时电价影响的情况下,本文方法可以更充分地挖掘多个影响因素和负荷值的复杂关系,相应的  $e_{\text{MAPE}}$  总平均值为 2.26%,比其他 3 种方法预测误差都小。

图 3 为 2016 年 12 月 6 日至 12 日连续 7 日实际负荷值和不同方法预测结果对比分析图,由图 3 可知,本文方法具有较好的拟合精度。BP 神经网络、SVM 方法和传统 DBN 方法整体预测结果不错,但是在负荷峰谷时段,由于用户用电行为和分布式电源不确定性较大,这几种方法不能有效分析该

时段输入变量对负荷的影响,导致其预测精度有所下降。

表 2 不同季节预测误差的比较  
Table 2 Comparison of forecasting errors  
in different seasons

季节	日期	$e\text{MAPE}/\%$			
		BP	SVM	传统 DBN	本文方法
春季	2016 年 4 月 11 日至 24 日	6.59	4.31	3.31	2.41
夏季	2016 年 7 月 4 日至 17 日	4.53	3.49	4.07	2.57
秋季	2016 年 10 月 17 日至 30 日	5.36	4.45	4.29	2.21
冬季	2016 年 12 月 5 日至 18 日	4.51	4.14	3.67	1.86
平均值		5.25	4.10	3.84	2.26




图 3 2016 年 12 月 6 日至 12 日不同方法的  
预测结果对比

Fig.3 Comparison of forecasting results of different  
methods from December 6 to 12, 2016

分布式电源渗透率较低时,各种方法的预测结果对比图见附录 F 图 F1。由图 F1 可知,当用电模式稳定、分布式电源和电动汽车接入量较低时,浅层网络更具优势。本文方法更适用于复杂因素下的负荷预测问题。

#### 4 结语

本文将改进的 DBN 应用于复杂环境下考虑多种因素影响的负荷预测问题中,通过部分有监督预训练的方法将 DBN-NN 模型的参数初始化为较优解,再利用 LM 优化算法进一步训练得到全局最优解,既解决了模型训练速度慢的问题,同时产生较好的参数,从而大大提升了模型的建模能力和预测精度。和 BP 神经网络、SVM 方法和传统 DBN 方法相比,改进的 DBN 预测模型能够有效提高复杂影响因素情况下的负荷预测精度。未来可以将该方法与其他负荷预测方法相结合,并研究针对负荷特性分类及基于 MapReduce 并行化的计算模型,进一步

提高该方法的训练效率及数据处理能力。

附录见本刊网络版 (<http://www.aeps-info.com/aeps/ch/index.aspx>)。

#### 参考文献

- [1] 康重庆,夏清,刘梅.电力系统负荷预测[M].2版.北京:中国电力出版社,2017.
- [2] HONG T, WANG P, WILLIS H L. A naive multiple linear regression benchmark for short term load forecasting [C]// IEEE Power and Energy Society General Meeting, July 24-29, 2011, Detroit, USA: 1-6.
- [3] 吴倩红,高军,侯广松,等.实现影响因素多源异构融合的短期负荷预测支持向量机算法[J].电力系统自动化,2016,40(15): 67-72.DOI:10.7500/AEPS20160229012.
- [4] WU Qianhong, GAO Jun, HOU Guangsong, et al. Short-term load forecasting support vector machine algorithm based on multi-source heterogeneous fusion of load factors [J]. Automation of Electric Power Systems, 2016, 40(15): 67-72. DOI: 10.7500/AEPS20160229012.
- [5] HERNANDEZ L, BALADRON C, AGUIAR J M, et al. Artificial neural network for short-term load forecasting in distribution systems[J]. Energies, 2014, 7(3): 1576-1598.
- [6] LIU J, GAO H, ZHAO M A, et al. Review and prospect of active distribution system planning[J]. Journal of Modern Power Systems and Clean Energy, 2015, 3(4): 457-467.
- [7] 姚建刚,付强,叶伦,等.考虑峰谷分时电价影响的变电站容量规划方法[J].电力系统自动化,2017,41(13):53-61.DOI:10.7500/AEPS20161013010.
- [8] YAO Jiangang, FU Qiang, YE Lun, et al. Substation capacity planning method considering influence of peak-valley time-of-use power price[J]. Automation of Electric Power Systems, 2017, 41(13): 53-61. DOI: 10.7500/AEPS20161013010.
- [9] LIU H, ZENG P, GUO J, et al. An optimization strategy of controlled electric vehicle charging considering demand side response and regional wind and photovoltaic[J]. Journal of Modern Power Systems and Clean Energy, 2015, 3(2): 232-239.
- [10] HINTON G E, OSINDERO S, TEH Y W. A fast learning algorithm for deep belief nets[J]. Neural Computation, 2006, 18(7): 1527-1554.
- [11] LIU W, WANG Z, LIU X, et al. A survey of deep neural network architectures and their applications[J]. Neurocomputing, 2016, 234: 11-26.
- [12] HUANG G B. Learning hierarchical representations for face verification with convolutional deep belief networks [C]// IEEE Conference on Computer Vision and Pattern Recognition, June 16-21, 2012, Providence, RI, USA: 2518-2525.
- [13] SHEN F R, CHAO J, ZHAO J X. Forecasting exchange rate using deep belief networks and conjugate gradient method[J]. Neurocomputing, 2015, 167: 243-253.
- [14] 张新伯,唐炬,潘成,等.用于局部放电模式的深度置信网络方法[J].电网技术,2016,40(10):3272-3278.
- [15] ZHANG Xinbo, TANG Ju, PAN Cheng, et al. Research of

- partial discharge recognition based on deep belief nets[J]. Power System Technology, 2016, 40(10): 3272-3278.
- [13] KUREMOTO T, KIMURA S, KOBAYASHI K, et al. Time series forecasting using a deep belief network with restricted Boltzmann machines[J]. Neurocomputing, 2014, 137(15): 47-56.
- [14] QIU X, ZHANG L, REN Y, et al. Ensemble deep learning for regression and time series forecasting[C]// IEEE Symposium on Computational Intelligence in Ensemble Learning, December 9-12, 2014, Orlando, USA: 1-6.
- [15] DEDINEC A, FILIPOSKA S, DEDINEC A, et al. Deep belief network based electricity load forecasting: an analysis of Macedonian case[J]. Energy, 2016, 115: 1688-1700.
- [16] HINTON G E. A practical guide to training restricted Boltzmann machines[J]. Momentum, 2012, 9(1): 599-619.
- [17] HINTON G, DENG L, YU D, et al. Deep neural networks for acoustic modeling in speech recognition: the shared views of four research groups[J]. IEEE Signal Processing Magazine, 2012, 29(6): 82-97.
- [18] HINTON G E. Training products of experts by minimizing contrastive divergence[J]. Neural Computation, 2002, 14(8): 1771-1800.
- [19] HINTON G E, SALAKHUTDINOV R R. Reducing the dimensionality of data with neural networks[J]. Science, 2006, 313(5786): 504-507.
- [20] BENGIO Y. Learning deep architectures for AI [J]. Foundations and Trends in Machine Learning, 2009, 2(1): 1-127.
- [21] MARQUARDT D W. An algorithm for least-squares estimation of nonlinear parameters[J]. Journal of the Society for Industrial & Applied Mathematics, 1963, 11(2): 431-441.
- [22] 严正, 范翔, 赵文恺, 等. 自适应 Levenberg-Marquardt 方法提高潮流计算收敛性[J]. 中国电机工程学报, 2015, 35(8): 1909-1918.  
YAN Zheng, FAN Xiang, ZHAO Wenkai, et al. Improving the convergence of power flow calculation by a self-adaptive Levenberg-Marquardt method[J]. Proceedings of the CSEE, 2015, 35(8): 1909-1918.
- [23] 吴潇雨, 和敬涵, 张沛, 等. 基于灰色投影改进随机森林算法的电力系统短期负荷预测[J]. 电力系统自动化, 2015, 39(12): 50-55. DOI:10.7500/AEPS20140916005.  
WU Xiaoyu, HE Jinghan, ZHANG Pei, et al. Power system short-term load forecasting based on improved random forest with grey relation projection[J]. Automation of Electric Power Systems, 2015, 39(12): 50-55. DOI: 10.7500/AEPS20140916005.
- 孔祥玉(1978—),男,博士,副教授,主要研究方向:电力系统分析、智能配用电技术。E-mail: eekongxy@tju.edu.cn  
郑 锋(1992—),男,通信作者,硕士研究生,主要研究方向:电力负荷预测及应用。E-mail: zhengfeng6\_6@163.com  
鄂志君(1977—),男,博士,高级工程师,主要研究方向:电力系统运行与控制。E-mail: ezj1977@126.com  
(编辑 孔丽蓓)

### Short-term Load Forecasting Based on Deep Belief Network

KONG Xiangyu<sup>1</sup>, ZHENG Feng<sup>1</sup>, E Zhijun<sup>2</sup>, CAO Jing<sup>2</sup>, WANG Xin<sup>2</sup>

(1. Key Laboratory of Smart Grid of Ministry of Education (Tianjin University), Tianjin 300072, China;  
2. State Grid Tianjin Electric Power Company, Tianjin 300010, China)

**Abstract:** The development of power system informationization and the increasing integration of distributed generators and electric vehicle to distribution network have increased the complexity of power consumption mode and put forward higher requirements for the accuracy and stability of load forecasting. A short-term load forecasting method based on deep belief network is proposed. The method includes the network construction, the layer-by-layer pre-training of the model parameters, the supervised fine-tuning, and the application of the model. In the pre-training process of the model parameters, the Gaussian-Bernoulli restricted Boltzmann machine (GB-RBM) is used as the first module for stacking the deep belief network to deal more effectively with the multi-type real-valued input data. And the partially supervised training algorithm combined by unsupervised training algorithm and supervised training algorithm is used for pre-training. The Levenberg-Marquardt (LM) optimization algorithm is used to fine-tune the parameters obtained by the pre-training phase, which can help to converge faster to the optimal solution. Finally, the actual load data are used for test and the experiments results show that the method proposed has higher prediction accuracy in the case of large training samples and complicated load factors.

This work is supported by National Natural Science Foundation of China (No. 51377119) and National Key R&D Program of China (No. 2017YFB0902902).

**Key words:** power system; load forecasting; restricted Boltzmann machines; deep belief network; Levenberg-Marquardt algorithm