

# 基于深度学习LSTM网络的短期电力负荷预测方法

陈卓 孙龙祥

(浙江大学 电气工程学院, 浙江 杭州 310027)

**摘要:** 随着电力系统的建立与发展, 负荷预测将发挥越来越重要的作用。电力系统负荷预测的结果对电力系统的调度运行和生产有很大影响, 准确的负荷预测有助于提高电力系统的安全稳定性。但在进行短期电力负荷预测时, 传统模型无法同时兼顾负荷数据的时序性和非线性特点。为此文章提出一种基于长短期记忆神经网络(Long Short Term Memory, LSTM)的电力负荷预测方法, 并使用这种方法对某地电力负荷值进行预测, 将预测结果与传统模型对比, 最终证明LSTM模型的误差更低, 预测效果更好。

**关键词:** 短期电力负荷预测; 长短期记忆神经网络; 传统模型

## Short-Term Electrical Load Forecasting Based on Deep Learning LSTM Networks

Chen Zhuo Sun Long-xiang

(Zhejiang University, Hangzhou 310027, China)

**Abstract:** With the establishment and development of power system, Electrical load forecasting will play an increasingly important role. Power system load forecasting has great influence on scheduling and production planning of power system. Accurate load forecasting can help to improve the safety and stability of power system. But in the short-term power load forecasting, the traditional model can not grasp the relationship of timing and nonlinearity simultaneously. In this paper, a power load forecasting method based on Long Short Term Memory (LSTM) is proposed to predict the power load. Finally, the prediction results are compared with the traditional model to prove that it has lower error and applicability.

**Key words:** Short-term power load forecasting, Long-term memory neural network, Traditional model

### 0 引言

电力系统负荷预测是电力系统规划的重要组成部分, 也是电力系统经济运行的基础, 它从已知的用电需求出发来预测未来的用电需求。电力系统负荷预测的结果可以在一定程度上反映负荷的发展状况和水平, 电力生产部门和管理部门以此为依据制定生产计划和发展规划。

电力负荷预测方法按照预测的时间范围来划分, 可分为长期、中期、短期和超短期预测。长期负荷预测通常指10年以上的预测, 中期负荷预测通常指5年左右的预测, 中、长期负荷预测是以年为单位进行预测的, 主要用于为电力系统规划建设, 包括电网的增容扩建及装机容量的大小、位置和时间的确定提供基础数据, 确定年度检修计划、运行方式等。短期负荷预测通常为1年以内的预测, 它的预测单位包括月、周、天、小时, 主要用于调节指导电力部门的日常运行。

短期电力负荷预测的传统模型有两类, 一类是传统的时间序列模型, 代表模型为自回归积分滑动平均模型[1],[2],[3](Autoregressive Integrated Moving Average Model, ARIMA)。它是由博克思和詹金斯

在70年代提出的一种经典时间序列预测方法。

ARIMA模型的基本思想是: 将电力负荷随时间推移而形成的数据序列视为一个随机序列, 用这个序列对电力负荷变化的规律和特性进行分析并对未来负荷作出预测。它的优点在于考虑了数据的时序性关系, 缺点在于对非线性关系数据的预测能力有限。

第二类是机器学习模型。例如文献[4],[5],[6]中使用了BP神经网络来预测, 文献[7]中用到了灰色投影和随机森林算法。文献[8]先利用PCA对特征处理, 然后利用支持向量机来回归预测。文献[9]使用了梯度下降决策树GBDT来预测。以上算法共同存在的问题在于缺少对时序数据时间相关性的考虑, 需要人为添加时间特征来保证预测的结果。

为了解决以上两类模型无法同时兼顾数据的时序性和非线性关系的问题, 本文介绍了一种利用深度学习长短期记忆神经网络模型来对电力负荷进行预测的方法, 这种神经网络在短期回归预测的同时也考虑了数据的相关性。

### 1 基于LSTM神经网络的模型建立

长短期记忆网络<sup>[10]</sup>(Long Short Term Memory,

LSTM), 由 Sepp Hochreiter 和 Jürgen Schmidhuber 在 1997 年提出并加以完善与普及。LSTM 神经网络是基于循环神经网络 (Recurrent Neural Networks, RNN) 改进的一种算法。

### 1.1 循环神经网络RNN原理

RNN叫做循环神经网络<sup>[11]</sup>, 它会将上一时刻的隐藏层状态信息应用于当前输出的计算中, 下图是一个典型的RNN单元:




图1 RNN单元

RNN的原理如下:  $x_t$ 表示的t时刻的输入,  $s_t$ 表示t时刻隐藏层的状态,  $o_t$ 表示输出。RNN不同于传统神经网络的地方在于隐藏层的输入有两个来源, 一个是当前的输入 $x_t$ , 一个是上一个状态隐藏层的输出 $s_{t-1}$ ,  $W, U, V$ 为参数。使用公式可以将上面结构表示为:

$$s_t = \tanh(Ux_t + Ws_{t-1}) \quad (1)$$

$$o_t = \text{softmax}(Vs_t) \quad (2)$$

RNN存在的问题在于, 当时间间隔不断增大时, RNN会丧失学习过去较久远信息的能力, 即梯度消失。

### 1.2 长短期记忆网络LSTM原理

LSTM就是为了解决梯度消失的问题而产生的, 其结构是基于RNN的改进。LSTM的细胞单元结构如下




图2 LSTM单元

LSTM的细胞单元具有三个门<sup>[12]</sup>, 分别是Input Gate(输入门), Forget Gate(遗忘门), Output Gate(输出门)。输入门用来控制信息输入, 遗忘门用来控制细胞历史状态信息的保留, 输出门用来控制信息输出。激活函数 $\sigma$ 使得遗忘门的输出值在 $[0,1]$ 之间, 当遗忘门输出为0的时候, 表示将上一状态的信息全部丢弃;

为1的时候, 表示上一状态的信息全部保留。

$$i_t = \sigma(W_{xi}x_t + W_{hi}h_{t-1} + W_{ci}c_{t-1} + b_i) \quad (3)$$

$$f_t = \sigma(W_{xf}x_t + W_{hf}h_{t-1} + W_{cf}c_{t-1} + b_f) \quad (4)$$

$$c_t = f_t c_{t-1} + i_t \tanh(W_{xc}x_t + W_{hc}h_{t-1} + b_c) \quad (5)$$

$$o_t = \sigma(W_{xo}x_t + W_{ho}h_{t-1} + W_{co}c_t + b_o) \quad (6)$$

$$h_t = o_t \tanh(c_t) \quad (7)$$

其过程可用以上公式表示,  $x_t$ 为输入,  $h_t$ 为输出,  $i_t$ 为输入门的输出,  $f_t$ 为遗忘门的输出,  $c_t$ 为当前时刻t的细胞单元状态,  $o_t$ 为输出门的输出, 其中 $W$ 和 $b$ 为参数矩阵。

## 2 实验和证明

本次实验使用的数据是某市电力公司的2012-2017年共2110条电力负荷数据。

### 2.1 数据处理

#### (1)数据标准化

标准化采用了min-max标准化法, 对于数据集中每一个值 $x$ , 其标准化计算公式为:

$$x_{norm} = \frac{x - \min}{\max - \min} \quad (8)$$

其中 $x_{norm}$ 为标准化后的值,  $x$ 为数据集中的最大值,  $\max$ 为数据集中的最小值。

#### (2)训练测试集划分

以2012-2016年数据作为训练集, 以2017年的数据作为测试集。

#### (3)预测结果误差评估标准

采用平均绝对百分误差(Mean Absolute Percentage Error, MAPE)作为最终评估标准, 越低则表明误差越小。

$$MAPE = \frac{\sum_{i=1}^n \frac{|y_i - \hat{y}_i|}{|y_i|}}{n} \quad (9)$$

其中 $n$ 为预测结果总个数,  $y_i$ 为真实值,  $\hat{y}_i$ 为预测值。

### 2.2 实验比较

#### (1)ARIMA结果

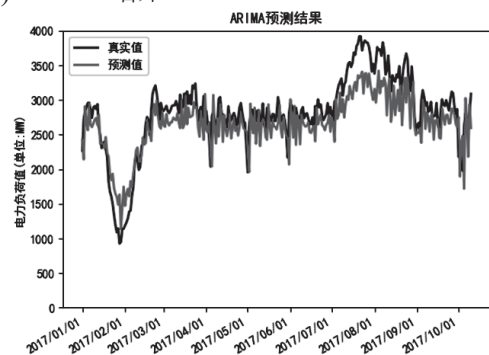


图3 ARIMA预测结果

## (2)LSTM结果

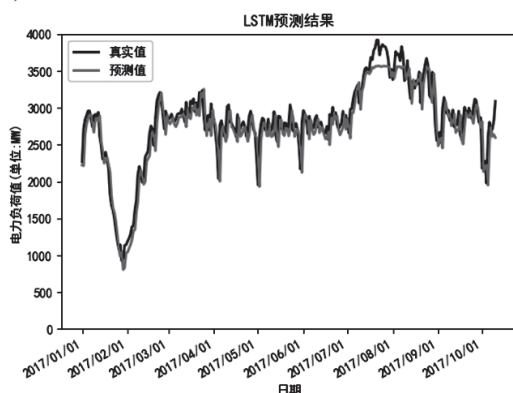


图4 LSTM 预测结果

## (3)预测误差




图5 预测误差

## (4)MAPE误差比较

模型	ARIMA	LSTM
MAPE	9.74%	5.76%

由以上结果可以看出，LSTM的对电力负荷预测的误差低于传统模型ARIMA的误差，证明LSTM在电力负荷预测上比ARIMA更准确。

## 3 结语

由于时序数据具有时序性和非线性特点，而传统时序模型和机器学习模型无法同时兼顾数据的这两个特点，使得传统模型预测结果预测不佳。本文采用的LSTM长短期记忆神经网络方法可以很好地解决这两种问题，同时将它和传统经典的ARIMA模型共同在真实的电力数据集上实验比较，实验结果表明LSTM能较准确地对电力系统的负荷进行预测。

## 参考文献

[1] 麦鸿坤,李惊涛,董雨,等.一种基于ARIMA模型的电力负荷预测及预测结果评价的方法:,CN104794549A[P]. 2015.

[2] 李晨熙.基于ARIMA模型的短期电力负荷预测[J].吉林电力,2015,43(6):22-24.  
 [3] 宋亚莉.基于ARIMA模型的电力负荷预测[J].城市建设理论研究:电子版,2012(29).  
 [4] 张振,王锋,陈敏曦.基于BP网络的电力负荷预测改进研究[J].中国电机:技术版,2015(10).  
 [5] 吕婵.基于BP神经网络的短期负荷预测[D].华中科技大学,2007.  
 [6] 方方.基于改进BP神经网络的电力负荷预测研究[D].哈尔滨工业大学,2011.  
 [7] 吴潇雨,和敬涵,张沛,等.基于灰色投影改进随机森林算法的电力系统短期负荷预测[J].电力系统自动化,2015,39(12):50-55.  
 [8] 石海波.PCA-SVM在电力负荷预测中的应用研究[J].计算机仿真,2010,27(10):279-282.  
 [9] 郑凯文,杨超.基于迭代决策树(GBDT)短期负荷预测研究[J].贵州电力技术,2017,20(2):82-84.  
 [10] Hochreiter S, Schmidhuber J. Long Short-Term Memory[J]. Neural Computation, 1997, 9(8):1735.  
 [11] Graves A. Generating Sequences With Recurrent Neural Networks[J]. Computer Science, 2013.  
 [12] Graves A, Mohamed A R, Hinton G. Speech recognition with deep recurrent neural networks[C]//IEEE International Conference on Acoustics, Speech and Signal Processing. IEEE, 2013: 6645-6649.