

基于深度学习的电网短期负荷预测方法研究

吴润泽¹, 包正睿¹, 宋雪莹¹, 邓 伟²

(1. 华北电力大学电气与工程学院, 北京 102206; 2. 北京国电通网络技术有限公司, 北京 100070)

Research on Short-term Load Forecasting Method of Power Grid Based on Deep Learning

WU Runze¹, BAO Zhengrui¹, SONG Xueying¹, DENG Wei²

(1. School of Electric and Electronic Engineering, North China Electric Power University, Beijing 102206, China;

2. Beijing Guodiantong Network Technology Co., Ltd., Beijing 100070, China)

摘 要: 深度模型通过学习一种深层非线性网络结构以实现复杂函数逼近, 具有很强的自适应感知能力。本文为了提高电力负荷预测精度, 提出一种基于栈式自编码神经网络的深度学习预测方法。该方法结合自编码器和逻辑回归分类器构建一个多输入单输出预测模型, 并将重构后的历史负荷、气象信息等数据输入到预测模型中, 用栈式自编码器逐层学习并提取深层特征, 最后在网络顶层连接逻辑回归模型进行短期负荷预测。实例分析表明, 所提预测模型能够有效刻画日负荷变化规律, 泛化能力较强, 其预测精度达到 96.2%, 比支持向量回归和模糊神经网络两种浅层学习模型更高。

关键词: 负荷预测; 深度学习; 栈式自编码器; 特征提取; 神经网络

Abstract: The depth model achieves complex function approximation by learning a deep nonlinear network structure, which has strong adaptive perception ability. In order to improve the prediction accuracy of power load, a deep learning prediction method based on stacked auto-encoder neural network is proposed in the paper. A multi-input single-output prediction model is built by combing the auto-encoder with the logic regression classifier, such data as the reconstructed historical load, meteorological elements and so on are all input into prediction model, and the load characteristics is extracted through the hierarchical learning of the stacked auto-encoder. Finally, the short-term load prediction is realized by using the logical regression model at the top of the network. Case analysis shows that the proposed model can effectively characterize the daily load change law with strong generalization performance, and its prediction accuracy can reach 96.2%, which is higher than that of two shallow

learning models based on support vector regression and fuzzy neural network respectively.

Keywords: load forecasting; deep learning; stacked auto-encoder; feature extraction; neural network

0 引 言

电力系统负荷预测作为能量管理系统的重要组成部分, 预测误差的大小直接影响电网后续安全校核的分析结果, 对电网动态状态估计、负荷调度和减少发电成本等方面具有重要意义^[1-2]。由于负荷本身的不确定性和复杂性, 准确的负荷特性分析和预测模型建立是提高预测精度的关键所在^[3]。现有预测模型主要集中在浅层学习, 在有限的样本和计算单元下对复杂函数的逼近能力有限, 难以提取负荷序列的深层次特征, 模型的泛化性能受到了限制, 阻碍了预测精度的进一步提高。而近年来兴起的深度学习模型具有非常好的信息表达能力, 鲁棒性和泛化性^[4], 已成功应用在图像识别、计算机视觉等诸多领域, 并且在预测领域也开始崭露头角。

传统负荷预测方法主要有基于时间序列的 AR-MA 模型、灰色预测法以及回归分析法等。该类方法所构建的预测模型简单, 应用较为广泛, 但对负荷序列的平稳性要求较高, 大多只利用历史负荷进行预测, 在某些情况下的预测精度会受到影响。为了克服这些缺陷, 以人工神经网络(ANN)^[5]和支持向量机(SVM)^[6]为代表的浅层机器学习算法凭借良好的非线性函数拟合能力已成为该领域的研究热点, 这些方法的改进和组合在一定程度上改善了负荷预测精度提高受限的问题。如文献 [7] 基于

基金项目: 国家自然科学基金资助项目(51507063); 国家电网公司科技项目(B34681150152)

聚类分析和神经网络提出一种组合预测方法, 将其应用到商业办公区的负荷预测, 比 ARIMA 模型预测精度提高约 50%。文献 [8] 提出一种改进的随机森林回归算法, 并通过灰色关联投影法选择相似日来提高预测模型的精度和鲁棒性。文献 [9] 针对负荷影响因素的多源异构特性进行差异化处理和融合, 建立并行化多核 SVM 预测模型来提高负荷预测精度和速度。然而, 随着更多的学习样本和影响因素考虑在内, 这些非参数模型寻优过程越加复杂, 易陷入局部最优, 并且预测稳定性一般。目前, 基于深度学习的预测模型已在其它领域相继被提出。在文献 [10] 中, HUANG 等人开创性地应用基于限制波尔兹曼机的深度信念网络 (DBN) 模型实现交通流量预测。文献 [11] 利用底层 DBN 模型进行交通流量特征学习, 并在顶层连接支持向量回归 (SVR) 进行交通流预测, 预测精度提高了 18.01%。而文献 [12] 在主成分分析基础上将深度长短期记忆网络 (LSTM) 应用在短期风电功率预测中, 预测误差比 SVM 模型更低。深度学习应用在上述领域所表现出的自适应学习、感知能力, 可有效解决现有浅层预测模型对大量非线性负荷数据潜在特性的认知能力不足、人为因素干扰等问题。

本文将深度学习引入到负荷预测领域, 提出一种栈式自编码神经网络 (stacked auto-encoder neural network, SAE-NN) 深度预测方法。该方法由底层的栈式自编码器 (SAE) 和顶层的逻辑回归 (LR) 模型组成多输入单输出预测模型, 将重构后的历史负荷和气象信息等数据作为模型的输入, 利用堆叠的自编码器逐层进行特征识别和学习, 经过无监督的网络训练和有监督的参数微调后提取出负荷变化的深层特征, 最后连接到顶层 LR 模型实现短期负荷预测。对山西某城市电网负荷数据进行算例分析, 结果表明该方法可有效提高负荷预测精度。

1 深度自编码神经网络

1.1 自编码器

自编码器 (autoencoder, AE) 作为构建 SAE 模型的基本单元, 通过逼近一个恒等函数, 使得输出接近于输入, 其结构类似三层神经网络, 如图 1 所示, 包含可视层、隐藏层和重构可视层, 在功能上可分为编码和解码两部分。

假设网络的输入和输出数据形式同构, 将历史




图1 自编码器结构

负荷、天气要素和日类型重构后组成一个学习样本集 $X = \{x_1, x_2, \dots, x_i, \dots, x_N\}$, 其中 $x_i = \{x_{i,1}, x_{i,2}, \dots, x_{i,d}\}$, N 表示样本个数, 可视层每个节点与 x_i 内元素逐一对应。在编码阶段, 将 x_i 作为特征向量输入到隐藏层中, 通过公式 (1) 得到编码结果 h , 完成特征提取, 然后使用公式 (2) 对一阶特征表示 h 进行重构, 得到解码输出 $y(x_i)$ 。

$$h = f(w_1 x_i + b_1) \quad (1)$$

$$y(x_i) = g(w_2 h + b_2) \quad (2)$$

式中: $\{w_1, b_1\}$ 和 $\{w_2, b_2\}$ 分别表示可视层与隐藏层、隐藏层与重构可视层的连接权值和偏置值矩阵。 $f(\cdot)$ 和 $g(\cdot)$ 是对应节点的变换核函数, 一般采用 sigmoid 函数, 如式 (3) 所示。

$$g(x) = f(x) = \frac{1}{1 + e^{-x}} \quad (3)$$

单个自编码器通过反向传播算法来训练网络实现重构并恢复输入值, 关键在于最小化代价函数求解满足逼近条件 $y(x_i) \approx x_i$ 的参数 $\{w, b\}$ 值。自编码器的误差代价函数 $C_{\text{sparse}}^{[13]}$ 可表示为

$$C_{\text{sparse}}(w, b) = \frac{1}{2N} \sum_{i=1}^N \sum_{j=1}^d (y(x_{i,j}) - x_{i,j})^2 + \frac{\lambda}{2} \sum_l \sum_i \sum_j (w_{i,j}(l))^2 + \gamma \sum_{k=1}^n KL(\rho \| \hat{\rho}_k) \quad (4)$$

式中: d 表示输入层节点个数; λ 是权重衰减参数; n 为隐藏层神经元个数; $KL(\rho \| \hat{\rho}_k)$ 是稀疏项惩罚因子; γ 为稀疏项权重; ρ 一般取值 0.05。

1.2 SAE-NN 预测模型设计

栈式自编码神经网络 SAE-NN 主要包含 SAE 模型和 LR 模型两部分, 底层 SAE 模型由多个稀疏自编码器堆叠而成, 即去除解码层, 当前层 l 的自编码隐藏层输出 $h(l)$ 作为后一层 $l+1$ 的自编码

可视层输入 $x(l+1)$ ，如下式所示：

$$x(l+1) = h(l), l = 1, 2, \dots, n-1 \quad (5)$$

式中： n 为 SAE 模型中自编码器的个数。

电力负荷变化趋势不仅取决于自身特性，还受诸多随机因素尤其气象因素的直接干扰。如气温在气象因素中对负荷影响最大，夏季温度较高，空调等制冷设备导致用电负荷显著增长；而冬季温度越低，用电负荷会因供暖设备的使用反而增加。相对湿度与气温则联合作用于用电负荷，与负荷变化主要呈负相关。此外，由于用电习惯不同，工作日、周末、节假日的负荷水平以及负荷变化趋势也有很大区别。因此，本文 SAE-NN 预测模型的输入除了历史负荷数据外，还包含最高温度、最低温度、湿度和日类型等因素数据。对于实现短期负荷的预测目标而言，需要在 SAE 模型的顶层连接一个用于预测的 LR 模型来构建 SAE-NN，以非线性 sigmoid 神经元作为最后预测模型的输出节点。多输入单输出 SAE-NN 模型结构如图 2 所示。




图2 SAE-NN 模型结构

输入样本 $x(1)$ 经过 SAE 的多次非线性变换得到其 n 阶特征表示 $h(n)$ ，它包含了预测目标中的重要信息；随后以 $h(n)$ 作为输入，通过顶层 LR 模型预测负荷。用 SAE 学习到的深层特征代替初始向量作为预测器的输入，可有效提高网络的泛化性能。

1.3 SAE-NN 模型训练

SAE-NN 模型训练是一种半监督式学习过程，通常采用自下而上的无监督预训练完成 SAE 网络

参数的初始化，再应用自上而下的有监督训练来微调整个网络参数。SAE-NN 的关键在于通过最小化代价函数(4)和(6)的值，不断调整 $\{w, b\}$ 来拟合输入与输出数据之间的函数关系。SAE-NN 的整体代价函数为

$$J(w, b) = \frac{1}{2N} \sum_{i=1}^N (y_i - f_i)^2 + \frac{\lambda}{2} \sum_l \sum_i \sum_j (w_{i,j}(l))^2 \quad (6)$$

式中： y_i 与 f_i 为目标输出值和预测值。

SAE 模型的训练采用逐层贪婪学习算法^[14]，该算法的核心思想在于每次只训练网络中含有一个隐藏层的 AE，当该 AE 达到最优时去除重构可视层，以隐藏层输出作为输入再训练下一个 AE，直到最后一层 AE 最优时完成 SAE 的无监督预训练。在逐层训练过程中，重构数据通过单个 AE 得到一个输出，然后最小化代价函数(4)进行 $\{w, b\}$ 的更新，权值更新规则如下：

$$w_{k+1}(l) = w_k(l) - \alpha \nabla_{w(l)} C_{\text{sparse}}(w, b) \quad (7)$$

$$b_{k+1}(l) = b_k(l) - \alpha \nabla_{b(l)} C_{\text{sparse}}(w, b) \quad (8)$$

式中： $l = 1, 2, \dots, n$ ， k 代表迭代次数， α 为每次迭代的学习步长。

在无监督预训练之后，SAE 模型被赋予初始权值，并结合 LR 模型对整个网络进行有监督参数微调，此时代价函数变为 $J(w, b)$ ， $l = 1, 2, \dots, n+1$ 。通过梯度下降法反复迭代更新参数使 $J(w, b)$ 最小，得到最优 SAE-NN 预测模型。

2 SAE-NN 负荷预测流程

为了提取负荷内在变化特性以及在外在影响因素间的深层关系，本文通过 SAE-NN 深度学习模型进行短期负荷预测，负荷预测框架如图 3 所示。

预测框架主要包括 3 个部分：数据预处理模块、SAE-NN 训练模块和 SAE-NN 预测模块，具体的预测流程如下：

① 对采集到的异常和缺失数据进行修正和填补，将所有的负荷、气象和日类型数据均按式(13)进行 $[0, 1]$ 归一化处理。随后对样本数据进行重构，以满足预测模型的输入输出要求。

$$\bar{x} = \frac{x - x_{\min}}{x_{\max} - x_{\min}} \quad (9)$$

② 以训练样本作为 SAE-NN 模型输入进行特征学习，得到重构后的负荷、气象以及日类型数据

的高阶特征表示, 经过无监督网络预训练和有监督参数微调使预测模型达到最优。

③ 将测试样本输入至最优 SAE-NN 模型中进行短期日负荷预测, 并根据预测结果评估模型性能。

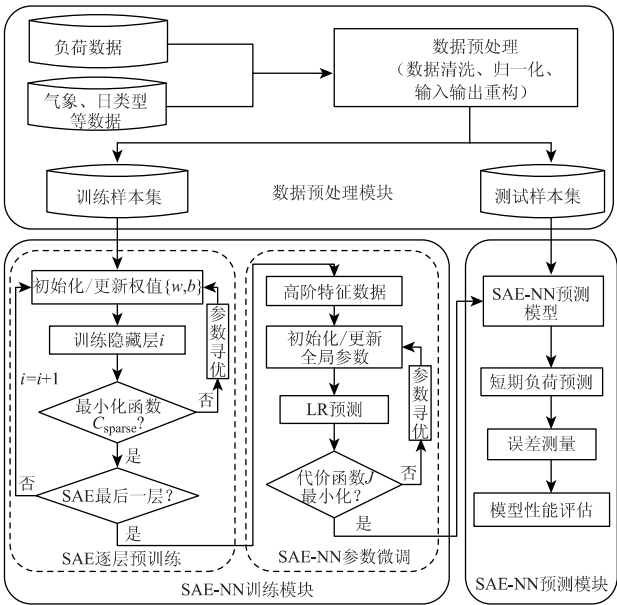


图3 SAE-NN 模型负荷预测框架

3 实例分析

3.1 实验数据集及误差评价指标

实验数据来源于山西电网某地区采集的真实负荷数据和整点天气等影响因素数据, 数据量约为1.5T。将2015年1月1日至12月31日的用电数据作为训练样本, 预测时间分辨率为1h。对样本数据重构来产生输入输出向量, 如表1所示, 其中日类型赋值为{工作日, 周末, 节假日}={1, 2, 3}。

表1 样本数据重构

参数设置	含义
$x_1 \sim x_8$	预测日待测时刻 <i>t</i> 的前8小时历史负荷值
$x_9 \sim x_{14}$	预测日前6天同时刻 <i>t</i> 的历史负荷值
$x_{15} \sim x_{17}$	预测日前3周同星期同时刻 <i>t</i> 的历史负荷值
输入 $x_{18} \sim x_{19}$	预测日和前一天的最高温度
$x_{20} \sim x_{21}$	预测日和前一天的最低温度
$x_{22} \sim x_{23}$	预测日和前一天的平均湿度
x_{24}	预测日日类型
输出 y	预测日 <i>t</i> 时刻的负荷值

对于负荷预测准确度的评价, 本文选取准确率*P*和平均绝对百分比误差 E_{MAPE} 作为评价标准, 即

$$P = \left[1 - \sqrt{\frac{1}{24} \sum_{k=0}^{23} \left(\frac{y_k - f_k}{y_k} \right)^2} \right] \times 100\% \quad (10)$$

$$E_{MAPE} = \frac{1}{24} \sum_{k=0}^{23} \left| \frac{y_k - f_k}{y_k} \right| \times 100\% \quad (11)$$

式中: y_k 和 f_k 是 k 时刻的实际负荷值和预测值。

3.2 预测结果分析

为了从各个方面分析 SAE-NN 深度模型的预测效果, 本文以模糊神经网络(FNN)和SVR浅层模型作为对比算法, 采用多变量滑动窗口机制对不同季节的工作日、周末以及节假日负荷进行多步滚动式预测^[15], 编码实现基于MATLAB_R2013b平台完成。实验中SAE-NN模型包含3个隐藏层, 模型参数设定为 $\lambda=1 \times 10^{-4}$, $\gamma=0.001$, $\alpha=0.3$, $\rho=0.061$ 。表2给出了2017年1月1日至10日冬季负荷的最优预测结果, 图4、图5展示了其中两天的日负荷曲线对比情况。

表2 冬季日负荷预测结果对比

日期	$E_{MAPE}/\%$			$P/\%$		
	SAE-NN	FNN	SVR	SAE-NN	FNN	SVR
01/01	3.96	5.49	4.52	95.2	93.1	94.1
01/02	3.25	3.68	3.76	95.8	95.3	95.1
01/03	3.09	3.67	3.04	95.6	95.0	95.7
01/04	2.35	7.69	3.15	97.0	90.9	95.6
01/05	2.12	3.46	2.81	97.2	95.8	96.5
01/06	2.78	5.07	6.12	96.6	93.8	92.8
01/07	4.46	4.19	5.43	94.3	94.5	93.3
01/08	2.02	5.18	2.76	97.4	93.6	96.8
01/09	3.37	3.62	5.11	96.1	95.7	93.9
01/10	2.94	2.69	3.39	96.3	96.5	95.7
均值	3.03	4.47	4.01	96.2	94.4	95.0

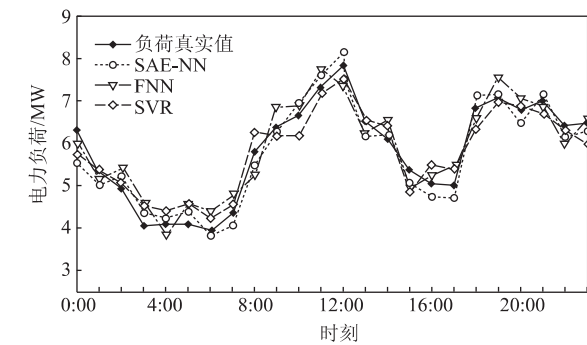


图4 1月1日负荷预测曲线(节假日)




图 5 1 月 4 日负荷预测曲线(工作日)

应用同样方法缩小样本数据集范围, 进行 2015 年 7 月 12 日至 14 日夏季负荷预测, 如图 6 和表 3 所示。

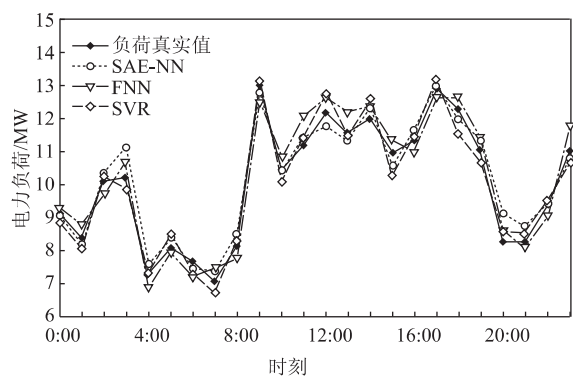


图 6 7 月 12 日负荷预测曲线(周日)

表 3 夏季日负荷预测结果对比

日期	$E_{MAPE}/\%$			$P/\%$		
	SAE-NN	FNN	SVR	SAE-NN	FNN	SVR
07/12	3.23	4.05	3.38	95.6	94.7	95.8
07/13	2.69	3.20	3.04	96.2	95.5	95.9
07/14	2.93	3.41	3.57	96.0	95.6	95.4
均值	2.95	3.55	3.33	95.9	95.3	95.7

由表 2 对比同构 FNN 和 SVR 模型的冬季负荷最优预测结果可知, 所提方法的综合预测效果明显更好, 其预测精度达到 96.2%, 比 FNN 和 SVR 模型分别高出 1.8 和 1.2 个百分点, 而预测误差也相对较低, 降至 3.03%。结合图 4 发现, 3 种方法对节假日负荷预测效果都不够理想, 误差皆超过 3%, 主要原因是节假日属于特殊日, 数据样本较少, 用户行为的随机性严重干扰了负荷走势, 但 SAE-NN 模型仍能通过有限样本的深层学习挖掘出负荷潜在变化特性, 保持相对较低的预测误差。当

然, SAE-NN 在对工作日负荷进行预测时, 预测值与实际值的整体偏离程度最小, 可有效捕捉负荷序列高频分量极值点, 具有更高的预测精度。纵观 10 天的冬季日负荷预测误差, SAE-NN 模型超过 4% 只出现 1 次, 其余日误差均在 3% 上下浮动, 而 FNN 和 SVR 分别达到 5 次和 4 次, 波动较为明显, SAE-NN 深度模型具有更好的泛化性能。同时, 表 3 和图 6 的结果表明 SAE-NN 模型对夏季负荷的预测也能得到较高的预测精度, 可全面适用于不同季节、不同日类型负荷的预测。

此外, 为进一步验证 SAE-NN 模型在样本集不断扩充情况下的适应能力, 设定 2015 年 11 月至 12 月的重构负荷和气象等数据作为初始学习集, 信息容量为 744 条, 并以 1 个月的数据量为步长递增, 共分为 11 组样本集, 规模上限为 8016。图 7 和表 4 分别给出了 3 种预测模型在 11 组学习集上的冬季负荷预测精度与训练时间变化情况。




图 7 预测精度随样本集规模变化情况对比

表 4 预测模型训练时间对比 min

样本集	训练时间			样本集	训练时间		
	SAE-NN	FNN	SVR		SAE-NN	FNN	SVR
1	67.5	3.2	2.1	7	406.9	29.5	24.6
2	119.3	6.8	4.9	8	447.5	33.9	30.6
3	163.0	11.6	7.5	9	504.3	37.6	38.5
4	215.8	16.5	10.8	10	568.7	40.2	47.1
5	276.1	20.3	15.2	11	619.2	45.7	58.3
6	335.4	24.4	19.7				

从图 7 中发现当样本集规模较小时, SVM 预测精度较高, SAE-NN 预测精度最差, 勉强达到 85%。当样本规模达到 6 个月时, FNN 预测精度最高为 94.4%, 但此后和 SVR 一样逐渐衰减, 最终分别维持在 84% 和 88% 上下。而 SAE-NN 从第 3 组样本开始预测准确率稳步上升, 最终保持在

94%以上。通过对比可知,SVR 和 FNN 浅层模型在数据集较大时容易出现过拟合产生较大的泛化误差,SAE-NN 深度模型则凭借独特的逐层特征提取能力具备良好的增量学习特性,信息利用更充分,预测稳定性较强,非常适用于负荷数据流的大规模挖掘处理。然而,对比表 4 中的训练时间发现,SAE-NN 的耗时明显高出其他两种浅层模型,在全样本集下已超过 10 h,其工程适用性较差。因此,所提模型的训练效率有待进一步优化。

4 结束语

电力系统数据的海量化趋势为负荷特性分析和高质量的预测模型建立奠定了基础,但经典浅层学习模型由于对复杂函数的表达能力有限,大样本集下的过拟合问题反而会降低预测精度。因此,本文将深度学习引入负荷预测领域,针对电力负荷非线性特点,同时考虑温度、湿度等气象因素,建立一种栈式自编码深度预测模型。该模型有效克服了因梯度弥散而陷入局部最优的缺陷,经过逐层提取负荷、气象数据间隐含的非线性特征,挖掘出负荷数据流的深层变化规律,以实现对未来负荷的预测。实验结果表明,本文提出的预测模型具有明显的增量学习特性,预测精度更高,泛化性能较强。在今后工作中,将不断深入这方面的研究,构建更高层级的多输入多输出深度学习网络,并优化寻优算法降低模型复杂度和训练时间,同时考虑结合多种顶层预测器实现预测。

参 考 文 献

- [1] Amjady N. Short-term hourly load forecasting using time series modeling with peak load estimation capability [J]. IEEE Transactions on Power Systems, 2001, 16(4): 798-805.
- [2] 马坤隆. 基于大数据的分布式短期负荷预测方法 [D]. 长沙: 湖南大学, 2014.
- [3] 廖旋煥, 胡智宏, 马莹莹, 等. 电力系统短期负荷预测方法综述 [J]. 电力系统保护与控制, 2011, 39(1): 147-152.
- [4] 徐培, 蔡小路, 何文伟, 等. 基于深度自编码网络的运动目标检测 [J]. 计算机应用, 2015, 30(8): 2934-2937.
- [5] 李龙, 魏靖, 黎灿兵, 等. 基于人工神经网络的负荷模型预测 [J]. 电工技术学报, 2014, 31(3): 225-230.
- [6] 杨再鹤, 向铁元, 郑丹. 基于小波变换和 SVM 算法的微电网短期负荷预测研究 [J]. 现代电力, 2014, 31(3): 74-79.
- [7] Jorjeta G J, Mostafa M, Chen Weipeng. Neural network model ensembles for building-level electricity load forecasts [J]. Energy and Buildings, 2014, 84: 214-223.
- [8] 吴潇雨, 和敬涵, 张沛, 等. 基于灰色投影改进随机森林算法的电力系统短期负荷预测 [J]. 电力系统自动化, 2015, 39(12): 50-55.
- [9] 吴倩红, 高军, 侯广松, 等. 实现影响因素多源异构融合的短期负荷预测支持向量机算法 [J]. 电力系统自动化, 2016, 40(15): 67-72.
- [10] Huang W, Song G, Hong H, et al. Deep architecture for traffic flow prediction: deep belief networks with multitask learning [J]. IEEE Transactions on Intelligent Transportation Systems, 2014, 15(5): 2191-2201.
- [11] 罗向龙, 焦青青, 牛力瑶, 等. 基于深度学习的短时交通流预测 [J]. 计算机应用研究, 2017, 34(1): 91-93.
- [12] Qu X, Kang X, Zhang C, et al. Short-Term Prediction of Wind Power Based on Deep Long Short-Term Memory [C] //Power and Energy Engineering Conference (APPEEC). Xi'an: IEEE, 2016: 1148-1152.
- [13] 寇茜茜, 何希平. 基于栈式自编码器模型的汇率时间序列预测 [J]. 计算机应用与软件, 2017, 34(3): 218-222.
- [14] Hinton G E, Osindero S Y W. The A fast learning algorithm for deep belief nets [J]. IEEE Transactions on Intelligent Transportation Systems, 2014, 15(5): 2191-2201.
- [15] 严干贵, 王东, 杨茂, 等. 两种风电功率多步预测方式的分析及评价 [J]. 东北电力大学学报, 2013, 33(z1): 126-130.

收稿日期: 2017-06-19

作者简介:

吴润泽(1975—), 女, 博士, 副教授, 研究方向为智能电网大数据技术研究, E-mail: wurz@ncepu.edu.cn;

包正睿(1992—), 男, 硕士研究生, 研究方向为面向智能电网应用的大数据关键技术和电力负荷预测, E-mail: baozr_ncepu@163.com.

(责任编辑: 杨秋霞)