

大用户电力负荷的多模型模糊综合预测

谷云东¹ 张素杰¹ 冯君淑²

(1. 华北电力大学数理学院 北京 102206

2. 华北电力大学电气与电子工程学院 北京 102206)

摘要 研究大用户的短期电力负荷预测问题,给出一种基于变权综合模糊推理的多模型综合预测方法。该方法首先引入基于质心相似度聚类的负荷模式分析算法,挖掘历史负荷数据中合群的典型负荷模式,并按相似性进行分组,同时剔除少量的离群异常记录;然后给出基于共轭梯度的 RBF 神经网络训练算法,分别对每类典型负荷模式建立相应的单元预测模型;最后利用基于相似度加权的多模型变权综合模糊推理策略,实现各单元模型预测结果的自适应融合。案例仿真验证了多模型模糊综合预测方法的可靠性。

关键词: 大用户负荷预测 质心相似度聚类 RBF 神经网络 多模型模糊综合预测 模糊推理
中图分类号: TM76

Multi-model Fuzzy Synthesis Forecasting of Electric Power Loads for Larger Consumers

Gu Yundong¹ Zhang Sujie¹ Feng Junshu²

(1. School of Mathematics and Physics North China Electric Power University Beijing 102206 China

2. School of Electrical and Electronic Engineering North China Electric Power University
Beijing 102206 China)

Abstract A multi-model based variable weighted fuzzy synthesis forecasting method is proposed for the power load forecasting of large consumers. A clustering algorithm based on Renyi-entropy and centroid similarity is introduced to mining typical load patterns from historical load data and grouping them according to similarities as well as detecting atypical outliers. A conjugate gradient based learning algorithm for the RBF neural network is designed to construct unit forecasting model for each group of typical load patterns. Then, the forecasting results of all unit models are integrated adaptively by using variable weighted fuzzy synthesis inference. The simulation results show that the multi-model fuzzy synthesis forecasting method can raise the prediction accuracy and stability significantly.

Keywords: Electric power load forecasting for large consumers, centroid similarity based clustering, RBF neural network, multi-model fuzzy synthesis forecasting, fuzzy reasoning

0 引言

随着我国电力改革的深入,大用户直购直供逐渐被提上议程。所谓大用户通常是指钢铁、水泥、炼铝等高能耗工矿企业用户,其用电量超过一定规模,成

本支出中电费占很大比例,并经常在其所在地区电力负荷中占有较大比重^[1-6]。随着国民经济发展和产业结构调整,企业设备逐步向大容量、高参数自控设备升级,从而导致电压等级较高、负荷较大的大用户的数量明显增加,其重要性也日益增强。大用户负荷受企业的生产工艺和生产计划影响,负荷变化剧烈,随机性强,易对电网的稳定有效运行形成较大冲击。及时准确的大用户负荷预测是优化供、配电结构,提高

国家自然科学基金(71171080)和中央高校基本科研业务费专项资金(12MS84、2015MS51)资助项目。

收稿日期 2015-01-05 改稿日期 2015-08-12

电网效益,并合理应对大用户电力负荷变化对电网造成破坏性冲击的基础。因此,研究大用户电力负荷预测对电力系统保护与控制(即保护电网安全)以及控制电网稳定、经济、高效运行,具有重要的现实意义。学者们围绕大用户电力负荷模式识别和负荷预测进行了大量研究^[5-8]。李扬等^[1]研究了大工业用户对峰谷分时电价的响应情况。史新祁等^[2]在分析大型钢铁企业的电力负荷特点的基础上,提出一种人工神经网络与小波变换相结合短期负荷预测模型。G. J. Tsekouras等^[5]研究了大用户电力负荷模式的识别和评价问题。蔡剑彪等^[6]讨论了大用户负荷预测管理系统的设计。黄宇腾等^[7]讨论了面向需求侧管理的用户负荷形态分析问题。

大用户电力负荷较少受气候、天气和节假日等因素的影响,但与企业的生产工艺和生产计划直接相关,变化剧烈,随机性强。因此,大用户电力负荷预测较一般的负荷预测更为复杂。为解决负荷预测上普遍存在预测准确度不够高、预测性能不够稳定的问题,学者们尝试利用优化技术改进已有模型^[9,10],并提出多模型组合的预测思路^[11-16]及基于区间值模糊逻辑的新预测方法^[17-19]。与基于历史数据分析的时间序列分析、人工神经网络、小波分析、支持向量回归、非参数自回归和灰色系统等传统的单模型预测方法相比,使用优化技术的改进型负荷预测方法能够显著改善预测准确率,但仍存在使用信息有限、易陷入局部极值以及参数优化过程复杂且难以重复等不足。多模型综合预测方法为多个角度、多个层次解读并充分利用已知信息提供了可能,有望获得更高的预测准确度和更强的泛化能力。许甜田^[3]给出一种粒子群优化和SVM相结合的预测方法,并分别用灰色模型、BP神经网络、广义回归神经网络和灰色神经网络对大用户负荷进行单独预测和综合预测仿真。结果表明,多模型综合预测可有效改善预测性能。事实上,多模型组合的预测方法引起学者们越来越多的关注^[12-16,20,21]。

本文研究了面向大型工业用户的电力负荷预测问题,给出了一种基于负荷模式分类的多模型模糊综合预测方法。首先介绍了大用户电力负荷及其特点;然后给出了大用户负荷的基于改进RBF神经网络的多模型模糊综合预测方法;最后对某工业用户的日负荷曲线进行了实例分析,验证了新方法的可行性,并测试了评估其性能。

1 大用户电力负荷及其特点

从系统组成的角度分析,电网整体负荷可以看做

是由数量较少但用电量巨大的大用户和数量众多但用电量较小的小用户共同组成。大用户易受自身设备运行状态的影响,负荷变化剧烈、波动大(如图1所示),易对电网稳定性形成较大冲击,但其用电较为集中,部分负荷具有一定程度的可转移性,便于规划;而小用户数量巨大但单户负荷较小,因此负荷波动较小,变化较平缓,但其用电分散,难以规划。因此,研究大用户负荷需求特点,并对其进行较为准确的预测,不仅有助于更好地引导用(发)电企业设计实施更合适的用(发)电计划,同时能为电力高效配置和调度提供有效的依据,提高电力网络系统的安全稳定性和电网效益。但考虑到大用户电力负荷变化快、波动大的特点,常用的单模型预测方法难以取得理想的预测效果,本文提出一种基于负荷模式分类建模的多模型自适应变权模糊综合预测方法。




图1 某工业用户2011年7月1日~7日负荷曲线

Fig. 1 The load curve of an industrial user during July 1-7 2011

2 大用户负荷的多模型变权模糊综合预测

下面给出基于改进RBF神经网络的分类多模型变权模糊综合预测模型。

2.1 主要思路

如图2所示,基于负荷模式分类的多模型变权模糊综合预测方法主要包括4个环节:首先,给出基于质心相似度聚类的负荷模式分析算法,借助该算法可剔除少量的离群异常数据,得到反映用户负荷模式特点的典型负荷模式,并依据相似性进行分组;然后,给出基于共轭梯度的神经网络学习算法,分别训练RBFNN建立与各典型负荷模式分组相对应的单元子预测模型;接着给出一种基于相似度的子模型定权方法;最后,采用变权综合模糊推理方法集成各子模型预测结果,得到大用户负荷预测值。

2.2 基于质心相似聚类的异常负荷识别与分类

作为负荷预测的基础,负荷模式的辨识分析一直是电力系统研究的重要内容之一。2010年,G. Chicco等^[22,23]将基于Renyi熵的质心相似度聚类(Centroid

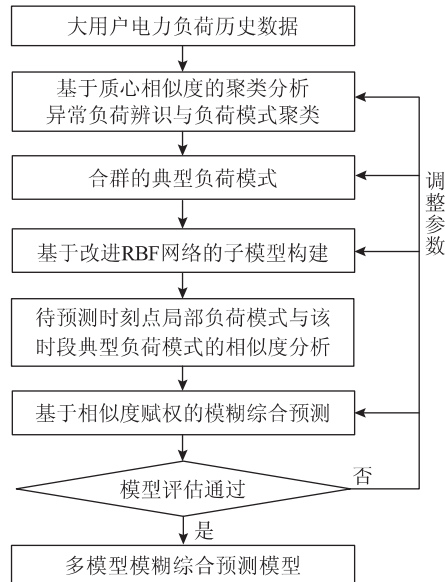


图 2 多模型模糊综合预测模型

Fig. 2 Multi-model fuzzy synthesis forecasting model

Similarity-based Clustering, CSC) 方法应用于典型负荷模式的识别分类以及异常负荷模式的发现,取得了很好的效果。因此,本文将该算法应用于大用户电力负荷数据的处理,给出一种基于质心相似度聚类的负荷模式分析算法。该算法可实现异常负荷识别和典型负荷模式发现及分类。

考虑负荷模式数据 $X = \{x_m \in R^d, m = 1, \dots, M\}$, 其中 M 为记录条数。设 M 条负荷数据分成 K 个类, 类 $C_k \subset X$ 包括 N_k 条记录, 则其质心

$$c_k = \{c_{k1}, \dots, c_{kd}\} = \frac{1}{N_k} \sum_{m=1}^M x_m \quad k = 1, 2, \dots, K$$

定义簇间熵

$$H = - \left\{ \log \left[\sum_{i=1}^M \sum_{j=1}^M b(x_i, x_j) G(x_i - x_j, \Sigma_x) \right] - \log \left(2 \prod_{k=1}^K N_k \right) \right\}$$

式中: $b(x_i, x_j)$ 在 x_i, x_j 属于不同簇时取值为 1, 其他情况取值为 0; Σ_x 为 d 维的对角矩阵, 其对角线元素为数据 x_{it} 的方差 $\sigma_{it}^2, t = 1, 2, \dots, d$ 。定义两个负荷模式之间的相似度为

$$s_{ij} = G(x_i - x_j, \Sigma_x) \quad (1)$$

两个负荷模式类之间的相似度为

$$s_{C_i, C_j} = \frac{1}{N_i N_j} \sum_{x_i \in C_i} \sum_{x_j \in C_j} G(x_i - x_j, \Sigma_x) \quad (2)$$

式中

$$G(x_i - x_j, \Sigma_x) = \frac{\exp \left[-\frac{1}{2} (x_i - x_j)^T \Sigma_x^{-1} (x_i - x_j) \right]}{\sqrt{(2\pi)^d \det(\Sigma_x)}} \quad (3)$$

基于上述分析, 给出基于质心相似度聚类的负荷模式分析算法如下:

1) 设经过数据预处理得到历史负荷数据集 $X = \{x_m \in R^d, m = 1, \dots, M\}$, 计算对角方差矩阵 Σ_x 。

2) 设定聚类数 K , 利用基于 Renyi 熵的聚类算法对当前历史负荷数据进行聚类。

3) 类内离群点识别。

(1) $k = 1$;

(2) 计算类 C_k 的质心 c_k , 类内各数据与类质心 c_k 的相似度 s_{ik} (其中 $i = 1, 2, \dots, N_k$) 及其类均值 $\bar{s}_k = \frac{1}{N_k} \sum_{x_i \in C_k} s_{ik}$, 方差 $\sigma_k = \frac{1}{N_k} \sum_{x_i \in C_k} (s_{ik} - \bar{s}_k)^2$;

(3) 对 $1 \leq i \leq N_k$, 若 $s_{ik} \geq \bar{s}_k + \tau \sigma_k$, 则判定 x_i 为离群异常数据, 令 $C_k = C_k \setminus \{x_i\}$, 返回步骤 (2), 其中 $\tau \geq 1$ 为识别参数;

(4) 若 $k \leq K, k = k + 1$, 返回步骤 (2); 否则结束。

借助基于质心相似度的聚类算法可剔除历史负荷数据中的异常负荷, 得到可用于预测的典型负荷模式, 并对其进行分组。下面研究预测子模型的构建问题, 给出一种基于共轭梯度的 RBF 神经网络学习算法。

2.3 基于共轭梯度的 RBF 学习算法

作为一种常用的神经网络模型, RBF 网络具有拓扑结构简单以及学习速度快的特点。RBF 神经网络中中心分量 $c_{ji}(t)$ 、宽度 $d_{ji}(t)$ 等参数的选择直接影响预测性能。目前的 RBF 学习算法通常采用梯度法对参数进行训练学习。但梯度法存在学习速度慢及准确度不高等缺陷, 而共轭方向法具有二次终止性, 其内存需要量小、计算简便、易实现。因此, 本文给出一种改进的基于共轭梯度的 RBF 神经网络学习算法, 具体步骤如下。

1) 对神经网络参数进行初始化。设定隐含层和输出层神经元个数 p 和 q , 利用随机数对网络参数进行初始赋值, 确定迭代终止精度 ε 或迭代最大次数 N , 置迭代次数 $n = 1$ 。

2) 计算隐含层和输出层神经元的输出。

$$z_j = \exp \left(- \left\| \frac{X - C_j}{D_j} \right\|^2 \right) \quad j = 1, 2, \dots, p$$

$$y_k = \sum_{j=1}^p w_{kj} z_j \quad k = 1, 2, \dots, q$$

3) 计算网络输出的均方根误差。

$$\text{RMS} = \sqrt{\frac{1}{qN} \sum_{l=1}^N \sum_{k=1}^q (O_{lk} - y_{lk})^2}$$

若 $\text{RMS} \leq \varepsilon$, 则训练结束; 否则, 转到步骤4)。

4) 迭代计算, 调节权重、中心和宽度参数。

$$\begin{aligned} w_{kj}(t) &= w_{kj}(t-1) + \eta g_{w_{kj}(t)}(t-1) + \alpha [w_{kj}(t-1) - w_{kj}(t-2)] \\ c_{ji}(t) &= c_{ji}(t-1) + \eta g_{c_{ji}(t)}(t-1) + \alpha [c_{ji}(t-1) - c_{ji}(t-2)] \\ d_{ji}(t) &= d_{ji}(t-1) + \eta g_{d_{ji}(t)}(t-1) + \alpha [d_{ji}(t-1) - d_{ji}(t-2)] \end{aligned}$$

其中下降搜索方向分别为

$$\begin{aligned} g_{w_{kj}(t)}(1) &= -\frac{\partial E}{\partial w_{kj}(1)} \\ g_{w_{kj}(t)}(t-1) &= -\frac{\partial E}{\partial w_{kj}(t-1)} + g_{w_{kj}(t)}(t-2) \frac{\left\| \frac{\partial E}{\partial w_{kj}(t-1)} \right\|^2}{\left\| \frac{\partial E}{\partial w_{kj}(t-2)} \right\|^2} \\ g_{c_{ji}(t)}(1) &= -\frac{\partial E}{\partial c_{ji}(1)} \\ g_{c_{ji}(t)}(t-1) &= -\frac{\partial E}{\partial c_{ji}(t-1)} + g_{c_{ji}(t)}(t-2) \frac{\left\| \frac{\partial E}{\partial c_{ji}(t-1)} \right\|^2}{\left\| \frac{\partial E}{\partial c_{ji}(t-2)} \right\|^2} \\ g_{d_{ji}(t)}(1) &= -\frac{\partial E}{\partial d_{ji}(1)} \\ g_{d_{ji}(t)}(t-1) &= -\frac{\partial E}{\partial d_{ji}(t-1)} + g_{d_{ji}(t)}(t-2) \frac{\left\| \frac{\partial E}{\partial d_{ji}(t-1)} \right\|^2}{\left\| \frac{\partial E}{\partial d_{ji}(t-2)} \right\|^2} \end{aligned}$$

其中偏导数分别为

$$\begin{aligned} \frac{\partial E}{\partial w_{kj}(t-1)} &= (y_k(t-1) - O_k) z_j \\ \frac{\partial E}{\partial c_{ji}(t-1)} &= -\frac{2w_{kj}(t-1)}{d_j^2(t-1)} \|X - C_j\| (y_k(t-1) - O_k) z_j \\ \frac{\partial E}{\partial d_{ji}(t-1)} &= \frac{2w_{kj}(t-1)}{d_j^3(t-1)} \|X - C_j\|^2 (y_k(t-1) - O_k) z_j \end{aligned}$$

5) 若 $n \geq N$, 则训练结束; 否则, $n = n + 1$, 返回步骤2)。

2.4 基于相似度的子模型权重确定

基于多模型模糊综合推理的负荷预测模型中, 子模型权重的确定是一个重要问题。本文给出一种基于相似度分析的定权方法, 即根据待预测时刻输入和各个子模型相对应的典型负荷模式类相应输入之间的相似度分析来确定子模型权重。

设待预测时刻输入 $x = (x_1, x_2, \dots, x_d)$ 到第 j 类典型负荷模式类中心 c_j 的相似度为

$$r_{xj} = \left(1 + \frac{1}{d} \sum_{h=1}^d q_h (x_h - c_{jh})^2 \right)^{-1}$$

则第 j 子模型权重为

$$w_{xj} = \frac{r_{xj}}{\sum_{j=1}^c r_{xj}} \quad j = 1, 2, \dots, c$$

式中 q_h 为待预测时刻输入数据第 h 个分量的权重, 按照近大远小的原则可取 $q_h = 1 - \frac{h-1}{d}$ 。

容易看出, 这里的子模型权重 w_{xj} 不是固定不变的常数, 而是一种与待预测时刻输入 x 有关、能够随 x 与各类中心相似度的不同而自适应调整变化的“变权”。借助“变权综合”可以实现“越相似者贡献越大”的多模型自适应融合。

2.5 基于多模型模糊综合推理的大用户负荷预测

基于上述分析, 可给出面向大用户负荷预测的分类多模型变权综合模糊推理预测算法如下:

- 1) 数据预处理, 得到规范统一的大用户历史日负荷记录。
- 2) 利用基于质心相似度聚类的负荷模式分析算法, 剔除离群的异常负荷数据, 得到反映负荷变化规律的典型负荷模式, 并分组。
- 3) 对各典型负荷模式类, 使用基于共轭梯度的 RBF 神经网络学习算法, 训练神经网络, 建立预测子模型。
- 4) 计算待预测时刻负荷模式到各典型负荷模式类之间的相似度, 并据此确定各子模型的权重。
- 5) 采用基于变权综合的模糊推理方法融合各子模型预测值, 得到模糊综合预测结果。

3 实例分析

结合某工业用户的日负荷数据进行实例分析, 验证方法的有效性。

3.1 数据选择和预处理

选取山东某工业企业, 夏季从6月1日~9月30日(共122天)每天0:00~23:00的数据。首先, 将上述120条数据进行标准化; 然后, 按照基于质心相似度聚类的负荷模式分析算法识别异常负荷数据, 并将其聚类, 得到5类典型负荷模式, 并剔除3条异常的负荷数据, 其对应的日期分别是: 6月19日, 7月11日, 8月22日。

3.2 实验设计

将选出的5类典型负荷模式数据分别随机分为大致均匀的6部分, 选择其中5份作为训练数据, 一份作为测试数据, 进行6折交叉确认。利用改进的基于共轭梯度的训练算法, 训练 RBF 神经网络建立对应各类典型负荷模式的预测子模型。设置网络学习最大次

数为 50 000 次,期望误差限为 0.1。学习完成后,以 9 月 27 日的日负荷预测为例,进行预测分析。

3.3 实验结果及分析

为保证算法评估的有效性,运行算法 50 次,取其预测平均值作为最终预测值,其结果如图 3 所示。




图 3 单模型与多模型模糊综合预测的比较

Fig. 3 The comparison of forecasting between the single-model and multi-model fuzzy synthesis

由图 3 可看出,多模型模糊综合预测方法较单一模型预测方法能更有效地反映电力负荷数据的变化趋势,预测准确性更高。事实上,预测的最大相对预测误差从 5.87% 下降到 3.49%,相对误差绝对值均值从 3.12% 下降到 2.32%,方均误差(MSE)从 119.3 下降为 82.6。为更直观地分析两者的差异,绘制相对误差分布直方图如图 4 所示。




图 4 单模型预测与多模型模糊综合预测的误差比较

Fig. 4 The comparison of error between the single-model forecasting and multi-model fuzzy synthesis forecasting

由图 4 可看出,多模型综合预测的误差分布较单一模型预测存在明显差异。通常单一模型预测相对误差变化较大,且误差分布有在负荷变化较大的负荷峰、谷附近集中的趋势。但对于多模型模糊综合预测而言,预测误差变化较小,其分布更均匀。换言之,多模型综合方法可有效平抑误差波动。综上所述,与传统单一模型预测算法相比,多模型模糊综合预测的准确性和稳定性均有显著提高。

4 结论

本文研究了大用户电力负荷预测问题,构建了基于改进 RBF 神经网络和变权综合模糊推理的大用户负荷需求多模型模糊综合预测模型。实例分析表明,基

于共轭梯度的新训练算法有效提高了 RBF 神经网络学习过程的收敛速度和预测准确度。今后,可进一步研究面向需求侧管理的负荷形态分析^[7]和主动负荷与分布式电源的互动响应行为分析^[8]等问题。

参考文献

- [1] 李扬,王治华,卢毅,等. 峰谷分时电价的实施及大工业用户的响应[J]. 电力系统自动化,2001,25(8): 45-48.
Li Yang, Wang Zhihua, Lu Yi, et al. The implementation of peak and valley time price for electricity and response of large industries[J]. Automation of Electric Power Systems, 2001, 25(8): 45-48.
- [2] 郑静,杜秀华,史新祁. 大型钢铁企业电力负荷短期预测的研究[D]. 电力需求侧管理,2004,6(1): 18-21.
Zheng Jing, Du Xiuhua, Shi Xinqi. Research on short term load forecasting in steel enterprise[J]. Power Demand Side Management, 2004, 6(1): 18-21.
- [3] 许甜田. 大用户负荷预测方法研究及其应用[D]. 长沙: 湖南大学,2013.
- [4] 康重庆,夏清,张伯明. 电力系统负荷预测研究综述与发展方向的探讨[J]. 电力系统自动化,2004,17(17): 1-9.
Kong Chongqing, Xia Qing, Zhang Bomeng. Review of power system load forecasting and its development[J]. Automation of Electric Power Systems, 2004, 17(17): 1-9.
- [5] Tsekouras G J, Kotoulas P B, Tsirekis C D, et al. A pattern recognition methodology for evaluation of load profiles and typical days of large electricity customers[J]. Electric Power Systems Research, 2008, 78(9): 1494-1510.
- [6] 蔡剑彪,罗滇生,周小宝,等. 大用户负荷预测管理系统[J]. 电力需求侧管理,2012,14(4): 7-10, 24.
Cai Jianbiao, Luo Diansheng, Zhou Xiaobao, et al. Load forecasting management system about large consumer[J]. Power Demand Side Management, 2012, 14(4): 7-10, 24.
- [7] 黄宇腾,侯芳,周勤,等. 一种面向需求侧管理的用户负荷形态组合分析方法[J]. 电力系统保护与控制,2013(13): 20-25.
Huang Yuteng, Hou Fang, Zhou Qin, et al. A new combinational electrical load analysis method for demand side management[J]. Power System Protection and Control, 2013(13): 20-25.

- [8] 程瑜, 安甦. 主动负荷互动响应行为分析[J]. 电力系统自动化, 2013, 37(20): 63-70.
Cheng Yu, An Su. Analysis of active load's interaction response behavior[J]. Automation of Electric Power Systems, 2013, 37(20): 63-70.
- [9] 肖白, 徐潇, 穆钢, 等. 空间负荷预测中确定元胞负荷最大值的概率谱方法[J]. 电力系统自动化, 2014(21): 47-52.
Xiao Bai, Xu Xiao, Mu Gang, et al. A possibility spectrum method for ascertaining maximal value of cellular load in spatial load forecasting[J]. Automation of Electric Power Systems, 2014(21): 47-52.
- [10] Duan Pan, Xie Kaigui, Guo Tingting, et al. Short-term load forecasting for electric power systems using the PSO-SVR and FCM clustering techniques[J]. Energies, 2011, 4(1): 173-184.
- [11] 周淦, 邓景云, 任海军, 等. 基于蚁群算法的配电网空间负荷预测方法研究[J]. 电力系统保护与控制, 2010, 38(24): 99-104.
Zhou Quan, Deng Jingyun, Ren Haijun, et al. Research on spatial load forecast of distribution networks based on ant colony algorithm[J]. Power System Protection and Control, 2010, 38(24): 99-104.
- [12] Thordarson F O, Madsen H, Nielsen H A, et al. Conditional weighted combination of wind power forecasts[J]. Wind Energy, 2010, 13(8): 751-763.
- [13] Germi, M B, Mirjavadi M, Namin A S S, et al. A hybrid model for daily peak load power forecasting based on SAMBA and neural network[J]. Journal of Intelligent & Fuzzy Systems, 2014, 27(2): 913-920.
- [14] 牛东晓, 魏亚楠. 基于 FHNN 相似日聚类自适应权重的短期电力负荷组合预测[J]. 电力系统自动化, 2013, 37(3): 54-57.
Niu Dongxiao, Wei Yanan. Short-term power load combinatorial forecast adaptive weighted by FHNN similar-day clustering[J]. Automation of Electric Power Systems, 2013, 37(3): 54-57.
- [15] Taylor J W. Short-term load forecasting with exponentially weighted methods[J]. IEEE Transactions on Power Systems, 2012, 27(1): 458-464.
- [16] Borges C E, Penya Y K, Fernandez I. Evaluating combined load forecasting in large power systems and smart grids[J]. IEEE Transactions on Industrial Informatics, 2013, 9(3): 1570-1577.
- [17] Yao Lan, Jiang Yulian, Xiao Jian. Short-term power load forecasting by interval type-2 fuzzy logic system[J]. Information Computing and Applications, 2011, 244: 575-582.
- [18] Khosravi A, Nahavandi S, Creighton D. et al. Interval type-2 fuzzy logic systems for load forecasting: a comparative study[J]. IEEE Transactions on Power Systems, 2012, 27(3): 1274-1282.
- [19] Quan H, Srinivasan D, Khosravi A. Short-term load and wind power forecasting using neural network-based prediction intervals[J]. IEEE Transactions on Neural Networks and Learning Systems, 2014, 25(2): 303-315.
- [20] 罗滇生, 姚建刚, 何洪英, 等. 基于自适应滚动优化的电力负荷多模型组合预测系统的研究与开发[J]. 中国电机工程学报, 2003, 23(5): 58-61.
Luo Diansheng, Yao Jiangang, He Hongying, et al. Research and development of multi-model combining load forecasting system based on self-adaptive rolling optimization[J]. Proceedings of the CSEE, 2003, 23(5): 58-61.
- [21] 谢开贵, 李春燕, 周家启, 等. 基于神经网络的负荷组合预测模型研究[J]. 中国电机工程学报, 2002, 22(7): 85-89.
Xie Kaigui, Li Chunyan, Zhou Jiaqi, et al. Research of the combination forecasting model for load based on artificial neural network[J]. Proceedings of the CSEE, 2002, 22(7): 85-89.
- [22] Chicco G, Akilimali J S. Renyi entropy based classification of daily electrical load patterns[J]. IET Generation, Transmission & Distribution, 2010, 4(6): 736-745.
- [23] Chicco G, Ionel O M, Porumb R. Electrical load pattern grouping based on centroid model with ant colony clustering[J]. IEEE Transactions on Power Systems, 2013, 28(2): 1706-1715.

作者简介

谷云东 男, 1976 年生, 博士, 副教授, 研究方向为模糊系统建模、评估与优化决策等。(通信作者)

张素杰 女, 1991 年生, 硕士研究生, 研究方向为模糊系统建模与优化等。