

考虑温度因素的中期电力负荷概率密度预测方法

何耀耀¹, 闻才喜¹, 许启发¹, 撒奥洋²

(1. 过程优化与智能决策教育部重点实验室(合肥工业大学), 安徽省 合肥市 230009;

2. 山东电力集团 青岛供电公司调控中心, 山东省 青岛市 266300)

A Method to Predict Probability Density of Medium-Term Power Load Considering Temperature Factor

HE Yaoyao¹, WEN Caixi¹, XU Qifa¹, HAN Aoyang²

(1. Key Laboratory of Process Optimization and Intelligent Decision-Making (Hefei University of Technology),
Ministry of Education, Hefei 230009, Anhui Province, China; 2. Qingdao Power Supply Company Control Center,
Shandong Electric Power Group, Qingdao 266300, Shandong Province, China)

ABSTRACT: In allusion to the influence of temperature factor on medium-term power load, based on exiting neural network prediction, interval prediction and probability density prediction the influences of temperatures and historical loads at different quantiles on the distribution rule of power system medium-term load is researched and a method to predict neural network quantile regression based medium-term probability density of power load is proposed. According to continuous conditional quantile functions the probability density of medium-term power load on a certain day is predicted to obtain more information related to medium-term power load. Meanwhile, the comparison results of conditional probability density prediction curves, in which the temperature factors are considered and not considered respectively, and the prediction values corresponding to peak load points show that the temperature at the very predicted day evidently influences the predictive result of medium-term power load, so it offers more decision information and prediction results, in which the uncertain factors in medium-term power load prediction are decreased.

KEY WORDS: temperature; probability density prediction; neural network quantile regression; medium-term load

摘要: 针对温度因素对中期电力负荷的影响,在现有的神经网络预测、区间预测和概率密度预测方法的基础上,研究在不同分位点上温度和历史负荷对电力系统中期负荷分布规律的影响,提出基于神经网络分位数回归的中期电力负荷概率密度预测方法。根据连续的条件分位数函数预测中期负荷在某天的概率密度,获得更多关于中期负荷预测信息。同时,

通过比较在考虑温度因素下和不考虑温度因素下的条件概率密度预测曲线以及峰值对应的点预测值,可以得出,预测当天温度对中期负荷预测有较重要的影响,这为降低中期电力负荷预测的不确定因素提供了更多的决策信息和预测结果。

关键词: 温度; 概率密度预测; 神经网络分位数回归; 中期负荷

DOI: 10.13335/j.1000-3673.pst.2015.01.027

0 引言

电力系统负荷预测是指从电力负荷自身的变化规律以及季节、温度、电价等因素的影响出发,通过对历史数据的分析和研究,对电力需求做出预先的估计和推测^[1]。但电力负荷预测的不确定性和受多因素干扰的情况,给电力系统内部进行电力负荷预测增加了难度和随机性,也给电力系统内部进行调度、计划等工作带来很大不利影响^[2]。近年来,为了提高电网运行的安全性和效益性,对电力负荷预测的精度要求不断提高^[3-4]。随着现代计算机技术的不断发展,人工智能方法^[1]、神经网络^[5]、模糊聚类^[6]、支持向量机^[7]、灰色模型^[8]、粗糙集^[9]、云计算和极限学习机法^[10]等点预测方法不断被科研工作者们运用到电力负荷预测工作中来。

对于未来某个时期,区间预测可以不是一个简单的确定性数值,而是一个对应了一定水平的期望概率区间^[5,11-12]。区间预测可以比点预测传递更多的信息。在给定某个区间预测结果,可以根据这个区间的中点值,得到一个点预测值。进一步,通过概率密度预测的结果,可以得到区间预测各点负荷出现的概率值,获得未来负荷的概率密度函数^[13]。从预测结果所拥有的信息量来看,显然概率密度预测是最为详尽的。如果能够获得未来负荷变化的连

基金项目: 国家自然科学基金项目(71401049); 高等学校博士学科点专项科研基金资助项目(20130111120015); 安徽省自然科学基金项目(1408085QG137); 全国统计科研计划重点项目(2012LZ041)。

Project Supported by National Natural Science Foundation of China (71401049); Project Supported by Specialized Research Fund for the Doctoral Program of Higher Education (20130111120015) .

续的概率密度函数,分析负荷分布区间的概率,则可使电力系统决策人员更好地了解未来负荷的变化波动范围,更好地认识到未来负荷可能存在的不确定性和面临的风险因素,及时做出更为合理的决策。然而,概率密度预测的方法需要依赖于更多的理论推导,涉及到更加复杂的数学计算。因此,关于电力负荷概率密度预测技术的研究还不多见^[14]。本文的研究重点是通过运用神经网络分位数回归方法来实现考虑温度因素的中期负荷概率密度预测,实现获得预测对象连续的概率密度函数。

Koenker 等为了解决普通最小二乘法(ordinary least square, OLS)难以处理响应变量存在非对称分布或数据分布较分散的情况,提出了分位数回归(quantile regression, QR),可以在不同分位点下解释各个输入变量对响应变量的影响,得到更多关于输入变量与响应变量之间关系的信息^[15]。分位数回归不仅能够揭示输入变量与响应变量在各个分位点处的异质关系,而且可以得到输入变量在连续分位点下的条件分位数信息,便于科学决策。但 Koenker 提出的 QR 仍然是建立在线性回归的基础上,这样处理的结果,只能对那些变量之间存在简单线性关系,能够有比较好的描述和反映,但针对比较复杂的非线性函数,处理起来比较困难^[16]。Taylor 等人在分位数回归的基础上,把神经网络运用到分位数回归中去,从而提出了一种非线性分位数回归分析方法,即为神经网络分位数回归(neural network quantile regression, NNQR)^[17]。在这种非线性分位数回归的分析方法下,不仅可以取得较好的预测精度,同时也能分析解释变量对响应变量连续条件密度函数的影响^[18-19]。

本文主要通过神经网络分位数回归理论,在考虑温度影响因素和不考虑温度影响因素 2 种不同情况下,可以得出中期电力负荷在任何一天所有分位点上连续的概率密度预测函数曲线图,同时比较这二者之间的差别,得到更多关于温度影响电力系统中期负荷的信息;然后再对考虑温度因素和不考虑温度因素进行误差分析;最后本文将概率密度曲线上最高概率的点预测值(众数)与传统的径向基(radial basis function, RBF)神经网络和前向反馈(back propagation, BP)神经网络的预测结果进行对比。

1 分位数回归

分位数回归依据被解释变量的条件分位数对输入变量 X 进行回归,得到所有分位数下的回归模型,这样运用分位数回归可以更细致地反映出输入

变量对被解释变量的影响。我们也可以通过分析这些回归模型,获得输入变量在不同范围内对被解释变量的不同影响;同时也能获得更多输入变量对被解释变量位置、散布、形状影响的信息^[16]。

分位数回归首先定义损失函数,通过损失函数最小化,优化估计出使损失函数最小的最优参数,估计出的参数是随着分位点的不同在不停变化,这样就可以连续反映出输入变量对响应变量比较完备的解释和影响。损失函数定义为

$$\rho_{\theta}(\varepsilon)=\varepsilon \cdot[\theta-I(\varepsilon)] \quad (1)$$

式中示性函数 $I(\varepsilon)=\begin{cases} 0, & \varepsilon \geq 0 \\ 1, & \varepsilon < 0 \end{cases}$,这种函数本质是一种

分段线性凸函数。分位数回归实质就是通过示性函数对残差绝对值赋予不同权重,从而通过调节不同分位点,得到不同的参数估计,通过分析不同参数估计数,得出输入变量在不同分位点下对响应变量的影响,为研究对象提供更多更有用的信息。

Koenker 提出的 QR 仍然是建立在线性回归的基础上对输入变量和响应变量之间的关系进行分析^[15]。也就是假设响应变量为 Y ,输入变量为一列因素 X_1, \dots, X_n ,先建立线性分位数函数模型,即

$$Q_Y(\theta|X)=X \cdot \beta(\theta) \quad (2)$$

式中: X 为解释变量组成的矩阵;分位点 $\theta \in (0, 1)$; $\beta(\theta)$ 为参数矩阵,分位数回归通过采用单纯形法、内点算法等优化方法,对式(3)进行优化,从而估计出参数。

$$\min_{\beta} \rho_{\theta}(Y_i - X_i^T \beta(\theta)) = \min_{\beta} \theta |Y_i - X_i^T \beta(\theta)| + \min_{\beta} (1 - \theta) |Y_i - X_i^T \beta(\theta)| \quad (3)$$

式中: X_i^T 为输入变量 X 第 i 个分量的转置; Y_i 为响应变量 Y 的第 i 个分量。

分位数回归优势在于:首先,它对模型中的随机扰动残差项不要做任何分布的假定,这与最小二乘法回归具有很明显的区别,这样整个回归模型就有很好的稳健性;然后,分位数回归由于是对所有分位数进行回归,对数据中出现的异常点或奇异点具有耐抗性,可以克服这种非平稳的数据,从而可以更好地反映被解释变量;最后,分位数回归估计出来的参数,具有在大样本理论下的渐进优良性^[15]。

2 神经网络分位数回归

2.1 神经网络理论

神经网络兴起于 20 世纪中叶,是一种跨学科的理论知识。它通过仿照人类神经元工作过程,借助于计算机,实现人工神经网络过程。神经网络由于

具有很强的鲁棒性、自适应性和自组织能力，而且具有很强的逼近能力，近几年发展较快。常见的神经网络有 RBF 和 BP 神经网络，其中作为神经网络隐含层的传递函数，RBF 神经网络一般采用高斯核函数；BP 神经网络一般采用 Sigmoid 函数，其形式为

$$K = 1 / (1 + e^{-x}) \quad (4)$$

式中 K 为隐含层期望输出值。采用这种函数能够模仿神经元的非线性过程，同时可以对数据两端进行抑制，而对中间数据更加敏感，这样可以使神经网络保持较好特征识别。

由于神经网络更适合运用于平稳的时间序列，这样在使用此方法进行预测时对数据的特征要求较高。但电力系统中期负荷预测与国家经济和政策有很大关系。通常认为电力中期负荷是一个非平稳的时间序列，这样在选择仅使用神经网络来进行电力负荷的中期预测会产生很大的预测误差。也就是说，数据平稳性越低，可能导致采用神经网络来进行预测产生的预测误差越大。

2.2 基于神经网络分位数回归的概率密度预测方法

分位数回归只是一种单纯线性回归，不能较好地对样本进行拟合，建立适应性较好的模型。神经网络由于采用非线性核函数，可以为处理复杂非线性对象提供较好的方式。本文主要基于 Taylor 提出的单隐层神经网络模型^[17]，运用神经网络分位数回归预测概率密度，采用双曲正切的 Sigmoid 函数作为神经网络隐含层基函数，在输入变量与响应变量之间建立稳定网络结构，实现对中期电力负荷概率密度预测。神经网络分位数回归模型的表达式为

$$Q_Y(\theta|X) = f[X, U(\theta), V(\theta)] = \sum_{j=1}^J \left\{ \frac{2v_j(\theta)}{-2 \sum_{i=1}^n u_{ij}(\theta) X_i} - v_j(\theta) \right\} \quad (5)$$

式中： θ 为分位点；输入层与隐含层之间的待估计权重矩阵 $U(\theta) = \{u_{ij}(\theta)\}$ ，其中 $i=1, 2, \dots, n$ ； $j=1, 2, \dots, J$ ；隐含层与输出层之间的连接权重向量 $V(\theta) = \{v_j(\theta)\}$ ， $j=1, 2, \dots, J$ 。

为实现模型(5)的参数估计，可以通过求解如下优化目标函数来完成。

$$\tilde{E}_\theta = \frac{1}{N} \sum_{i=1}^N \rho_\theta\{Y_i - f[X, U(\theta), V(\theta)]\} \quad (6)$$

式中： N 为输入样本个数； \tilde{E}_θ 为神经网络分位数回归的误差函数。

不过，这样容易使得神经网络模型陷入过程拟合状态。为此，在目标函数再增加相应的惩罚项，得到新的目标函数：

$$E_\theta(U(\theta), V(\theta)) = \tilde{E}_\theta + \lambda_1 \sum_{i,j} u_{ij}(\theta) + \lambda_2 \sum_{i,j} v_j(\theta) \quad (7)$$

式中： $E_\theta(U(\theta), V(\theta))$ 为加惩罚项的神经网络分位数回归的误差函数； λ_1 、 λ_2 为模型惩罚参数，通过确定最优惩罚参数，可以有效防止模型陷入过度对经验数据拟合，减少预测误差，提高预测精度。对式(7)进行优化，即 $\min_{U(\theta), V(\theta)} E_\theta(U(\theta), V(\theta))$ ，可以得出 $U(\theta)$ 、 $V(\theta)$ 的最优估计值 $\hat{U}(\theta)$ 、 $\hat{V}(\theta)$ 。然后将 $\hat{U}(\theta)$ 、 $\hat{V}(\theta)$ 带入式(5)中，得到响应变量条件分位数估计函数。根据许启发、蒋翠侠等人提出的条件分布等价于条件密度，进而可以由条件分布预测，进一步计算出条件密度预测^[16]。对 $dF(F^{-1}(\theta))/d\theta = 1$ 两边关于 θ 求微分可得

$$\begin{cases} f(F^{-1}(\theta)) = d\theta / dF^{-1}(\theta) \\ f(Q(\theta)) = d\theta / dQ(\theta) \end{cases} \quad (8)$$

式中 F 和 F^{-1} 分别为分布函数和分布函数的逆函数。

对式(8)离散化和条件化，即通过式(9)得到响应变量的条件概率密度预测函数 $\hat{f}(\hat{Q}_Y(\theta) | X)$ 。

$$\hat{f}(\hat{Q}_Y(\theta) | X) = \frac{2h_T}{\hat{Q}_Y(\theta + h_T | X) - \hat{Q}_Y(\theta - h_T | X)} \quad (9)$$

式中： h_T 为最优宽度； $\hat{Q}_Y(\theta - h_T | X)$ 与 $\hat{Q}_Y(\theta + h_T | X)$ 分别为 θ 分位点以 h_T 为半径的左右 2 个领域的条件分位数。最优窗宽确定对响应变量的条件概率密度预测具有重要影响，确定最优窗宽的方法有很多，本文根据 Portnoy 提出的自适应核密度估计方法来确定^[20]。关于最优窗宽的选择对响应变量概率密度预测的影响，也是后续研究的内容。

3 算例仿真

3.1 算例描述

本文选取 2010 年某地区电网 3 月 24 日至 31 日以及 4、5 月份历史电力日最大负荷和日最高温度为样本数据^[3]。本文选取前 7 d 历史最大负荷和日最高温度以及预测当天最高温度为输入变量，以 3 月最后一天和 4 月的 30 d 为输出期望值，所有样本都事先进行归一化处理。这样本文共选取了 31 组样本，对神经网络分位数回归模型进行训练，确定神经网络的参数，获得最优结构，对 5 月份中期电力负荷进行预测。在考虑温度因素情况下，神经网络结构为输入层 15 个节点，隐含层 1 个节点，输出层 1 个节点，即 15-1-1 结构；而在不考虑温度因素情况下，神经网络结构为输入层 7 个节点，隐含层 1 个节点，输出层 1 个节点，即 7-1-1 结构。神经网络的训练次数为 1 000 次，惩罚参数 λ_1 、 λ_2 都

为 0.1。通过训练好的神经网络结构, 求出 5 月份任何一天在所有分位点上连续的分位数, 本文选取分位点区间为 0.000 1 到 0.999 9, 间隔为 0.005, 然后以预测获得的每天最大电力负荷的分位数为输入变量通过高斯核密度估计方法, 得出 5 月份每天连续的概率密度曲线图。

3.2 考虑温度因素的电力系统中期负荷概率密度预测结果

根据前述内容, 运用神经网络分位数回归方法可以得到 5 月份每天连续的概率密度曲线图。图 1 给出了 5 月份其中 8 d 在没有考虑温度影响下的条件概率密度曲线图。此外, 本文也给出了考虑前 7 d 历史温度和预测当天温度情况下预测结果的概率密度曲线图, 如图 2 所示。

通过比较图 1、图 2 共 8 d 的连续概率密度预测曲线图可以得到, 在考虑温度因素的情况下, 真实值基本上都在概率密度预测曲线的最高概率点附近, 没有出现在概率密度尾部的情况; 但在不考虑温度因素的情况下, 真实值很多都偏离概率密度曲线的最高概率点, 其中第 2 天、第 6 天、第 14 天及第 18 天, 真实值都出现在概率密度函数曲线

的尾部。尤其第 2 和第 6 天, 真实值出现在概率密度预测分布图的最右侧及最左侧, 使得预测值严重偏离真实值。通过分析, 在采用神经网络分位数回归预测电力负荷中期概率密度时, 在考虑温度因素的情况下, 有较高概率实现预测值与真实值基本相同。同时也可以根据预测的概率密度曲线图, 预测电力系统中期负荷某天的均值、方差等其他信息。这样, 不仅使电力系统内部在获得更多关于中期负荷预测的有用信息, 也为中期负荷预测提供一种有意义的探索。

在运用神经网络分位数回归概率密度预测理论的基础上, 表 1 给出了 5 月份每天最大日负荷在概率密度曲线峰值处的点预测值(众数)的 4 种结果, 即在考虑温度因素、不考虑温度因素、不考虑历史负荷温度因素、不考虑预测当天温度因素这 4 种情况。

表 1 的实验结果说明, 在考虑温度因素时, 预测值与实际值平均绝对误差为 3.26%, 在其他 3 种不考虑温度因素情况下, 平均绝对误差分别为 3.53%、3.39%、4.51%; 在考虑温度因素时, 预测值与实际值最大相对误差为 10.330%, 在其他 3 种




图 1 不考虑温度因素的概率密度曲线图

Fig. 1 Diagram of probability density curve without considering temperature factor

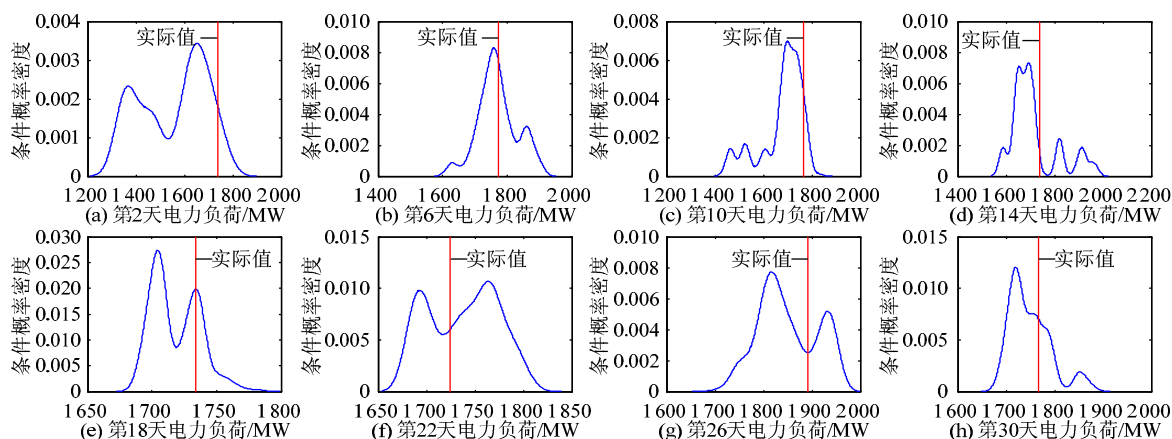


图 2 考虑温度因素的概率密度曲线图

Fig. 2 Diagram of probability density curve considering temperature factor

表 1 4 种情况预测结果
Tab. 1 Forecasting results of four kinds of situations

时 间/d	实际 值/MW	考虑温度因素		不考虑温度因素		不考虑历史负荷温度因素		不考虑预测当天温度因素	
		预测值/MW	相对误差/%	预测值/MW	相对误差/%	预测值/MW	相对误差/%	预测值/MW	相对误差/%
1	1 599	1 735.785	8.554	1 771.303	10.776	1 748.395	9.343	1 665.483	4.158
2	1 737	1 733.684	-0.191	1 612.669	-7.158	1 752.160	0.873	1 639.815	-5.595
3	1 876	1 733.921	-7.574	1 776.423	-5.308	1 736.043	-7.460	1 790.031	-4.583
4	1 765	1 735.927	-1.647	1 869.288	5.909	1 768.119	0.177	1 889.105	7.031
5	1 937	1 736.903	-10.330	1 729.753	-10.699	1 768.983	-8.674	1 650.516	-14.790
6	1 773	1 736.751	-2.044	1 914.627	7.988	1 764.976	-0.453	1 756.403	-0.936
7	1 778	1 737.091	-2.301	1 764.017	-0.786	1 775.132	-0.161	1 572.907	-11.535
8	1 751	1 739.109	-0.679	1 820.671	3.979	1 835.386	4.819	1 825.489	4.254
9	1 712	1 736.485	1.430	1 777.549	3.829	1 791.022	4.616	1 770.899	3.440
10	1 766	1 735.393	-1.733	1 696.316	-3.946	1 763.486	-0.142	1 704.953	-3.457
11	1 812	1 733.977	-4.306	1 811.507	-0.027	1 755.859	-3.098	1 805.984	-0.332
12	1 796	1 736.072	-3.337	1 777.248	-1.044	1 749.810	-2.572	1 735.150	-3.388
13	1 771	1 740.856	-1.702	1 825.802	3.094	1 788.345	0.979	1 695.508	-4.263
14	1 739	1 738.666	-0.019	1 753.363	0.826	1 746.968	0.458	1 697.677	-2.376
15	1 702	1 737.125	2.064	1 768.979	3.935	1 762.028	3.527	1 788.710	5.094
16	1 691	1 736.535	2.693	1 758.259	3.977	1 763.330	4.277	1 818.472	7.538
17	1 753	1 737.101	-0.907	1 755.909	0.166	1 777.874	1.419	1 734.114	-1.077
18	1 734	1 735.625	0.094	1 762.237	1.628	1 771.469	2.161	1 703.649	-1.750
19	1 751	1 738.778	-0.698	1 787.685	2.095	1 789.153	2.179	1 696.854	-3.092
20	1 803	1 735.938	-3.719	1 783.486	-1.082	1 752.143	-2.821	1 788.660	-0.795
21	1 719	1 736.588	1.023	1 791.412	4.212	1 773.925	3.195	1 809.267	5.251
22	1 724	1 736.426	0.721	1 752.730	1.666	1 788.607	3.748	1 763.117	2.269
23	1 697	1 734.155	2.189	1 766.264	4.082	1 749.896	3.117	1 725.019	1.651
24	1 835	1 735.336	-5.431	1 716.727	-6.445	1 746.148	-4.842	1 699.920	-7.361
25	1 880	1 735.992	-7.650	1 822.786	-3.043	1 743.452	-7.263	1 813.496	-3.537
26	1 893	1 736.632	-8.260	1 877.938	-0.796	1 760.861	-6.980	1 815.698	-4.084
27	1 854	1 738.574	-6.226	1 820.336	-1.816	1 752.803	-5.458	1 719.714	-7.243
28	1 799	1 741.681	-3.186	1 825.040	1.447	1 776.104	-1.273	1 714.175	-4.715
29	1 743	1 735.755	-0.416	1 816.135	4.196	1 751.663	0.497	1 721.417	-1.238
30	1 768	1 735.871	-1.817	1 755.396	-0.713	1 748.432	-1.107	1 715.277	-2.982
31	1 888	1734.245	-8.144	1 834.433	-2.837	1 745.793	-7.532	1 699.314	-9.994

不考虑温度因素情况下，最大相对误差分别为 10.776%、9.343%、14.790%。通过分析可以得出，在同样适用于神经网络分位数回归概率密度预测方法时，考虑温度因素时，预测结果优于不考虑温度因素时的结果；同时可以得到预测当天的温度因素对中期负荷的影响比较大，这要求本文在对电力系统中期负荷进行预测时，要充分考虑预测当天温度因素，以减少电力系统中期负荷预测的不确定因素。为充分说明本文方法的高效性，选取与神经网络分位数回归方法具有相同的隐含层节点数和训练次数的传统 BP 和 RBF 神经网络的点预测误差进行对比，如表 2 所示。

表 2 实验结果说明，在采用传统 BP 和 RBF 对电力系统中期负荷进行预测时，得到平均绝对误差分别为 3.60%、3.46%，最大相对误差分别为 12.55%、11.05%，比采用神经网络分位数回归预测概率密度方法得到的误差要大，且不考虑温度因素时，RBF 神经网络完全预测失败。因此，神经网络分位数回

表 2 BP 和 RBF 神经网络的预测误差
Tab. 2 Forecasting errors of BP and RBF neural network

算法	考虑温度因素		不考虑温度因素	
	平均绝对 误差/%	最大相对 误差/%	平均绝对 误差/%	最大相对 误差/%
BP	3.60	12.55	3.57	14.62
RBF	3.46	11.05	17.03	88.24

归预测概率密度方法优于传统神经网络方法。

4 结论

本文运用神经网络分位数回归概率密度预测方法，对电力系统中期负荷进行了概率密度预测和日最大负荷点预测，在分别考虑了温度因素和不考虑温度因素的情况下，得出以下结论：

- 1) 使用神经网络分位数回归概率密度预测方法，可以给出电力负荷在每天连续的概率分布曲线图，从而得到更多关于电力系统中期负荷有用的信息，为电力系统调度提供更多有价值信息。
- 2) 在比较考虑温度因素和不考虑温度因素预

测的概率密度曲线图,可以得出在考虑温度时,真实值基本出现在概率密度图的最高概率点附近,这表明以较高概率出现的预测值与真实值基本上相同;而在不考虑温度因素时,真实值很多处于概率密度函数的尾部,这导致点预测值误差较大。本文通过概率密度预测可以得出,在考虑温度因素时,得出的预测精度是最高的,真实值基本都出现在概率密度曲线图上的峰值处或其附近处。通过与传统神经网络进行比较,得出的预测精度也是最高的,这也为电力系统中期负荷预测提供一种更加全面的预测技术,为中期电力负荷预测提供更多的有用信息。

参考文献

- [1] 牛东晓,曹树华,卢建昌,等.电力负荷预测技术及其应用[M].北京:中国电力出版社,2009:1-8.
- [2] 廖峰,徐聪颖,姚建刚,等.常德地区负荷特性及其影响因素分析[J].电网技术,2012,36(7):117-125.
Liao Feng, Xu Congying, Yao Jiangang, et al. Load characteristics of Changde region and analysis on its influencing factors[J]. Power System Technology, 2012, 36(7): 117-125(in Chinese).
- [3] 贺辉.电力负荷预测和负荷管理[M].北京:中国电力出版社,2013:1-4.
- [4] 肖白,周潮,穆钢.空间电力负荷预测方法综述与展望[J].中国电机工程学报,2013,33(25):78-92.
Xiao Bai, Zhou Chao, Mu Gang. Review and prospect of the spatial load forecasting methods[J]. Proceedings of the CSEE, 2013, 33(25): 78-92(in Chinese).
- [5] 周建中,张亚超,李清清,等.基于动态自适应径向基函数网络的概率性短期负荷预测[J].电网技术,2010,34(3):37-41.
Zhou Jianzhong, Zhang Yachao, Li Qingqing, et al. Probabilistic short-term load forecasting based on dynamic self-adaptive radial basis function network[J]. Power System Technology, 2010, 34(3): 37-41(in Chinese).
- [6] 牛东晓,魏亚楠.基于FHNN相似日聚类自适应权重的短期电力负荷组合预测[J].电力系统自动化,2013,34(3):54-57.
Niu Dongxiao, Wei Yinnan. Short-term power load combined forecasting adaptive weighted by FHNN similar-day clustering[J]. Automation of Electric Power Systems, 2013, 34(3): 54-57(in Chinese).
- [7] 李瑾,刘金朋,王建军.采用支持向量机和模拟退火算法的中长期负荷预测方法[J].中国电机工程学报,2011,31(16):63-66.
Li Jin, Liu Jinpeng, Wang Jianjun. Mid-long term load forecasting based on simulated annealing and SVM algorithm[J]. Proceedings of the CSEE, 2011, 31(16): 63-66(in Chinese).
- [8] 王大鹏,汪秉文.基于变权缓冲灰色模型的中长期负荷预测[J].电网技术,2013,37(1):167-171.
Wang Dapeng, Wang Bingwen. Medium-and long-term load forecasting based on variable weights buffer grey model[J]. Power System Technology, 2013, 37(1): 167-171(in Chinese).
- [9] 龙丹丽,黎静华,韦化.粗糙集法解多环境因素影响的母线负荷预测问题[J].电网技术,2013,37(5):1335-1340.
Long Danli, Li Jinghua, Wei Hua. A solution of multi environmental factor-influenced bus load forecasting by rough set method[J]. Power System Technology, 2013, 37(5): 1335-1340(in Chinese).
- [10] 王保义,赵硕,张少敏.基于云计算和极限学习机的分布式电力负荷预测算法[J].电网技术,2014,38(2):526-531.
Wang Baoyi, Zhao Shuo, Zhagn Shaomin. A distributed load forecasting algorithm based on cloud computing and extreme learning machine[J]. Power System Technology, 2014, 38(2): 526-531(in Chinese).
- [11] 方仍存,周建中,张勇传,等.基于粒子群优化的非线性灰色Bernoulli模型在中长期负荷预测中的应用[J].电网技术,2008,32(12):60-63.
Fang Rengcun, Zhou Jianzhong, Zhang Yongchuan, et al. Application of particle swarm optimization based nonlinear grey bernoulli model in medium and long-term load forecasting[J]. Power System Technology, 2008, 32(12): 60-63(in Chinese).
- [12] 陈新宇,康重庆,陈敏杰.极值负荷及其出现时刻的概率化预测[J].中国电机工程学报,2011,31(22):64-72.
Chen Xinyu, Kang Chongqing, Chen Minjie. Short term probabilistic forecasting of the magnitude and timing of extreme load[J]. Proceedings of the CSEE, 2011, 31(22): 64-72(in Chinese).
- [13] 方仍存.电力系统负荷区间预测[D].武汉:华中科技大学,2008.
- [14] 何耀耀,许启发,杨善林,等.基于RBF神经网络分位数回归的电力负荷概率密度预测方法[J].中国电机工程学报,2013,33(1):93-98.
He Yaoyao, Xu Qifa, Yang Shanlin, et al. A power load probability density forecasting method based on RBF neural network quantile regression[J]. Proceedings of the CSEE, 2013, 33(1): 93-98(in Chinese).
- [15] Koenker R W, Bassett Jr G. Regression quantiles[J]. Econometrica, 1978, 46(1): 33-50.
- [16] 许启发,蒋翠侠.分位数局部调整模型及应用[J].数量经济技术经济研究,2011,28(8):115-133.
Xu Qifa, Jiang Cuixia. Quantile partial adjustment model and its application[J]. Journal of Quantitative & Technical Economics, 2011, 28(8): 115-133(in Chinese).
- [17] Taylor J W. A quantile regression neural network approach to estimating the conditional density of multiperiod returns[J]. Journal of Forecasting, 2000, 19(4): 299-311.
- [18] Feng Y, Li R, Sudjianto A, et al. Robust neural network with applications to credit portfolio data analysis[J]. Statistics and Its Interface, 2010, 3(4): 437.
- [19] Cannon A J. Quantile regression neural networks: implementation in R and application to precipitation downscaling[J]. Computers & Geosciences, 2010, 37(9): 1277-1284.
- [20] Portnoy S, Koenker R. Adaptive L-estimation for linear models[J]. Annals of Statistics, 1989, 17(1): 362-381.



何耀耀

收稿日期:2013-12-12。

作者简介:

何耀耀(1982),男,工学博士,副教授,硕士生导师,主要从事智能优化方法在电力系统中的应用,E-mail:hy-342501y@163.com;

闻才喜(1986),男,硕士研究生,主要研究方向为分位数回归预测方法,E-mail:wcxhfut@163.com;

许启发(1975),男,教授,博士生导师,主要研究方向为风险分析与预测科学,E-mail:xuqifa1975@163.com。

(责任编辑 杜宁)